

Basit Doğrusal Regresyon Modeli

Ekonometri I

Dr. Ömer Kara¹

¹İktisat Bölümü
Eskişehir Osmangazi Üniversitesi

10 Kasım 2021

Taslak

1 Motivasyon

2 Basit Doğrusal Regresyon Modeli

- Basit Doğrusal Regresyon Modelinin Mantığı
- Basit Doğrusal Regresyon Modeli
- Gauss–Markov Varsayımları
- Anakütle Regresyon Fonksiyonu

3 Basit Doğrusal Regresyon Modeli Tahmini

- Örneklem Regresyon Fonksiyonu
- Tahmin Yöntemleri
- SEKK Parametre Tahmincileri
- Yorumlama ve Örnekler
- Tahmin Edilen Değer ve Kalıntı
- Kareler Toplamları ve Determinasyon Katsayısı
- SEKK Parametre Tahmincilerinin Varyansı

Motivasyon

Bu bölümde, sırasıyla aşağıdaki konular incelenecektir.

- Basit Doğrusal Regresyon modeli
- Basit Doğrusal Regresyon modelinde Gauss–Markov varsayımları
- Basit Doğrusal Regresyon modelinin tahminine ait yöntemler
- Sıradan En Küçük Kareler parametre tahmincileri
- Determinasyon Katsayısı
- Sıradan En Küçük Kareler parametre tahmincilerinin özellikleri
- Basit Doğrusal Regresyon modelinde Gauss–Markov teoremi

Motivasyon

- Basit Doğrusal Regresyon (BDR) iki farklı değişken arasındaki ilişkiyi incelemek için kullanılır.
- Daha sonra göreceğimiz nedenlerden dolayı, uygulamalı analizde genel bir araç olarak kullanıldığında BDR modelinin kısıtları vardır.
- Buna rağmen, BDR modelinin nasıl yorumlanacağını öğrenmek, sonraki bölümlerde yapacağımız Çoklu Doğrusal Regresyon (ÇDR) modelini temelden anlamak için üzerinde durulması gereken bir konudur.
- BDR modelinin kısıtları ve ÇDR modeli hakkındaki detaylı bilgi “Ekonometri I - Çoklu Doğrusal Regresyon Modeli: Tahmin” konusunda bulunabilir.

Basit Doğrusal Regresyon Modelinin Mantığı

- Uygulamalı ekonometrik analizlerin çoğu şu önermeyle başlar:

Temel Ekonometrik Önerme

y ve x , bir anakütleyi temsil eden iki rassal değişkendir ve biz, “ y ’yi x cinsinden açıklamak” veya “ y ’nin x ’teki değişikliklerle nasıl değiştiğini incelemekle” ilgileniyoruz.

- “Ekonometri I - Matematik ve İstatistik Gözden Geçirme” konusunda y ve x arasındaki **kesin ilişkiyi** gösteren fonksiyonları incelemiştik.
- Fakat sosyal bilimlerde iki değişken arasındaki ilişki hiçbir zaman kesin değildir.
- Bu nedenle, “ y ’yi x cinsinden açıklayacak” bir model yazarken üç sorun vardır.
 - ❶ İki değişken arasında hiçbir zaman kesin bir ilişki olmadığına göre, **diğer faktörlerin** y ’yi etkilemesine nasıl izin verebiliriz?
 - ❷ y ve x arasındaki ilişkiyi belirten **fonksiyonel form** nedir?
 - ❸ y ve x arasında bir **ceteris paribus** ilişkisi yakaladığımızdan nasıl emin olabiliriz?
- Bu sorunları, y ’den x ’e ilişkin bir denklem yazarak Slayt 6’daki gibi çözebiliriz.

Basit Doğrusal Regresyon Modeli

Model

$$y = \beta_0 + \beta_1 x + u \quad (\text{İndekssiz})$$

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, 2, \dots, n \quad (\text{İndeksli})$$

- k : bağımsız değişken sayısı $\longrightarrow k = 1$
- $k + 1$: bilinmeyen sabit β parametre sayısı $\longrightarrow \beta_0, \beta_1$
- n : gözlem (veri) sayısı $\longrightarrow i = 1, 2, \dots, n$ ve $s = 1, 2, \dots, n, i \neq s$
- y : bağımlı değişken
- x : bağımsız değişken
- u : Hata terimi, x dışında modele dahil edilmemiş tüm faktörlerin ortak etkisi
- β_0 : Kesim parametresi (1 tane var), sabit terim olarak da adlandırılır
- β_1 : x bağımsız değişkeni için eğim parametresi (1 tane var)
- \mathbf{x} : Tüm bağımsız değişkenlerin temsili $\longrightarrow \mathbf{x} = \{x\}$
- Yukarıdaki model bazen **anakütle modeli** olarak da bilinir.

Basit Doğrusal Regresyon Modeli

Model

$$y = \beta_0 + \beta_1 x + u \quad (\text{İndekssiz})$$

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, 2, \dots, n \quad (\text{İndeksli})$$

- u : Bağımlı değişken y üzerinde etkili olan bağımsız değişken x dışındaki diğer gözlenemeyen faktörleri temsil eder.
- β_0 : $x = 0$ iken y 'nin alacağı değeri gösterir.
- β_1 : y 'yi etkileyen diğer tüm faktörler, yani u 'da içerilen faktörler, sabitken ($\Delta u = 0$), x 'deki değişimin y 'de yaratacağı yalın etkiyi/değişmeyi gösterir.

$$\Delta y = \beta_1 \Delta x + \Delta u$$

$$\Delta y = \beta_1 \Delta x \quad \text{eğer} \quad \Delta u = 0$$

- Parametreleri yorumlarken fonksiyonel forma dikkat edilmelidir.
- Farklı fonksiyonel formların yorumlamaları hakkındaki detaylı bilgi Slayt ??'de bulunabilir.
- $\Delta u = 0$ olduğunda, u 'nun içinde bulunan tüm gözlenemeyen faktörlerin ayrı ayrı sabit olduğu değil, ortalama olarak değişimin olmadığı kastedilir. Yani, negatif ve pozitif işaretli u 'lar birbirini götürdüğünde ortalama olarak değişim olmayacaktır.

Basit Doğrusal Regresyon Modeli

- Regresyon modellerinde değişkenler için kullanılan terminoloji aşağıda verilmiştir.

Tablo 1: Değişkenler Terminolojisi

y	x
Bağımlı Değişken	Bağımsız Değişken
Açıklanan Değişken	Açıklayıcı Değişken
Tepki Değişkeni	Kontrol Değişkeni
Tahmin Edilen Değişken	Tahmin Eden Değişken
Regresand	Regressor

Basit Doğrusal Regresyon Modeli - Örnek 1

Ücret vs. Eğitim Modeli

Bir çalışanın fazladan 1 yıl eğitim aldığında ücretinin ne kadar arttığını araştırmak istediğimizi düşünelim. Yani, eğitimin ücret üzerindeki etkisini ayırtırmak istiyoruz.

$$wage = \beta_0 + \beta_1 educ + u$$

wage: saat başına ücret (dolar); *educ*: eğitim düzeyi (yıl)

- **Eğim Parametresi** β_1 : Ceteris paribus eğitim düzeyindeki 1 birimlik değişimin, saat başına ücretinde meydana getireceği değişimi belirtir.

$$\Delta wage = \beta_1 \Delta educ + \Delta u$$

$$\Delta wage = \beta_1 \Delta educ \quad \text{eğer} \quad \Delta u = 0$$

- **Rassal Hata Terimi** u : Saat başına ücreti etkileyen, eğitim düzeyi dışındaki tecrübe, kıdem, doğuştan gelen yetenek, cinsiyet ve yaş gibi tüm faktörlerin ortak etkisini gösterir.

Ceteris Paribus \Leftrightarrow Diğer tüm faktörlerin sabit tutulması $\Leftrightarrow \Delta u = 0$

Basit Doğrusal Regresyon Modeli - Örnek 2

Tarımsal Çıktı vs. Gübre Miktarı Modeli

Gübre miktarının üretilen tarımsal çıktı miktarı üzerindeki yalın etkisini araştırmak istediğimizi düşünelim. Yani, kullanılan gübre miktarının üretilen tarımsal çıktı miktarı üzerindeki etkisini ayırtırmak istiyoruz.

$$output = \beta_0 + \beta_1 fert + u$$

output: tarımsal çıktı miktarı; *fert*: gübre miktarı

- **Eğim Parametresi** β_1 : Ceteris paribus gübre miktarındaki 1 birimlik değişimin, çıktı miktarında meydana getireceği değişimi belirtir.

$$\Delta output = \beta_1 \Delta fert + \Delta u$$

$$\Delta output = \beta_1 \Delta fert \quad \text{eğer} \quad \Delta u = 0$$

- **Rassal Hata Terimi** u : Çıktı miktarını etkileyen, gübre miktarı dışındaki yağmur miktarı ve toprağın kalitesi gibi tüm faktörlerin ortak etkisini gösterir. Ceteris Paribus \Leftrightarrow Diğer tüm faktörlerin sabit tutulması $\Leftrightarrow \Delta u = 0$

Doğrusal Model

- Regresyon modelinin doğrusal olması şu anlama gelir: x 'deki değişimin y 'de meydana getireceği etki, x 'in başlangıç değeri ne olursa olsun aynıdır, yani sabittir.
- Uygulamadaki bu sabit etki varsayımı çoğu zaman gerçeklere uymaz. Örneğin:
 - Ölçeğe göre artan ya da azalan getiri doğrusal regresyon modelleriyle açıklanamaz.
 - Slayt 9'de verilen ücret vs. eğitim modelinde, ilave bir yıl eğitimin etkisi önceki eğitim düzey(ler)ine göre aynıdır, fakat gerçekte daha fazla olması beklenir.
 - Tecrübenin ücret üzerindeki etkisini araştıran bir modelde ise gerçekte tecrübe düzeyinin ücretler üzerinde önce artan sonra azalan bir etkiye sahip olması beklenir.
- Doğrusal modellerin bu kısıtına rağmen Ekonometri Teorisi'nde basitliği ve kolay anlaşılması nedeniyle sıklıkla kullanılır.
- Sabit olmayan etkilerin nasıl modelleneceğini daha sonra göreceğiz.

Gauss–Markov Varsayımları

BDR.1: Gözlem Sayısı

Gözlem sayısı n tahmin edilecek anakütle parametre sayısından büyük ya da en azından eşit olmalıdır.

$$n \geq k + 1$$

BDR.2: Parametrelerde Doğrusallık

Model parametrelerde doğrusaldır.

$$y = \beta_0 + \beta_1 x + u \quad \checkmark$$

$$y = \beta_0 + \beta_1 x^2 + u \quad \checkmark$$

$$y = \beta_0 + \beta_1^2 x + u \quad \times$$

$$y = \beta_0 + \sqrt{\beta_1} x + u \quad \times$$

[► Detay](#)

Gauss–Markov Varsayımları

BDR.3: Rassallık

Tahminde kullanılan n tane gözlem ilgili anakütleden rassal örnekleme yoluyla seçilmiştir. Yani gözlemler stokastiktir (rassal), yani deterministik (kesin) değildir.

$$\{(x_i, y_i) : i = 1, 2, \dots, n\}$$

BDR.4: Bağımsız Değişkenin Sabit Olmaması

Örnekleme (ve bu nedenle anaküttele) bağımsız değişken kendi içinde sabit değildir (yeterli değişkenlik vardır).

$$\sum_{i=1}^n (x_i - \bar{x})^2 > 0$$

[► Detay](#)

Gauss–Markov Varsayımları

BDR.5: Sıfır Koşullu Ortalama

Bağımsız değişkenin herhangi bir değeri verildiğinde, u hata teriminin beklenen değeri sıfıra eşittir.

$$E(u|x) = E(u|\mathbf{x}) = 0$$

[► Detay](#)

- Yinelenen Beklentiler Kanunu ve koşullu beklenen değer 5. özelliği kullanılarak Sıfır Koşullu Ortalama varsayımı yeniden tanımlanabilir.

[► Ek Bilgi](#)

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

[► Ek Bilgi](#)

Gauss–Markov Varsayımları

BDR.6: Otokorelasyon Olmaması

Hata terimleri arasında otokorelasyon yoktur.

$$\text{Corr}(u_i, u_s | x) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s | \mathbf{x}) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s) = 0, \quad i \neq s$$

- BDR.6 varsayımı, yatay-kesit verilerindeki rassallık varsayımı (BDR.3) nedeniyle aslında otomatik olarak sağlanır. Fakat çok ekstrem durumlarda gereklidir ve bu nedenle diğer birçok kaynaktan farklı olarak eklenmiştir.
- BDR.6 varsayımı aşağıdaki eşitlikleri de sağlar.

BDR.6: Otokorelasyon Olmaması

$$\text{Cov}(u_i, u_s | \mathbf{x}) = 0 \quad \text{ve} \quad \text{Cov}(u_i, u_s) = 0, \quad i \neq s$$

$$E(u_i u_s | \mathbf{x}) = 0 \quad \text{ve} \quad E(u_i u_s) = 0, \quad i \neq s$$

► Ek Bilgi

Gauss–Markov Varsayımları

BDR.7: Sabit Varyans (Homoscedasticity)

u hata teriminin bağımsız değişken x 'e göre koşullu varyansı sabittir.

$$\text{Var}(u|x) = \sigma^2$$

$$\text{Var}(u|\mathbf{x}) = \sigma^2$$

$$\text{Var}(u) = \sigma^2$$

[► Detay](#)

- BDR.7 varsayımı aşağıdaki eşitlikleri de sağlar.

BDR.7: Sabit Varyans (Homoscedasticity)

$$E(u^2|\mathbf{x}) = \sigma^2 \quad \text{ve} \quad E(u^2) = \sigma^2$$

[► Ek Bilgi](#)

- σ **regresyonun standart sapmasıdır** (bilinmiyor, bu nedenle tahmin edilecek).

Gauss–Markov Varsayımları

- Yukarıda verilen **Gauss–Markov Varsayımları** yatay-kesit verisi ile yapılan regresyon için geçerli varsayımlardır.
- Zaman serileri ile yapılan regresyonlarda bu varsayımların değiştirilmesi gerekir.
- Gauss–Markov Varsayımları, **BDR Varsayımları** olarak da anılır.
- Bazı BDR Varsayımlarının detayı ilerleyen slaytlarda konu akışı içinde verilmiştir.
- Gauss–Markov Varsayımları daha sonra **Gauss–Markov Teoremi**'ni oluşturmada kullanılacaktır.
- Gauss–Markov Teoremi ise BDR modelinin **Sıradan En Küçük Kareler Yöntemi** ya da **Momentler Yöntemi** ile tahmini için teorik dayanak sağlamada kullanılacaktır. Bakınız Slayt ??.

Anakütle Regresyon Fonksiyonu

- **Anakütle Regresyon Fonksiyonu (ARF)**, BDR.5 varsayımı altında, bağımlı değişken y 'nin bağımsız değişken x 'e göre koşullu ortalamasıdır.

Anakütle Regresyon Fonksiyonu (ARF)

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$


$$E(y|x) = \beta_0 + \beta_1 x \quad (\text{ARF - İndekssiz})$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF - İndekssiz})$$

$$E(y_i|\mathbf{x}_i) = \beta_0 + \beta_1 x_i \quad (\text{ARF - İndeksli})$$

- ARF tektir ve bilinmez.
- ARF, bağımsız değişken x 'in doğrusal bir fonksiyonudur.
- $y = \beta_0 + \beta_1 x + u$ modeline ait ARF Şekil 1'de gösterilmiştir.

Anakütle Regresyon Fonksiyonu



Şekil 1: $y = \beta_0 + \beta_1 x + u$ Modeline ARF

Kaynak: Wooldridge (2016)

Anakütle Regresyon Fonksiyonu

- BDR.5 ve BDR.7 varsayımları altında bağımlı değişken y 'nin bağımsız değişken x 'e göre koşullu dağılımı aşağıdaki gibi ifade edilebilir.

y 'nin x 'e Göre Koşullu Dağılımı

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$


$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

$$y|\mathbf{x} \sim \underbrace{(\beta_0 + \beta_1 x)}_{\text{Ortalama}}, \underbrace{\sigma^2}_{\text{Varyans}} \quad (y|\mathbf{x}'\text{in dağılımı})$$

[► Ek Bilgi](#)

- Verilmiş bağımsız değişken x düzeyinde bağımlı değişken y 'nin dağılımının ortalaması $E(y|\mathbf{x})$ ve varyansı σ^2 'dir.
- BDR.5 (sıfır koşullu ortalama) ve BDR.7 (sabit varyans) varsayımları altında, $y = \beta_0 + \beta_1 x + u$ modeline ait ARF ve $y|\mathbf{x}$ 'in dağılımı Şekil 2'de gösterilmiştir.

Anakütle Regresyon Fonksiyonu ve $y|x$ 'in Dağılımı



Şekil 2: $y = \beta_0 + \beta_1 x + u$ Modeline Ait ARF ve $y|x$ 'in Dağılımı

Kaynak: Wooldridge (2016)

Örneklem Regresyon Fonksiyonu: Amaç

- BDR tahminindeki asıl amacımız sırasıyla:
 - Öncelikle, iktisat teorisine göre model oluşturmak.
 - Gauss–Markov varsayımları kullanarak ARF’yi oluşturmak.
 - ARF’yi rassal örneklemleyle seçtiğimiz belli sayıdaki veriyi kullanarak tahmin etmektir.
- ARF’nin tahmini ise **Örneklem Regresyon Fonksiyonu**’dur ve bu tahmin örneklemden örnekleme değişir.

Model

$$y = \beta_0 + \beta_1 x + u$$

Anakütle Regresyon Fonksiyonu (ARF)

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x$$

Örneklem Regresyon Fonksiyonu (ÖRF)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- ARF’deki parametreler (β_0, β_1) bilinmeyen sabit sayılarken, ÖRF’deki parametreler $(\hat{\beta}_0, \hat{\beta}_1)$ örneklemden örnekleme değişen rassal değişkenlerdir.

Örneklem Regresyon Fonksiyonu: Amaç

Model

$$y = \beta_0 + \beta_1 x + u \quad (\text{İndekssiz})$$

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\text{İndeksli})$$

Anakütle Regresyon Fonksiyonu (ARF)

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{İndekssiz})$$

$$E(y_i|\mathbf{x}_i) = \beta_0 + \beta_1 x_i \quad (\text{İndeksli})$$

Örneklem Regresyon Fonksiyonu (ÖRF)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{İndekssiz})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{İndeksli})$$

Örneklem Regresyon Fonksiyonu

Örneklem Regresyon Fonksiyonu (ÖRF)


$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{İndekssiz})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{İndeksli})$$

$$\underbrace{y_i}_{\text{Gözlenen Değer}} = \underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} + \underbrace{\hat{u}_i}_{\substack{\text{Kalıntı (Artık)} \\ \text{Rassal Değil (Deterministik)}}$$

- \hat{y}_i : y_i bağımlı değişkeninin tahmini
- Parametre tahmincileri/tahmin edicileri örneklemden örnekleme değişir, yani rassaldır.
 - $\hat{\beta}_0$: β_0 kesim parametresinin tahmini (1 tane var)
 - $\hat{\beta}_1$: β_1 eğim parametresinin tahmini (1 tane var)
- \hat{u}_i : Kalıntı (artık) olarak adlandırılır. Gözlenen değer y_i ile tahmin edilen değer \hat{y}_i arasındaki farktır. Rassal değildir, tahmin sırasında hesaplanır. Hata terimi u_i 'nin örneklem analogu olarak yorumlanabilir fakat kesinlikle aynı şeyler değildir.
- $y = \beta_0 + \beta_1 x + u$ modeline ait ÖRF Şekil 3'de gösterilmiştir.

Örneklem Regresyon Fonksiyonu



Şekil 3: $y = \beta_0 + \beta_1 x + u$ Modeline Ait ÖRF

Kaynak: Wooldridge (2016)

Örneklem Regresyon Fonksiyonu

- Model, ARF ve ÖRF denklemleri arasında dikkat edilmesi gereken farklar vardır.

Model, ARF ve ÖRF

$$\underbrace{y_i}_{\text{Gözlenen Değer}} = \underbrace{\beta_0 + \beta_1 x_i}_{E(y_i | \mathbf{x}_i) \text{ (Sistemetik Kısım)}} + \underbrace{u_i}_{\text{Rassal Hata Terimi (Sistematik Olmayan Kısım)}} \quad (\text{Model})$$


$$E(y_i | \mathbf{x}_i) = \underbrace{\beta_0 + \beta_1 x_i}_{\text{Sistemetik Kısım}} \quad (\text{ARF})$$

$$\underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} = \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\text{Sistemetik Kısımın Tahmini}} \quad (\text{ÖRF})$$

$$\underbrace{y_i}_{\text{Gözlenen Değer}} = \underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} + \underbrace{\hat{u}_i}_{\text{Kalıntı (Artık) Rassal Değil (Deterministik)}}$$

- $y = \beta_0 + \beta_1 x + u$ modeline ait ARF ve ÖRF Şekil 4'de beraberce gösterilmiştir.

ARF ve ÖRF

Şekil 4: $y = \beta_0 + \beta_1 x + u$ Modeline Ait ARF ve ÖRF

Örneklem Regresyon Fonksiyonu: Tahmin Yöntemleri

Model, ARF ve ÖRF

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{ÖRF})$$

- Örneklem Regresyon Fonksiyonu (ÖRF), iki yöntemle tahmin edilebilir.
 - Sıradan En Küçük Kareler (SEKK) Yöntemi
 - Momentler Yöntemi
- İki yöntem de aynı tahmin sonuçlarını verir.

Sıradan En Küçük Kareler Yöntemi

- **Sıradan En Küçük Kareler Yöntemi**, kalıntı kareleri toplamını (SSR) en küçük yapan parametre tahmincilerini hesaplamaya çalışır.

Örneklem Regresyon Fonksiyonu (ÖRF)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Gözlenen Değer, Tahmin Edilen Değer ve Kalıntı

$$y_i = \hat{y}_i + \hat{u}_i \quad \longrightarrow \quad \hat{u}_i = y_i - \hat{y}_i$$

SEKK Amaç Fonksiyonu

$$\min_{\hat{\beta}_0, \hat{\beta}_1} SSR = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Sıradan En Küçük Kareler Yöntemi

SEKK Birinci Sıra Koşulları

$$\frac{\partial SSR}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\frac{\partial SSR}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

Sıradan En Küçük Kareler Yöntemi

SEKK Birinci Sıra Koşulları

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad \longrightarrow \quad \sum_{i=1}^n \hat{u}_i = 0$$

$$\sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad \longrightarrow \quad \sum_{i=1}^n x_i \hat{u}_i = 0$$

- Birinci sıra koşullarından elde edilen $k + 1$ tane denklemin çözümünden parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ (toplamda $k + 1 = 2$ tane) bulunur.

Momentler Yöntemi

- Anakütle moment koşulları BDR.5 varsayımı kullanılarak yazılabilir.
- Daha sonra anakütle moment koşullarını kullanarak örneklem moment koşulları elde edilebilir.

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

Momentler Yöntemi

Anakütle Moment Koşulları ve Örneklem Moment Koşulları

$$\begin{array}{ccc} \text{Anakütle} & & \text{Örneklem} \\ \underbrace{} & & \underbrace{\phantom{\sum_{i=1}^n \hat{u}_i = 0}} \\ E(u) = 0 & \longrightarrow & \sum_{i=1}^n \hat{u}_i = 0 \\ \\ E(xu) = 0 & \longrightarrow & \sum_{i=1}^n x_i \hat{u}_i = 0 \end{array}$$

Momentler Yöntemi

- Örneklem moment koşullarından elde edilen $k + 1$ tane denklemin çözümünden parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ (toplamda $k + 1 = 2$ tane) bulunur.
- SEKK birinci sıra koşulları ve örneklem moment koşulları aslında aynı denklemler kümesini verir.
- Bu nedenle, SEKK Yöntemi ve **Momentler Yöntemi** ile BDR modeli tahmin edildiğinde aynı sonuçlara ulaşılır.
- Genellikle kullanılan yöntem SEKK'dır. Bu nedenle parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ genellikle **SEKK parametre tahmincileri** ya da **SEKK tahmincileri** olarak adlandırılır.
- Bu yöntemlerin tek çözüm vermesi için BDR.4 (Bağımsız Değişkenin Sabit Olmaması) varsayımının sağlanması gereklidir. Bakınız Slayt 13.

SEKK Parametre Tahmincileri

Ana Model

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\text{Model - İndeksli})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{ÖRF - İndeksli})$$

- β_0 kesim parametresinin tahmini $\hat{\beta}_0$:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

[► Ek Bilgi](#)

- β_1 eğim parametresinin tahmini, ya da x 'in eğim parametresinin tahmincisi, $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

[► Ek Bilgi 1](#)[► Ek Bilgi 2](#)

SEKK Parametre Tahmincileri

- β_1 eğim parametresinin tahmini, ya da x 'in eğim parametresinin tahmincisi, $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \longrightarrow \hat{\beta}_1 = \frac{\overbrace{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}^{y \text{ ile } x\text{'in Örneklem Kovaryansı}}}{\underbrace{\sum_{i=1}^n (x_i - \bar{x})^2}_{x\text{'in Örneklem Varyansı}} \overbrace{n-1}^{n-1}}$$

- 1 $\hat{\beta}_1$, y ile x 'in örneklem kovaryansının, x 'in örneklem varyansına oranına eşittir.
- 2 $\hat{\beta}_1$ 'nın işareti y ile x 'in örneklem kovaryansının işaretine bağlıdır. Örneklemde y ve x aynı yönde ilişkiliyse $\hat{\beta}_1$ pozitif işaretli, ters yönde ilişkiliyse negatif işaretli olacaktır.
- 3 $\hat{\beta}_1$ 'nın hesaplanabilmesi için x 'de yeterli değişiklik olmalıdır. Eğer örneklemde tüm x 'ler aynı değerleri alıyorsa x 'in örneklem varyansı sıfır olur ve $\hat{\beta}_1$ tanımsız olur.

$$\sum_{i=1}^n (x_i - \bar{x})^2 > 0$$

Sıfır Koşullu Ortalama Varsayımı (BDR.5) Yorumu

Basit Doğrusal Regresyon Modeli

$$y = \beta_0 + \beta_1 x + u$$

- BDR modelinde, u 'nun x 'lerle ilişkisiz olması varsayımı, yani BDR.5:

$$E(u|x) = E(u|\mathbf{x}) = 0$$

- Yani x 'in anakütledeki tüm değerleri için u 'nun beklenen değeri sıfırdır.
- Ücret vs. eğitim modelinde (Slayt 9) BDR.5 varsayımı aşağıdaki gibi yazılabilir.

$$wage = \beta_0 + \beta_1 educ + u \quad (\text{Model})$$

$$E(u|educ) = 0 \quad (\text{BDR.5})$$

- Bu ücretleri etkileyen diğer faktörlerin (u) ortalama olarak $educ$ ile ilişkisiz olduğu anlamına gelir.
- Örneğin, doğuştan gelen yetenek (ability) u 'nun bir parçası ise, ortalama yetenek düzeyi, eğitimin tüm düzeylerinde aynıdır (sabittir).

$$E(ability|educ = 4) = E(ability|educ = 8) = \dots = 0$$

- Eğer eğitim düzeyi ile doğuştan gelen yeteneğin ilişkili olduğunu düşünüyorsak (örneğin: daha yetenekliler okulda da daha iyiler ve bu nedenle eğitim düzeyleri fazla), bu durumda BDR.5 varsayımı sağlanmaz.

Sıfır Koşullu Ortalama Varsayımı (BDR.5) Yorumu

- Tarımsal çıktı vs. gübre miktarı modelinde (Slayt 10), BDR.5 varsayımı aşağıdaki gibi yazılabilir.

$$output = \beta_0 + \beta_1 fert + u \quad (\text{Model})$$

$$E(u|fert) = 0 \quad (\text{BDR.5})$$

- Yani, tarımsal çıktı miktarını etkileyen diğer faktörler (yağmur miktarı, toprağın kalitesi vs.), ortalama olarak, $fert$ değişkeniyle ilişkisizdir.
- Eğer yüksek kaliteli toprak parçalarına yüksek miktarda gübre uygulanırsa (yani toprak kalitesi ve gübre miktarı ilişkili), hata terimi u 'nun beklenen değeri gübre miktarı ile değişir. Bu durumda BDR.5 varsayımı sağlanmaz.

Regresyonun Yorumu

Model ve ÖRF

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \quad (\text{ÖRF})$$

$$\Delta \hat{y} = \hat{\beta}_1 \Delta x \quad (\text{Değişim Cinsinden})$$

- Eğim paramtresi tahmincisi $\hat{\beta}_1$, bağımsız değişken x 'in y üzerindeki yalın/kısmi yani ceteris paribus etkisini verir.
- $\hat{\beta}_1$ 'nin yorumu:

$$\Delta \hat{y} = \hat{\beta}_1 \Delta x$$

- x 'de meydana gelen 1 birimlik değişimin y 'de meydana getireceği ortalama değişim $\hat{\beta}_1$ kadardır.
 - Parametreleri yorumlarken fonksiyonel forma dikkat edilmelidir.
 - Farklı fonksiyonel formların yorumlamaları hakkındaki detaylı bilgi Slayt ??'de bulunabilir.

Örnek: CEO Maaşı vs. Karlılık Modeli

CEO Maaşı vs. Karlılık Modeli

$$y = \beta_0 + \beta_1 x + u \longrightarrow salary = \beta_0 + \beta_1 roe + u \quad (\text{Model})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \longrightarrow \widehat{salary} = \beta_0 + \beta_1 roe \quad (\text{ÖRF})$$

$$\widehat{salary} = 963.191 + 18.501 roe \quad (\text{ÖRF})$$

$$n = 209$$

salary: CEO maaşı (bin dolar); *roe*: şirketin karlılık yüzdesi

- Kesim parametresi $\hat{\beta}_0 = 963.191$ olarak tahmin edilmiştir.
 - *roe* = 0 olduğunda modelce tahmin edilen CEO maaşı \widehat{salary} 'yi ifade eder. Yani şirketin karlılık yüzdesi *roe* sıfır olduğunda, CEO maaşı \$963191'dir.
- Eğim parametresi $\hat{\beta}_1 = 18.501$ olarak tahmin edilmiştir.
 - *roe*'yı 1 birim arttırdığımızda CEO maaşı *salary* 18.501 birim, yani \$18501 artar.
 - Başka bir ifadeyle, iki CEO'dan birinin *roe* düzeyi diğerinden bir birim fazlaysa, bu iki CEO için tahmin edilen maaş farkı ortalama olarak \$18501'dir.
 - Burada somut iki CEO'dan değil ortalama durumdan bahsedilmektedir.

Örnek: CEO Maaşı vs. Karlılık Modeli

- roe 'daki farklı artışların CEO maaşı üzerindeki etkisini tahmin etmek için ÖRF'yi kullanabiliriz. Örneğin, $\Delta roe = 30$ ise


$$\begin{aligned}\widehat{\Delta salary} &= 18.501 \Delta roe && \text{(Değişim Cins.)} \\ &= 18.501 \times 30 \\ &= 555.030\end{aligned}$$

- Farklı roe seviyelerindeki CEO maaşını tahmin etmek için ÖRF'yi kullanabiliriz. Örneğin, $roe = 30$ ise

$$\begin{aligned}\widehat{salary} &= 963.191 + 18.501 roe && \text{(ÖRF)} \\ &= 963.191 + 18.501 \times 30 \\ &= 1518.221\end{aligned}$$

- Ancak bu, şirketi %30 karlılığa sahip olan belirli bir CEO'nun \$1518221 kazandığı anlamına gelmez. Bu sadece ÖRF kullanılarak yapılan bir tahmindir.
- Slayt 40'de verilen CEO maaşı vs. karlılık modeline ait
 - ARF ve ÖRF'nin grafiği Şekil 5'de gösterilmiştir.
 - İlk 15 gözlem için bağımsız değişken roe , bağımsız değişken ya da gözlenen değer $salary$, tahmin edilen değer \widehat{salary} , ve kalıntı \hat{u} Şekil 6'de gösterilmiştir.

Örnek: CEO Maaşı vs. Karlılık Modeli



Şekil 5: CEO Maaşı vs. Karlılık Modeline Ait ARF ve ÖRF

Kaynak: Wooldridge (2016)

Örnek: CEO Maaşı vs. Karlılık Modeli

TABLE 2.2 Fitted Values and Residuals for the First 15 CEOs

obsno	roe	salary	salaryhat	uhat
1	14.1	1095	1224.058	-129.0581
2	10.9	1001	1164.854	-163.8542
3	23.5	1122	1397.969	-275.9692
4	5.9	578	1072.348	-494.3484
5	13.8	1368	1218.508	149.4923
6	20.0	1145	1333.215	-188.2151
7	16.4	1078	1266.611	-188.6108
8	16.3	1094	1264.761	-170.7606
9	10.5	1237	1157.454	79.54626
10	26.3	833	1449.773	-616.7726
11	25.9	567	1442.372	-875.3721
12	26.8	933	1459.023	-526.0231
13	14.8	1339	1237.009	101.9911
14	22.3	937	1375.768	-438.7678
15	56.3	2011	2004.808	6.191895

Şekil 6: CEO Maaşı vs. Karlılık Modeli Tahminine Ait İlk 15 Gözlem İçin Bazı Değerler

Kaynak: Wooldridge (2016)

Örnek: Ücret vs. Eğitim Modeli

Ücret vs. Eğitim Modeli

$$y = \beta_0 + \beta_1 x + u \quad \longrightarrow \quad wage = \beta_0 + \beta_1 educ + u \quad (\text{Model})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad \longrightarrow \quad \widehat{wage} = \beta_0 + \beta_1 educ \quad (\text{ÖRF})$$

$$\widehat{wage} = -0.9 + 0.54 educ \quad (\text{ÖRF})$$

$$n = 526$$

wage: saat başına ücret (dolar); *educ*: eğitim düzeyi (yıl)

- Kesim parametresi $\hat{\beta}_0 = -0.9$ olarak tahmin edilmiştir.
 - *educ* = 0 olduğunda modelce tahmin edilen ücret \widehat{wage} 'i ifade eder. Yani çalışanın eğitim düzeyi *educ* sıfır olduğunda, ücreti $-\$0.9$ 'dur. Ancak ücret negatif olamayacağı için yorumlanması anlamsızdır.
- Eğitim parametresi $\hat{\beta}_1 = 0.54$ olarak tahmin edilmiştir.
 - *educ*'u 1 yıl arttırdığımızda ücret *wage* 0.54 birim, yani $\$0.54$ artar.
 - Başka bir ifadeyle, iki çalışandan birinin *educ* düzeyi diğerinden bir yıl fazlaysa, bu iki çalışan için tahmin edilen ücret farkı ortalama olarak $\$0.54$ 'dir.
 - Burada somut iki çalışandan değil ortalama durumdan bahsedilmektedir.

Tahmin Edilen Değer ve Kalıntı

i 'inci Gözlem İçin Tahmin Edilen \hat{y}_i Değeri

$$\underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{ÖRF})$$

- x_i değerini tahmin edilen regresyonda (ÖRF'de) yerine koyarsak tahmin edilen değer \hat{y}_i 'yi elde ederiz.

Kalıntı (Artık)

$$\underbrace{\hat{u}_i}_{\text{Kalıntı (Artık)}} = \underbrace{y_i}_{\text{Gözlenen Değer}} - \underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}}$$

- Gözlenen y_i değeriyle tahmin edilen değer \hat{y}_i arasındaki fark kalıntı \hat{u}_i 'yi verir.
- $\hat{u}_i > 0$ ise $y_i > \hat{y}_i$, eksik tahmin yapılmıştır.
- $\hat{u}_i < 0$ ise $y_i < \hat{y}_i$, fazla tahmin yapılmıştır.

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- SEKK kalıntılarının toplamı ve dolayısıyla da örneklem ortalaması sıfıra eşittir.

$$\sum_{i=1}^n \hat{u}_i = 0 \quad \text{ve} \quad \bar{\hat{u}} = 0$$

- Bu durum SEKK birinci sıra koşullarından ilkinin (aynı zamanda örneklem moment koşullarından ilkinin) bir sonucudur. Bakınız Slayt 31 ve Slayt 33.
- Anakütledeki hata terimi u 'nun örneklemdeki analogu kalıntı \hat{u} olarak yorumlanabilir fakat kesinlikle aynı şeyler değildir.

$$\underbrace{u}_{\text{Anakütle}} \longrightarrow \underbrace{\hat{u}}_{\text{Örneklem}}$$

$$\underbrace{E(u) = 0}_{\text{Anakütle}} \longrightarrow \underbrace{E(\hat{u}) = 0, \sum_{i=1}^n \hat{u}_i = 0 \quad \text{ve} \quad \bar{\hat{u}} = 0}_{\text{Örneklem}}$$

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- 2 Bağımsız değişken x ile kalıntı \hat{u} arasındaki örneklem kovaryansı ve korelasyon katsayısı sıfırdır.

$$Cov(x, \hat{u}) = 0 \quad \text{ve} \quad Corr(x, \hat{u}) = 0$$

- Bu durum diğer SEKK birinci sıra koşullarının (aynı zamanda diğer örneklem moment koşullarının) bir sonucudur. Bakınız Slayt 31 ve Slayt 33.
- Bağımsız değişken x 'le kalıntı \hat{u} 'nın doğrusal olarak ilişkisizliği çıkarılabilir.

$$Cov(x, u) = 0 \quad \text{ve} \quad Corr(x, u) = 0 \quad \longrightarrow \quad E(xu) = 0 \quad (\text{Anakütle})$$

$$Cov(x, \hat{u}) = 0 \quad \text{ve} \quad Corr(x, \hat{u}) = 0 \quad \longrightarrow \quad E(x\hat{u}) = 0 \quad (\text{Örneklem})$$

$$\underbrace{E(xu) = 0}_{\text{Anakütle}} \quad \longrightarrow \quad \underbrace{E(x\hat{u}) = 0 \quad \text{ve} \quad \sum_{i=1}^n x_i \hat{u}_i = 0}_{\text{Örneklem}}$$

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- 1. ve 2. cebirsel özelliklerin bir sonucu olarak tahmin edilen değer \hat{y} ile kalıntı \hat{u} arasındaki örneklem kovaryansı ve korelasyon katsayısı sıfırdır.

$$Cov(\hat{y}, \hat{u}) = 0 \quad \text{ve} \quad Corr(\hat{y}, \hat{u}) = 0$$

- Bu özellikten tahmin edilen değer \hat{y} ile kalıntı \hat{u} 'nun doğrusal olarak ilişkisizliği çıkarılabilir.

$$\underbrace{Cov(\hat{y}, \hat{u}) = 0 \quad \text{ve} \quad Corr(\hat{y}, \hat{u}) = 0}_{\text{Örneklem}} \quad \longrightarrow \quad \underbrace{E(\hat{y}\hat{u}) = 0 \quad \text{ve} \quad \sum_{i=1}^n \hat{y}_i \hat{u}_i = 0}_{\text{Örneklem}}$$

► Ek Bilgi

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- Tahmin edilen değer \hat{y}_i 'lerin ortalaması gözlenen değer y_i 'lerin ortalamasına eşittir.

$$y_i = \hat{y}_i + \hat{u}_i$$

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i + \underbrace{\sum_{i=1}^n \hat{u}_i}_{=0} \quad (1. \text{ Cebirsel Özellik})$$

$$n\bar{\hat{y}} = n\bar{y}$$

$$\bar{\hat{y}} = \bar{y}$$

- (\bar{x}, \bar{y}) noktası daima ÖRF'den geçer (ÖRF üzerindedir).

$$(\bar{x}, \bar{y}) \longrightarrow \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

Kareler Toplamları

- Her bir i gözlemi için gözlenen değer, tahmin edilen değer ve kalıntı arasındaki ilişki aşağıdaki gibi gösterilebilir.

$$y_i = \hat{y}_i + \hat{u}_i$$

- Her iki tarafın örneklem ortalamalarından sapmalarının karesini alıp toplarsak

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(\hat{y}_i - \bar{\hat{y}}) + (\hat{u}_i - \bar{\hat{u}})]^2$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(\hat{y}_i - \bar{y}) + \hat{u}_i]^2 \quad (1. \text{ ve } 4. \text{ Cebirsel Öz.})$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2 + 2 \underbrace{\sum_{i=1}^n \hat{u}_i \hat{y}_i}_{=0} - 2\bar{y} \underbrace{\sum_{i=1}^n \hat{u}_i}_{=0} \quad (3. \text{ Cebirsel Öz.})$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2$$

Kareler Toplamları

- **Toplam Kareler Toplamı:** SST (Total Sum of Squares) y 'deki toplam değişkenliği verir.

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

$Var(y) = SST/(n - 1)$ olduğuna dikkat edin.

- **Açıklanan Kareler Toplamı:** SSE (Explained Sum of Squares) model tarafından açıklanan kısımdaki, yani tahmin edilen değer \hat{y} 'lardaki, değişkenliği verir.

$$SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- **Kalıntı Kareleri Toplamı:** SSR (Residual Sum of Squares) model tarafından açıklanamayan kısımdaki, yani kalıntı \hat{u} 'lardaki, değişkenliği verir.

$$SSR = \sum_{i=1}^n \hat{u}_i^2$$

Kareler Toplamları

- y 'deki toplam değişkenlik aşağıdaki gibi yazılabilir.

$$SST = SSE + SSR$$

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{SST} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SSE} + \underbrace{\sum_{i=1}^n \hat{u}_i^2}_{SSR}$$

Determinasyon Katsayısı

- y 'deki toplam değişkenlik denkleminin her iki tarafını SST'ye bölersek

$$SST = SSE + SSR$$

$$1 = \frac{SSE}{SST} + \frac{SSR}{SST}$$

- Açıklanan kısmın değişkenliğinin toplam değişkenlik içindeki payı regresyonun **determinasyon katsayısı** ya da **belirlilik katsayısı**dır (coefficient of determination) ve R^2 ile gösterilir.

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

- SSE hiçbir zaman SST'den büyük olamayacağı için $0 \leq R^2 \leq 1$
- R^2 , y 'deki değişkenliğin x tarafından açıklanan kısmının oranını verir. Regresyonun açıklama gücü yükseldikçe R^2 , 1'e yaklaşır.
- R^2 'yi yorumlarken, yüzdeye dönüştürmek için genellikle 100 ile çarparız: $100 \times R^2$, y 'deki değişkenliğin x tarafından açıklanan kısmının yüzdesini verir.
- R^2 modelin açıklama gücünü (ne kadar iyi fit edildiğini) belirttiği için bazen **uyum iyiliği** (goodness-of-fit) olarak da adlandırılır.
- R^2 şu şekilde de hesaplanabilir: $R^2 = \text{Corr}(y, \hat{y})^2$

Determinasyon Katsayısı: Örnek

CEO Maaşı vs. Karlılık Modeli

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{ÖRF})$$

$$\widehat{\text{salary}} = 963.191 + 18.501 \text{ roe} \quad (\text{ÖRF})$$

$$n = 209, \quad R^2 = 0.0132$$

salary: CEO maaşı (bin dolar); *roe*: şirketin karlılık yüzdesi

- Determinasyon katsayısı 0.0132 olarak tahmin edilmiştir.
- CEO maaşı *salary*'deki değişkenliğin yaklaşık %1.32'si *roe* değişkeniyle açıklanabilmektedir. Diğer bir deyişle, *salary*'daki değişkenliğin yaklaşık %98.68'i açıklanamamıştır.
- Dışarıda bırakılan birçok faktör (hata terimi u 'nun içinde) olduğundan CEO maaşı *salary*'nin küçük bir kısmı açıklanabilmiştir.
- CEO maaşı *salary*'yi etkileyen ve bu modelde yer almayan başka birçok değişken olduğu unutulmamalıdır.

SEKK Parametre Tahmincilerinin Varyansı

BDR.7: Sabit Varyans (Homoscedasticity)

u hata teriminin bağımsız değişken x 'e göre koşullu varyansı sabittir.

$$\text{Var}(u|x) = \sigma^2$$

$$\text{Var}(u|\mathbf{x}) = \sigma^2$$

$$\text{Var}(u) = \sigma^2$$


- Bu varsayım SEKK parametre tahmincilerinin varyanslarının ve standart hatalarının türetilmesinde ve etkinlik özelliklerinin belirlenmesinde kullanılır.
 - SEKK parametre tahmincilerinin sapmasızlığı için ÇDR.7 varsayımına ihtiyaç yoktur.
- Örneğin, ücret vs. eğitim modelinde (Slayt 9) bu varsayım, model dışında bırakılan faktörler u 'daki değişkenliğin modele dahil edilen $educ$ 'e bağlı olmadığını söyler.
- BDR.5 ve BDR.7 varsayımları kullanılarak Slayt 20'deki gibi bağımlı değişken y 'nin bağımsız değişken x 'lere göre koşullu varyansının da sabit olduğu gösterilebilir.

$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

Sabit Varyans vs. Değişken Varyans

- **Sabit varyans** (BDR.7) durumunda, $y = \beta_0 + \beta_1 x + u$ modeline ait ARF ve $y|\mathbf{x}$ 'in dağılımı Şekil 7'de gösterilmiştir (BDR.5 varsayımı sağlanıyorken).
- BDR.7'nin sağlanmadığı duruma **değişken varyans** (heteroscedasticity) denir.
- Değişken varyans durumunda, Slayt 9'de verilen ücret vs. eğitim modeline ait ARF ve $y|\mathbf{x}$ 'in dağılımı Şekil 8'deki gibi gösterilebilir (BDR.5 varsayımı sağlanıyorken).


Sabit Varyans



Şekil 7: Sabit Varyans (BDR.7) Durumunda ARF ve $y|\mathbf{x}$ 'in Dağılımı

Kaynak: Wooldridge (2016)

Değişen Varyans




Şekil 8: Değişen Varyans Durumunda ARF ve $y|\mathbf{x}$ 'in Dağılımı

Kaynak: Wooldridge (2016)

Uygulamada Sabit Varyans vs. Değişken Varyans Belirleme


- Uygulamada, hata terimi u gözlenemediği için u 'nun x 'e göre koşullu varyansı $Var(u|\mathbf{x})$ 'in sabit olup olmadığını, yani u 'daki değişkenliğin \mathbf{x} 'e göre nasıl değiştiğini, anlamak mümkün olmaz.
- Bunun yerine iki farklı yöntem kullanılabilir.
 - Kalıntı \hat{u} vs. \mathbf{x} 'in grafiğine bakılır.
 - Kalıntı karesi \hat{u}^2 vs. \mathbf{x} 'in grafiğine bakılır.
- Eğer Şekil 9'deki gibi kalıntı \hat{u} vs. \mathbf{x} 'in grafiğine bakılırsa, kalıntı \hat{u} 'daki değişkenliğin bağımsız değişken \mathbf{x} 'e göre nasıl değiştiği incelenmelidir.
 - Şekil 9'de, sadece Grafik 2'de değişen varyans vardır. Çünkü, \hat{u} 'daki değişkenlik bağımsız değişken \mathbf{x} 'e göre değişir.
 - Şekil 9'deki diğer grafiplerde sabit varyans vardır.
- Eğer Şekil 10'deki gibi kalıntı karesi \hat{u}^2 vs. \mathbf{x} 'in grafiğine bakılır, kalıntı karesi \hat{u}^2 'nın bağımsız değişken \mathbf{x} 'e göre nasıl değiştiği incelenmelidir.
 - Şekil 10'de, sadece Grafik 3'de sabit varyans vardır. Çünkü, \hat{u}^2 bağımsız değişken \mathbf{x} 'e göre değişmez (sabit).
 - Şekil 10'deki diğer grafiplerde değişen varyans vardır.

Uygulamada Sabit Varyans vs. Değişken Varyans Belirleme



Şekil 9: Kalıntı \hat{u} vs. \mathbf{x} 'in Olası Grafikleri

Not: Tüm grafiklerde dikey eksenle kalıntılar \hat{u}_i ve yatay eksenle ise bağımsız değişken \mathbf{x} vardır.



Şekil 10: Kalıntı Karesi \hat{u}^2 vs. \mathbf{x} 'in Olası Grafikleri

Not: Tüm grafiklerde dikey eksenle kalıntılar \hat{u}_i^2 ve yatay eksenle ise bağımsız değişken \mathbf{x} vardır.

SEKK Parametre Tahmincilerinin Varyansı

Teorem: $\hat{\beta}_1$ 'nin Varyansı

Gauss–Markov varsayımları (BDR.1 - BDR.7) altında

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

► Ek Bilgi

- Ekonometrik analizde ana odak $\hat{\beta}_1$ olduğundan, $\hat{\beta}_0$ 'nın varyansı verilmemiştir.
- σ^2 gözlenemeyen hata terimi u 'nun varyansıdır. Bu nedenle σ^2 **hata varyansı**, σ ise **regresyonun standart sapması** olarak adlandırılır.
- SST_x , x 'deki örneklem değişkenliğini ifade eder.
- SEKK parametre tahmincilerine ait varyansın olabildiğinde küçük olması istenir, çünkü küçük varyans tahminin hassaslığını artırır. Bakınız Slayt ??.
- $Var(\hat{\beta}_j)$, σ^2 ile aynı yönde ilişkilidir. σ^2 'yi düşürmenin tek yolu güçlü bağımsız değişkenleri modele eklemektir. Daha büyük bir σ^2 , y 'yi etkileyen gözlenemeyen hata terimi u 'ya ait dağılımın daha fazla yayılmış olduğu anlamına gelir.
- $Var(\hat{\beta}_1)$, SST_x ile ters yönde ilişkilidir. SST_x 'yi arttırmanın tek yolu gözlem sayısını arttırmaktır.

SEKK Parametre Tahmincilerinin Varyansı

Teorem: $\hat{\beta}_1$ 'nin Varyansı

Gauss–Markov varsayımları (BDR.1 - BDR.7) altında

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

- Hata terimi u gözlenemediği için hata varyansı σ^2 bilinmez.
- Bu nedenle, SEKK parametre tahmincilerinin varyansı $Var(\hat{\beta}_1)$ 'nin tahmini için öncelikle hata varyansı σ^2 'nin tahmin edilmesi gerekir.
- Buradaki önemli nokta, $Var(\hat{\beta}_1)$ 'nin sapmasız tahmin edilmesi gerekir. Bu nedenle, σ^2 'nin de aynı şekilde sapmasız tahmin edilmesi gerekir.

SEKK Parametre Tahmincilerinin Varyansı

Hata Varyansı σ^2

BDR.5 varsayımı altında hata varyansı σ^2 aşağıdaki gibi yazılabilir.

$$Var(u) = \sigma^2 = E(u^2) - \underbrace{E(u)^2}_{= 0 \text{ (ÇDR.5)}} \quad (\text{Varyans Formülü})$$

$$\sigma^2 = E(u^2)$$

- σ^2 'nin sapmasız tahmincisi hata terimi u 'nun örneklem ortalaması $n^{-1} \sum_{i=1}^n u_i^2$ 'dir.
- Fakat, hata terimi u gözlenemediği için σ^2 'nin tahmininde hata terimi u 'nun yerine onun örneklem analogu olan kalıntı \hat{u} kullanılır. $n^{-1} \sum_{i=1}^n u_i^2 \longrightarrow n^{-1} \sum_{i=1}^n \hat{u}_i^2$
- Fakat $n^{-1} \sum_{i=1}^n \hat{u}_i^2$ sapmalı bir tahmincidir. Bu nedenle, σ^2 'nin sapmasız tahmincisini hesaplamak bu değerin serbestlik derecesi kullanılarak düzeltilmesi gerekir.

SEKK Parametre Tahmincilerinin Varyansı

Teorem: Hata Varyansı σ^2 'nin Sapmasız Tahmini

Gauss–Markov varsayımları (BDR.1 - BDR.7) altında hata varyansı σ^2 'nin sapmasız bir tahmincisi:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k - 1} = \frac{SSR}{n - k - 1} = \frac{SSR}{n - 2} \quad (\text{BDR'de } k = 2)$$

- **Serbestlik derecesi** (bağımsız bilgi sayısı) $\longrightarrow s.d. = n - (k + 1) = n - k - 1$
 - Serbestlik derecesi, SEKK birinci sıra koşullarından $(k + 1)$ tane gelmektedir. Bu koşullar n tane kalıntı \hat{u} 'nın üzerine $k + 1$ tane kısıt koyar.
 - n tane kalıntıdan $n - (k + 1)$ tanesi biliniyorsa, geriye kalan $k + 1$ kalıntı otomatik olarak bilinecektir. Bu nedenle kalıntıların serbestlik derecesi $n - k - 1$ 'dir.
- $\hat{\sigma}$ **regresyonun standart sapması** σ 'nın bir tahmincisidir ve **regresyonun standart hatası** ya da **ortalama karesel hata** olarak adlandırılır.
- Regresyona yeni bir bağımsız değişken eklendiğinde $\hat{\sigma}$ azalabilir ya da artabilir.
 - Modele yeni bir bağımsız değişken eklendiğinde SSR düşecektir fakat aynı zamanda serbestlik derecesi de 1 düşecektir. SSR payda, serbestlik derecesi ise payda olduğundan hangi değişimin daha fazla etkiye sahip olduğunu kestiremeyiz.

Kaynaklar

Gujarati, D.N. (2009). *Basic Econometrics*. Tata McGraw-Hill Education.

Stock, J.H. ve M.W. Watson (2015). *Introduction to Econometrics*.

Tastan, H. (2020). *Lecture on Econometrics I. Personal Collection of H. Tastan*. Retrieved from Online.

Wooldridge, J.M. (2016). *Introductory Econometrics: A Modern Approach*. Nelson Education.

Ek Bilgiler

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = 0$$

- Daha önce gördüğümüz Yinelenen Beklentiler Kanunu'nu hatırlayalım.

Yinelenen Beklentiler Kanunu

$$E[E(u|\mathbf{x})] = E(u)$$

Ek Bilgiler

- Yinelenen Beklentiler Kanunu kullanılarak BDR.5 varsayımı yeniden tanımlanabilir.

$$\underbrace{E[E(u|\mathbf{x})]}_{=0} = E(u)$$

$$E[0] = E(u)$$

$$0 = E(u)$$

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

Yani, hata terimi u 'nun bağımsız değişken x 'e göre koşullu ve koşulsuz ortalaması sıfırdır.

Ek Bilgiler

- Koşullu beklenen değerin 5. özelliğini kullanarak u ve x arasındaki ilişki hakkında daha fazla yorumda bulunabiliriz.

Koşullu Beklenen Değer: Özellik 5

$$E(u|\mathbf{x}) = E(u) \quad \text{ise} \quad Cov(x, u) = 0 \quad \text{ve} \quad Corr(x, u) = 0$$

Yani, bağımsız değişken x 'in her doğrusal fonksiyonu hata terimi u ile ilişkisizdir.

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

Ek Bilgiler

BDR.5: Sıfır Koşullu Ortalama Varsayımı

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

$$Cov(x, u) = E(xu) - E(x) \underbrace{E(u)}_{=0} = 0$$

$$= E(xu) = 0$$

Ek Bilgiler

BDR.6: Otokorelasyon Olmaması

$$\text{Cov}(u_i, u_s | \mathbf{x}) = 0 \quad \text{ve} \quad \text{Cov}(u_i, u_s) = 0, \quad i \neq s$$

$$E(u_i u_s | \mathbf{x}) = 0 \quad \text{ve} \quad E(u_i u_s) = 0, \quad i \neq s$$

$$\begin{aligned} \text{Cov}(u_i, u_s | \mathbf{x}) &= E(u_i u_s | \mathbf{x}) - \underbrace{E(u_i | \mathbf{x})}_{=0} \underbrace{E(u_s | \mathbf{x})}_{=0} = 0 \\ &= E(u_i u_s | \mathbf{x}) = 0 \end{aligned}$$

Ek Bilgiler

BDR.7: Sabit Varyans (Homoscedasticity)

$$E(u^2|\mathbf{x}) = \sigma^2 \quad \text{ve} \quad E(u^2) = \sigma^2$$

$$\begin{aligned} \text{Var}(u|\mathbf{x}) &= E(u^2|\mathbf{x}) - \underbrace{E(u|\mathbf{x})^2}_{=0} = \sigma^2 \\ &= E(u^2|\mathbf{x}) = \sigma^2 \end{aligned}$$

Ek Bilgiler

Anakütle Regresyon Fonksiyonu (ARF)

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

$$y = \beta_0 + \beta_1 x + u$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x + \underbrace{E(u|\mathbf{x})}_{=0}$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$y = \beta_0 + \beta_1 x + u$$

$$\text{Var}(y|\mathbf{x}) = \text{Var}(u|\mathbf{x})$$

$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

Ek Bilgiler

Parametre Tahmincileri

β_0 kesim parametresinin tahmini $\hat{\beta}_0$:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1$$

- $\hat{\beta}_0$ 'nın formülü

- SEKK birinci sıra koşulları ya da örneklem moment koşullarından ilki (Slayt 33)
- Kalıntı \hat{u} 'nın denklemi
- İndeksli haldeki model denklemi

kullanılarak çıkarılabilir.

$$\begin{aligned}\sum_{i=1}^n \hat{u}_i &= \sum_{i=1}^n (y_i - \hat{y}_i) = 0 \\&= \sum_{i=1}^n y_i - \sum_{i=1}^n \hat{\beta}_0 - \sum_{i=1}^n \hat{\beta}_1 x_i = 0 \\&= n\bar{y} - n\hat{\beta}_0 - \hat{\beta}_1 n\bar{x} = 0 \\&= \bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0\end{aligned}$$

Sonuç: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

Ek Bilgiler

Parametre Tahmincileri

β_1 eğim parametresinin tahmini $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- $\hat{\beta}_1$ 'nin formülü

- SEKK birinci sıra koşulları ya da örneklem moment koşullarından ikincisi (Slayt 33)
- Kalıntı \hat{u} 'nın denklemi
- β_0 kesim parametresinin tahmini $\hat{\beta}_0$
- Ortalamadan sapmaların kareleri toplamı

kullanılarak çıkarılabilir.

$$\begin{aligned}\sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ &= \sum_{i=1}^n x_i (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0\end{aligned}$$

Ek Bilgiler

$$\sum_{i=1}^n x_i (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0$$

$$\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} + \sum_{i=1}^n \hat{\beta}_1 x_i \bar{x} - \sum_{i=1}^n \hat{\beta}_1 x_i x_i = 0$$

$$\sum_{i=1}^n x_i (y_i - \bar{y}) = \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x})$$

$$\text{Sonuç: } \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

◀ Sunuma Geri Dön

burada

$$\sum_{i=1}^n x_i (y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$\sum_{i=1}^n x_i (x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})^2$$

Ek Bilgiler

Parametre Tahmincileri

β_1 eğim parametresinin tahmini $\hat{\beta}_1$ 'in alternatif formülü:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

◀ Sunuma Geri Dön

burada

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i$$

Ek Bilgiler

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri - 2

$$Cov(x, \hat{u}) = E(x\hat{u}) - E(x) \underbrace{E(\hat{u})}_{=0} = 0 \quad (1. \text{ Cebirsel Özellik})$$

$$= E(x_j \hat{u}) = 0$$

ya da

$$Cov(x, \hat{u}) = \frac{\sum_{i=1}^n (x_i - \bar{x})(\hat{u}_i - \bar{\hat{u}})}{n - 1} = 0$$

$$Cov(x, \hat{u}) = \sum_{i=1}^n x_i (\hat{u}_i - \underbrace{\bar{\hat{u}}}_{=0}) = 0 \quad (1. \text{ Cebirsel Özellik})$$

$$= \sum_{i=1}^n x_i \hat{u}_i = 0$$

Ek Bilgiler

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri - 3

$$\begin{aligned} Cov(\hat{y}, \hat{u}) &= Cov(\hat{\beta}_0 + \hat{\beta}_1 x, \hat{u}) \\ &= \hat{\beta}_1 \underbrace{Cov(x, \hat{u})}_{=0} = 0 \end{aligned} \quad (2. \text{ Cebirsel Özellik})$$

$$= E(\hat{y}\hat{u}) = 0 \quad (\text{Kovaryans formülü ve 1. Cebirsel Özellik})$$

ve

$$Cov(\hat{y}, \hat{u}) = \sum_{i=1}^n (\hat{y}_i - \bar{y}) (\hat{u}_i - \underbrace{\bar{\hat{u}}}_{=0}) = \sum_{i=1}^n (\hat{y}_i - \bar{y}) \hat{u}_i = 0 \quad (1. \text{ Cebirsel Özellik})$$

$$= \sum_{i=1}^n \hat{y}_i \hat{u}_i - \bar{y} \underbrace{\sum_{i=1}^n \hat{u}_i}_{=0} = 0 \quad (1. \text{ Cebirsel Özellik})$$

$$= \sum_{i=1}^n \hat{y}_i \hat{u}_i = 0$$