

Basit Doğrusal Regresyon Modeli

Ekonometri I

Dr. Ömer Kara¹

¹İktisat Bölümü
Eskişehir Osmangazi Üniversitesi

19 Kasım 2021



Taslak

1 Motivasyon

2 Basit Doğrusal Regresyon Modeli

- Basit Doğrusal Regresyon Modelinin Mantığı
- Basit Doğrusal Regresyon Modeli
- Gauss–Markov Varsayımları
- Anakütle Regresyon Fonksiyonu

3 Basit Doğrusal Regresyon Modeli Tahmini

- Örneklem Regresyon Fonksiyonu
- Tahmin Yöntemleri
- SEKK Parametre Tahmincileri
- Yorumlama ve Örnekler
- Tahmin Edilen Değer ve Kalıntı
- Kareler Toplamları ve Determinasyon Katsayısı
- SEKK Parametre Tahmincilerinin Beklenen Değeri
- SEKK Parametre Tahmincilerinin Varyansı

4 SEKK Parametre Tahmincilerinin Özellikleri

- SEKK Parametre Tahmincilerinin Sapmasızlığı
- SEKK Parametre Tahmincilerinin Etkinliği
- Gauss–Markov Teoremi

5 Modelleme Sorunları

- Orijinden Geçen Regresyon
- Fonksiyonel Form



Motivasyon

Bu bölümde, sırasıyla aşağıdaki konular incelenecaktır.

- Basit Doğrusal Regresyon modeli
- Basit Doğrusal Regresyon modelinde Gauss–Markov varsayımları
- Basit Doğrusal Regresyon modelinin tahminine ait yöntemler
- Sıradan En Küçük Kareler parametre tahmincileri
- Determinasyon Katsayısı
- Sıradan En Küçük Kareler parametre tahmincilerinin özellikleri
- Basit Doğrusal Regresyon modelinde Gauss–Markov teoremi

Motivasyon

- Basit Doğrusal Regresyon (BDR) iki farklı değişken arasındaki ilişkiyi incelemek için kullanılır.
- Daha sonra göreceğimiz nedenlerden dolayı, ugulamalı analizde genel bir araç olarak kullanıldığında BDR modelinin kısıtları vardır.
- Buna rağmen, BDR modelinin nasıl yorumlanacağını öğrenmek, sonraki bölümlerde yapacağımız Çoklu Doğrusal Regresyon (ÇDR) modelini temelden anlamak üzerinde durulması gereken bir konudur.
- BDR modelinin kısıtları ve ÇDR modeli hakkındaki detaylı bilgi “Ekonometri I - Çoklu Doğrusal Regresyon Modeli: Tahmin” konusunda bulunabilir.

Basit Doğrusal Regresyon Modelinin Mantığı

- Uygulamalı ekonometrik analizlerin çoğu şu önermeye baþlar:

Temel Ekonometrik Önerme

y ve x , bir anakütleyi temsil eden iki rassal deðiþkendir ve biz, " y 'yi x cinsinden açıklamak" veya " y 'nin x 'teki deðiþikliklerle nasýl deðistiðini incelemekle" ilgileniyoruz.

- "Ekonometri I - Matematik ve İstatistik Gözden Geçirme" konusunda y ve x arasındaki **kesin iliþkiyi** gösteren fonksiyonları incelemiþtik.
- Fakat sosyal bilimlerde iki deðiþken arasındaki iliþki hiçbir zaman kesin deðildir.
- Bu nedenle, " y 'yi x cinsinden açıklayacak" bir model yazarken üç sorun vardır.
 - ➊ İki deðiþken arasında hiçbir zaman kesin bir iliþki olmadığına göre, **diger faktörlerin** y 'yi etkilemesine nasýl izin verebiliriz?
 - ➋ y ve x arasındaki iliþkiyi belirten **fonksiyonel form** nedir?
 - ➌ y ve x arasında bir **ceteris paribus** iliþkisi yakaladığımızdan nasýl emin olabiliriz?
- Bu sorunları, y 'den x 'e iliþkin bir denklem yazarak Slayt 6'deki gibi çözebiliriz.

Basit Doğrusal Regresyon Modeli

Model

$$y = \beta_0 + \beta_1 x + u \quad (\text{İndekssiz})$$

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, 2, \dots, n \quad (\text{İndeksli})$$

- k : bağımsız değişken sayısı $\rightarrow k = 1$
- $k + 1$: bilinmeyen sabit β parametre sayısı $\rightarrow \beta_0, \beta_1$
- n : gözlem (veri) sayısı $\rightarrow i = 1, 2, \dots, n$ ve $s = 1, 2, \dots, n$, $i \neq s$
- y : bağımlı değişken
- x : bağımsız değişken
- u : Hata terimi, x dışında modele dahil edilmemiş tüm faktörlerin ortak etkisi
- β_0 : Kesim parametresi (1 tane var), sabit terim olarak da adlandırılır
- β_1 : x bağımsız değişkeni için eğim parametresi (1 tane var)
- \mathbf{x} : Tüm bağımsız değişkenlerin temsili $\rightarrow \mathbf{x} = \{x\}$
- Yukarıdaki model bazen **anakütle modeli** olarak da bilinir.

Basit Doğrusal Regresyon Modeli

Model

$$y = \beta_0 + \beta_1 x + u \quad (\text{İndekssiz})$$

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, 2, \dots, n \quad (\text{İndeksli})$$

- u : Bağımlı değişken y üzerinde etkili olan bağımsız değişken x dışındaki diğer gözlenemeyen faktörleri temsil eder.
- β_0 : $x = 0$ iken y 'nin alacağı değeri gösterir.
- β_1 : y 'yi etkileyen diğer tüm faktörler, yani u 'da içeren faktörler, sabitken ($\Delta u = 0$), x 'deki değişimden y 'de yaratacağı yalnız etkiyi/değişmeyi gösterir.

$$\Delta y = \beta_1 \Delta x + \Delta u$$

$$\Delta y = \beta_1 \Delta x \quad \text{eğer} \quad \Delta u = 0$$

- Parametreleri yorumlarken fonksiyonel forma dikkat edilmelidir.
- Farklı fonksiyonel formların yorumlamalarılarındaki detaylı bilgi Slayt 93'de bulunabilir.
- $\Delta u = 0$ olduğunda, u 'nun içinde bulunan tüm gözlenemeyen faktörlerin ayrı ayrı sabit olduğu değil, ortalama olarak değişimin olmadığı kastedilir. Yani, negatif ve pozitif işaretli u 'lar birbirini götürdüğünde ortalama olarak değişim olmayacağı.

Basit Doğrusal Regresyon Modeli

- Regresyon modellerinde değişkenler için kullanılan terminoloji aşağıda verilmiştir.

Tablo 1: Değişkenler Terminolojisi

y	x
Bağımlı Değişken	Bağımsız Değişken
Açıklanan Değişken	Açıklayıcı Değişken
Tepki Değişkeni	Kontrol Değişkeni
Tahmin Edilen Değişken	Tahmin Eden Değişken
Regresand	Regressor

Basit Doğrusal Regresyon Modeli - Örnek 1

Ücret vs. Eğitim Modeli

Bir çalışanın fazladan 1 yıl eğitim aldığında ücretinin ne kadar arendiğini araştırmak istedigimizi düşünelim. Yani, eğitimin ücret üzerindeki etkisini ayırtmak istiyoruz.

$$wage = \beta_0 + \beta_1 educ + u$$

wage: saat başına ücret (dolar); *educ*: eğitim düzeyi (yıl)

- **Eğim Parametresi** β_1 : Ceteris paribus eğitim düzeyindeki 1 birimlik değişimin, saat başına ücretinde meydana getireceği değişimi belirtir.

$$\Delta wage = \beta_1 \Delta educ + \Delta u$$

$$\Delta wage = \beta_1 \Delta educ \quad \text{eğer} \quad \Delta u = 0$$

- **Rassal Hata Terimi** u : Saat başına ücreti etkileyen, eğitim düzeyi dışındaki tecrübe, kıdem, doğuştan gelen yetenek, cinsiyet ve yaş gibi tüm faktörlerin ortak etkisini gösterir.

Ceteris Paribus \Leftrightarrow Diğer tüm faktörlerin sabit tutulması $\Leftrightarrow \Delta u = 0$



Basit Doğrusal Regresyon Modeli - Örnek 2

Tarımsal Çıktı vs. Gübre Miktarı Modeli

Gübre miktarının üretilen tarımsal çıktı miktarı üzerindeki yalın etkisini araştırmak istedigimizi düşünelim. Yani, kullanılan gübre miktarının üretilen tarımsal çıktı miktarı üzerindeki etkisini ayırtmak istiyoruz.

$$output = \beta_0 + \beta_1 fert + u$$

output: tarımsal çıktı miktarı; *fert*: gübre miktarı

- **Eğim Parametresi** β_1 : Ceteris paribus gübre miktarındaki 1 birimlik değişimin, çıktı miktarında meydana getireceği değişimi belirtir.

$$\Delta output = \beta_1 \Delta fert + \Delta u$$

$$\Delta output = \beta_1 \Delta fert \quad \text{eğer} \quad \Delta u = 0$$

- **Rassal Hata Terimi** u : Çıktı miktarını etkileyen, gübre miktarı dışındaki yağmur miktarı ve toprağın kalitesi gibi tüm faktörlerin ortak etkisini gösterir.
Ceteris Paribus \Leftrightarrow Diğer tüm faktörlerin sabit tutulması $\Leftrightarrow \Delta u = 0$

Doğrusal Model

- Regresyon modelinin doğrusal olması şu anlamına gelir: x 'deki değişmenin y 'de meydana getireceği etki, x 'in başlangıç değeri ne olursa olsun aynıdır, yani sabittir.
- Uygulamadaki bu sabit etki varsayıımı çoğu zaman gerçeklere uymaz. Örneğin:
 - Ölçeğe göre artan ya da azalan getiri doğrusal regresyon modelleriyle açıklanamaz.
 - Slayt 9'de verilen ücret vs. eğitim modelinde, ilave bir yıl eğitimimin etkisi önceki eğitim düzey(ler)ine göre aynıdır, fakat其实 daha fazla olması beklenir.
 - Tecrübenin ücret üzerindeki etkisini araştıran bir modelde ise gersekte tecrübe düzeyinin ücretler üzerinde önce artan sonra azalan bir etkiye sahip olması beklenir.
- Doğrusal modellerin bu kısıtına rağmen Ekonometri Teorisi'nde basitliği ve kolay anlaşılmasının nedeniyle sıkılıkla kullanılır.
- Sabit olmayan etkilerin nasıl modelleneceğini daha sonra göreceğiz.

Gauss-Markov Varsayımları

BDR.1: Gözlem Sayısı

Gözlem sayısı n tahmin edilecek anakütle parametre sayısından büyük ya da en azından eşit olmalıdır.

$$n \geq k + 1$$

BDR.2: Parametrelerde Doğrusallık

Model parametrelerde doğrusaldır.

$$y = \beta_0 + \beta_1 x + u \checkmark$$

$$y = \beta_0 + \beta_1 x^2 + u \checkmark$$

$$y = \beta_0 + \beta_1^2 x + u \times$$

$$y = \beta_0 + \sqrt{\beta_1} x + u \times$$

► Detay



Gauss-Markov Varsayımları

BDR.3: Rassallık

Tahminde kullanılan n tane gözlem ilgili anakütleden rassal örneklemeye yoluyla seçilmiştir. Yani gözlemler stokhastiktir (rassal), yani deterministik (kesin) değildir.

$$\{(x_i, y_i) : i = 1, 2, \dots, n\}$$

BDR.4: Bağımsız Değişkenin Sabit Olmaması

Örneklemde (ve bu nedenle anakütlede) bağımsız değişken kendi içinde sabit değildir (yeterli değişimlik vardır).

$$\sum_{i=1}^n (x_i - \bar{x})^2 > 0$$

► Detay



Gauss-Markov Varsayımları

BDR.5: Sıfır Koşullu Ortalama

Bağımsız değişkenin herhangi bir değeri verildiğinde, u hata teriminin beklenen değeri sıfıra eşittir.

$$E(u|x) = E(u|\mathbf{x}) = 0$$

► Detay

- Yinelenen Beklentiler Kanunu ve koşullu beklenen değerin 5. özelliği kullanılarak Sıfır Koşullu Ortalama varsayıımı yeniden tanımlanabilir.

► Ek Bilgi

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$\text{Cov}(x, u) = 0, \quad \text{Corr}(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

► Ek Bilgi



Gauss-Markov Varsayımları

BDR.6: Otokorelasyon Olmaması

Hata terimleri arasında otokorelasyon yoktur.

$$\text{Corr}(u_i, u_s | x) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s | \mathbf{x}) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s) = 0, \quad i \neq s$$

► Detay

- BDR.6 varsayıımı, yatay-kesit analizindeki rassallık varsayıımı (BDR.3) nedeniyle genellikle otomatik olarak sağlanır. Fakat çok ekstrem durumlarda gereklidir ve bu nedenle diğer birçok kaynaktan farklı olarak eklenmiştir.
- BDR.6 varsayıımı aşağıdaki eşitlikleri de sağlar.

BDR.6: Otokorelasyon Olmaması

$$\text{Cov}(u_i, u_s | \mathbf{x}) = 0 \quad \text{ve} \quad \text{Cov}(u_i, u_s) = 0, \quad i \neq s$$

$$E(u_i u_s | \mathbf{x}) = 0 \quad \text{ve} \quad E(u_i u_s) = 0, \quad i \neq s$$

► Ek Bilgi



Gauss-Markov Varsayımları

BDR.7: Sabit Varyans (Homoscedasticity)

u hata teriminin bağımsız değişken x 'e göre koşullu varyansı sabittir.

$$\text{Var}(u|x) = \sigma^2$$

$$\text{Var}(u|\mathbf{x}) = \sigma^2$$

$$\text{Var}(u) = \sigma^2$$

► Detay

- BDR.7 varsayıımı aşağıdaki eşitlikleri de sağlar.

BDR.7: Sabit Varyans (Homoscedasticity)

$$E(u^2|\mathbf{x}) = \sigma^2 \quad \text{ve} \quad E(u^2) = \sigma^2$$

► Ek Bilgi

- σ regresyonun standart sapmasıdır (bilinmiyor, bu nedenle tahmin edilecek).



Gauss-Markov Varsayımları

- Yukarıda verilen **Gauss-Markov Varsayımları** yatay-kesit verisi ile yapılan regresyon için geçerli varsayımlardır.
- Zaman serileri ile yapılan regresyonlarda bu varsayımların değiştirilmesi gerekir.
- Gauss-Markov Varsayımları, **BDR Varsayımları** olarak da anılır.
- Bazı BDR Varsayımlarının detayı ilerleyen slaytlarda konu akışı içinde verilmiştir.
- Gauss-Markov Varsayımları daha sonra **Gauss-Markov Teoremi**'ni oluşturmada kullanılacaktır.
- Gauss-Markov Teoremi ise BDR modelinin **Sıradan En Küçük Kareler Yöntemi** ya da **Momentler Yöntemi** ile tahmini için teorik dayanak sağlamada kullanılacaktır. Bakınız Slayt 89.

Anakütle Regresyon Fonksiyonu

- **Anakütle Regresyon Fonksiyonu (ARF)**, BDR.5 varsayıımı altında, bağımlı değişken y 'nin bağımsız değişken x 'e göre koşullu ortalamasıdır.

Anakütle Regresyon Fonksiyonu (ARF)

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

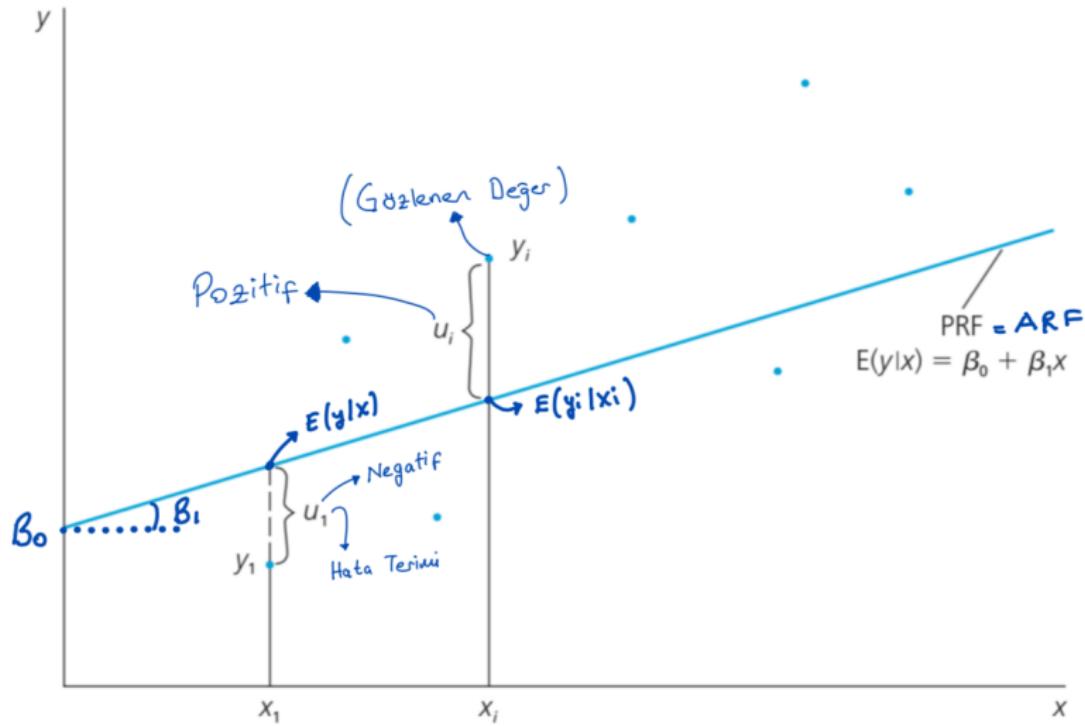
$$E(y|x) = \beta_0 + \beta_1 x \quad (\text{ARF - İndekssiz})$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF - İndekssiz})$$

$$E(y_i|\mathbf{x}_i) = \beta_0 + \beta_1 x_i \quad (\text{ARF - İndeksli})$$

- ARF tektir ve bilinmez.
- ARF, bağımsız değişken x 'in doğrusal bir fonksiyonudur.
- $y = \beta_0 + \beta_1 x + u$ modeline ait ARF Şekil 1'de gösterilmiştir.

Anakütle Regresyon Fonksiyonu

Şekil 1: $y = \beta_0 + \beta_1 x + u$ Modeline ARF

Kaynak: Wooldridge (2016)

Anakütle Regresyon Fonksiyonu

- BDR.5 ve BDR.7 varsayımları altında bağımlı değişken y 'nin bağımsız değişken x 'e göre koşullu dağılımı aşağıdaki gibi ifade edilebilir.

y 'nin x 'e Göre Koşullu Dağılımı

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

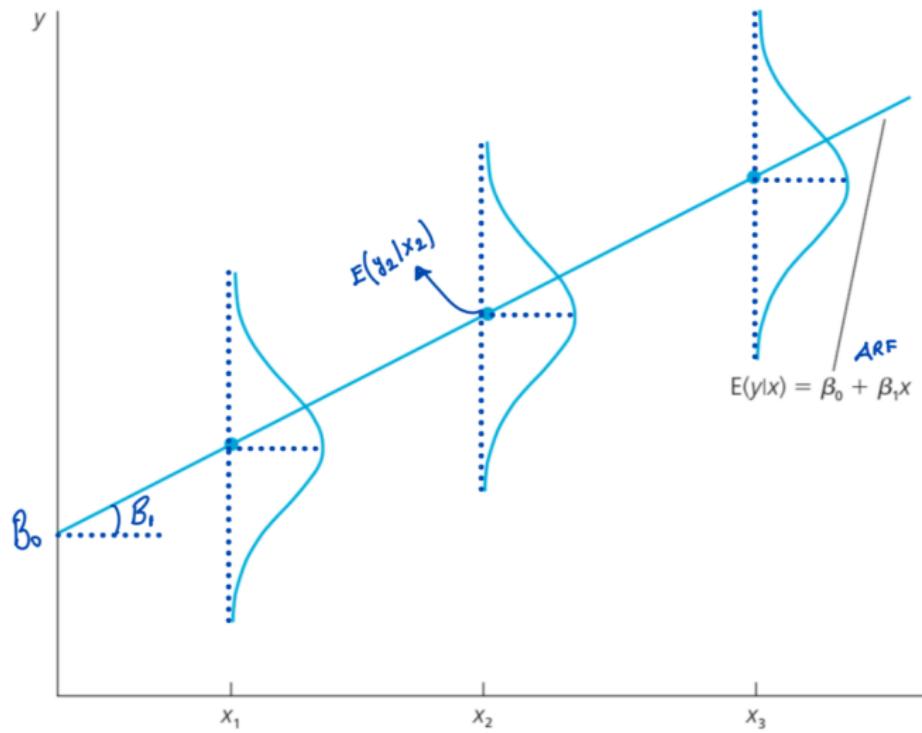
$$y|\mathbf{x} \sim (\underbrace{\beta_0 + \beta_1 x}_{\text{Ortalama}}, \underbrace{\sigma^2}_{\text{Varyans}}) \quad (y|\mathbf{x}'\text{in dağılımı})$$

► Ek Bilgi

- Verilmiş bağımsız değişken x düzeyinde bağımlı değişken y 'nin dağılımının ortalaması $E(y|\mathbf{x})$ ve varyansı σ^2 'dir.
- BDR.5 (sıfır koşullu ortalama) ve BDR.7 (sabit varyans) varsayımları altında, $y = \beta_0 + \beta_1 x + u$ modeline ait ARF ve $y|\mathbf{x}$ 'in dağılımı Şekil 2'de gösterilmiştir.



Anakütle Regresyon Fonksiyonu ve $y|\mathbf{x}$ 'in Dağılımı



Şekil 2: $y = \beta_0 + \beta_1 x + u$ Modeline Ait ARF ve $y|\mathbf{x}$ 'in Dağılımı

Kaynak: Wooldridge (2016)

Örneklem Regresyon Fonksiyonu: Amaç

- BDR tahminindeki asıl amacımız sırasıyla:
 - Öncelikle, iktisat teorisine göre model oluşturmak.
 - Gauss–Markov varsayımları kullanarak ARF'yi oluşturmak.
 - ARF'yi rassal örneklemeye seçtiğimiz belli sayıdaki veriyi kullanarak tahmin etmektir.
- ARF'nin tahmini ise **Örneklem Regresyon Fonksiyonu**'dur ve bu tahmin örneklemden örnekleme değişir.

Model

$$y = \beta_0 + \beta_1 x + u$$

Anakütle Regresyon Fonksiyonu (ARF)

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x$$

Örneklem Regresyon Fonksiyonu (ÖRF)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- ARF'deki parametreler (β_0, β_1) bilinmeyen sabit sayılarken, ÖRF'deki parametreler $(\hat{\beta}_0, \hat{\beta}_1)$ örneklemden örnekleme değişen rassal değişkenlerdir.



Örneklem Regresyon Fonksiyonu: Amaç

Model

$$y = \beta_0 + \beta_1 x + u \quad (\text{İndekssiz})$$

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\text{İndeksli})$$

Anakütle Regresyon Fonksiyonu (ARF)

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{İndekssiz})$$

$$E(y_i|\mathbf{x}_i) = \beta_0 + \beta_1 x_i \quad (\text{İndeksli})$$

Örneklem Regresyon Fonksiyonu (ÖRF)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{İndekssiz})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{İndeksli})$$

Örneklem Regresyon Fonksiyonu

Örneklem Regresyon Fonksiyonu (ÖRF)

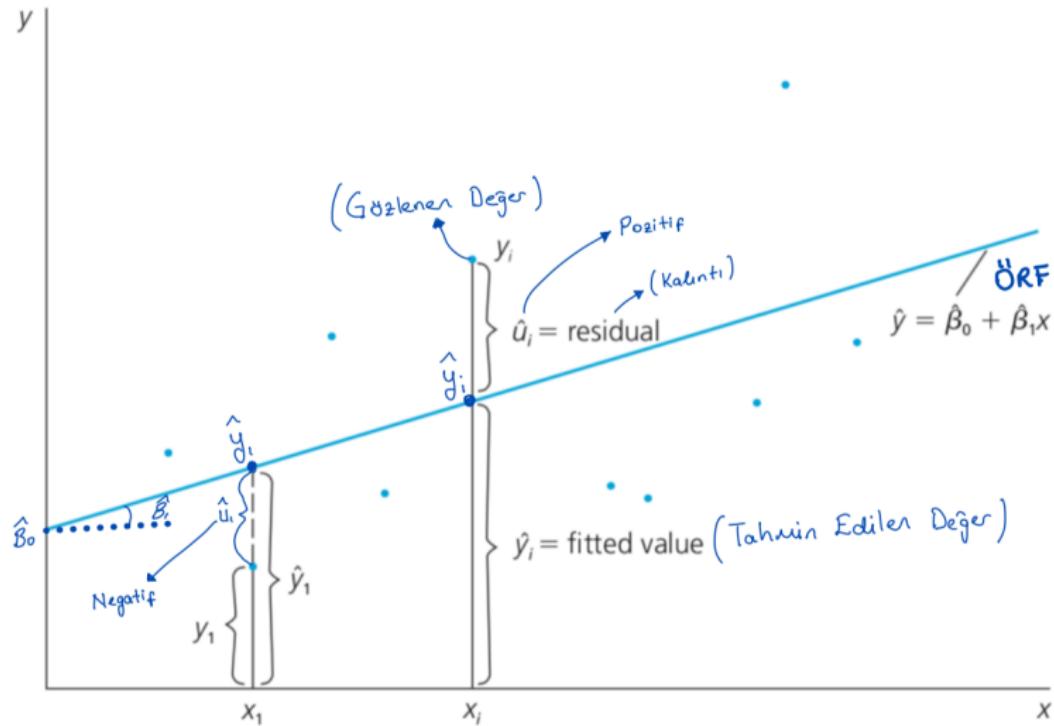
$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{İndekssiz})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{İndeksli})$$

$$\underbrace{y_i}_{\substack{\text{Gözlenen Değer}}} = \underbrace{\hat{y}_i}_{\substack{\text{Tahmin Edilen Değer}}} + \underbrace{\hat{u}_i}_{\substack{\text{Kalıntı (Artık)} \\ \text{Rassal Değil (Deterministik)}}}$$

- \hat{y}_i : y_i bağımlı değişkeninin tahmini
- Parametre tahmincileri örneklemden örnekleme değişir, yani rassaldır.
 - $\hat{\beta}_0$: β_0 kesim parametresinin tahmini (1 tane var)
 - $\hat{\beta}_1$: β_1 eğim parametresinin tahmini (1 tane var)
- \hat{u}_i : Kalıntı (artık) olarak adlandırılır. Gözlenen değer y_i ile tahmin edilen değer \hat{y}_i 'nın farktır. Rassal değildir, tahmin sırasında hesaplanır. Hata terimi u_i 'nun örneklem analogu olarak yorumlanabilir fakat kesinlikle aynı şeyler değildir.
- Hata terimi u ve kalıntı \hat{u} arasındaki farklar için Slayt 28'i inceleyin.
- $y = \beta_0 + \beta_1 x + u$ modeline ait ÖRF Şekil 3'de gösterilmiştir.

Örneklem Regresyon Fonksiyonu



Şekil 3: $y = \beta_0 + \beta_1 x + u$ Modeline Ait ÖRF

Kaynak: Wooldridge (2016)

Örneklem Regresyon Fonksiyonu

- Model, ARF ve ÖRF denklemleri arasında dikkat edilmesi gereken farklar vardır.

Model, ARF ve ÖRF

$$\underbrace{y_i}_{\text{Gözlenen Değer}} = \underbrace{\beta_0 + \beta_1 x_i}_{E(y_i | \mathbf{x}_i)} + \underbrace{u_i}_{\substack{\text{Rassal Hata Terimi} \\ (\text{Sistemetik Olmayan Kısım})}} \quad (\text{Model})$$

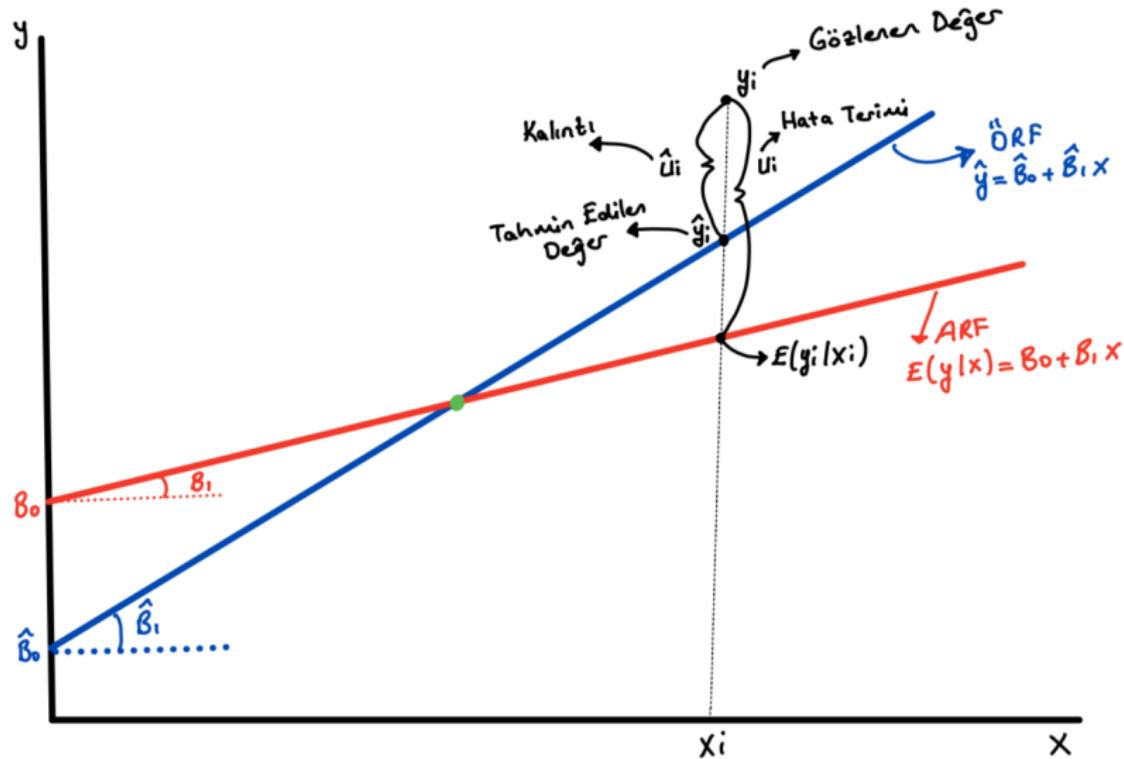
$$E(y_i | \mathbf{x}_i) = \underbrace{\beta_0 + \beta_1 x_i}_{\text{Sistemetik Kısım}} \quad (\text{ARF})$$

$$\underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} = \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\text{Sistemetik Kısımın Tahmini}} \quad (\text{ÖRF})$$

$$\underbrace{y_i}_{\text{Gözlenen Değer}} = \underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} + \underbrace{\hat{u}_i}_{\substack{\text{Kalıntı (Artık)} \\ \text{Rassal Değil (Deterministik)}}}$$

- $y = \beta_0 + \beta_1 x + u$ modeline ait ARF ve ÖRF Şekil 4'de beraberce gösterilmiştir.

ARF ve ÖRF



Şekil 4: $y = \beta_0 + \beta_1 x + u$ Modeline Ait ARF ve ÖRF

Hata Terimi u ve Kalıntı \hat{u} Arasındaki Farklar

- Kalıntı \hat{u} , hata terimi u 'nun örneklem analogu olarak yorumlanabilir fakat kesinlikle aynı şeyler değildir. Bu nedenle kesinlikle birbirine karıştırılmamalıdır.
- Hata terimi u :

$$y_i = \beta_0 + \beta_1 x_i + \underbrace{u_i}_{\text{Hata Terimi}}$$

- Tıpkı anakütle parametreleri β_0 ve β_1 gibi gözlenemez ve bu nedenle bilinemez.
- Rassaldır.

- Kalıntı \hat{u} :

$$y_i = \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\text{Tahmin Edilen Değer } \hat{y}_i} + \underbrace{\hat{u}_i}_{\text{Kalıntı}}$$

- Tahmin sırasında veriler kullanılarak hesaplanır ve bu nedenle bilinir.
- Rassal değildir.

Örneklem Regresyon Fonksiyonu: Tahmin Yöntemleri

Model, ARF ve ÖRF

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{ÖRF})$$

- Örneklem Regresyon Fonksiyonu (ÖRF), iki yöntemle tahmin edilebilir.
 - Sıradan En Küçük Kareler (SEKK) Yöntemi
 - Momentler Yöntemi
- İki yöntem de aynı tahmin sonuçlarını verir.



Sıradan En Küçük Kareler Yöntemi

- **Sıradan En Küçük Kareler Yöntemi**, kalıntı kareleri toplamını (SSR) en küçük yapan parametre tahmincilerini hesaplamaya çalışır.

Örneklem Regresyon Fonksiyonu (ÖRF)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Gözlenen Değer, Tahmin Edilen Değer ve Kalıntı

$$y_i = \hat{y}_i + \hat{u}_i \quad \longrightarrow \quad \hat{u}_i = y_i - \hat{y}_i$$

SEKK Amaç Fonksiyonu

$$\min_{\hat{\beta}_0, \hat{\beta}_1} SSR = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Sıradan En Küçük Kareler Yöntemi

SEKK Birinci Sıra Koşulları

$$\frac{\partial SSR}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\frac{\partial SSR}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

Sıradan En Küçük Kareler Yöntemi

SEKK Birinci Sıra Koşulları

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad \longrightarrow \quad \sum_{i=1}^n \hat{u}_i = 0$$

$$\sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad \longrightarrow \quad \sum_{i=1}^n x_i \hat{u}_i = 0$$

- Birinci sıra koşullarından elde edilen $k + 1$ tane denklemin çözümünden parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ (toplamda $k + 1 = 2$ tane) bulunur.

Momentler Yöntemi

- Anakütle moment koşulları BDR.5 varsayıımı kullanılarak yazılabilir.
- Daha sonra anakütle moment koşullarını kullanarak örneklem moment koşulları elde edilebilir.

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.



Momentler Yöntemi

Anakütle Moment Koşulları ve Örneklem Moment Koşulları

Anakütle

$$\overbrace{E(u) = 0}^{\text{Anakütle}}$$

Örneklem

$$\overbrace{\sum_{i=1}^n \hat{u}_i = 0}^{\text{Örneklem}}$$

$$E(xu) = 0 \quad \longrightarrow \quad \sum_{i=1}^n x_i \hat{u}_i = 0$$



Momentler Yöntemi

- Örneklem moment koşullarından elde edilen $k + 1$ tane denklemin çözümünden parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ (toplamda $k + 1 = 2$ tane) bulunur.
- SEKK birinci sıra koşulları ve örneklem moment koşulları aslında aynı denklemler kümesini verir.
- Bu nedenle, SEKK Yöntemi ve **Momentler Yöntemi** ile BDR modeli tahmin edildiğinde aynı sonuçlara ulaşılır.
- Genellikle kullanılan yöntem SEKK'dır. Bu nedenle parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ genellikle **SEKK parametre tahmincileri** ya da **SEKK tahmincileri** olarak adlandırılır.
- Bu yöntemlerin tek çözüm vermesi için BDR.4 (Bağımsız Değişkenin Sabit Olmaması) varsayıminının sağlanması gereklidir. Bakınız Slayt 13 ve Slayt 37.

SEKK Parametre Tahmincileri

Ana Model

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

(Model - İndeksli)

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

(ÖRF - İndeksli)

- β_0 kesim parametresinin tahmini $\hat{\beta}_0$:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

► Ek Bilgi

- β_1 eğim parametresinin tahmini, ya da x 'in eğim parametresinin tahminci, $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

► Ek Bilgi 1

► Ek Bilgi 2



SEKK Parametre Tahmincileri

- β_1 eğim parametresinin tahmini, ya da x 'in eğim parametresinin tahmincisi, $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \rightarrow \quad \hat{\beta}_1 = \underbrace{\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1}}_{\substack{y \text{ ile } x \text{'in Örneklem Kovaryansı} \\ \underbrace{\sum_{i=1}^n (x_i - \bar{x})^2}_{n-1}}} \\ \underbrace{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}_{x \text{'in Örneklem Varyansı}}$$

- ① $\hat{\beta}_1$, y ile x 'in örneklem kovaryansının, x 'in örneklem varyansına oranına eşittir.
- ② $\hat{\beta}_1$ 'nın işaretti y ile x 'in örneklem kovaryansının işaretine bağlıdır. Örneklemde y ve x aynı yönde ilişkiliyse $\hat{\beta}_1$ pozitif işaretli, ters yönde ilişkiliyse negatif işaretli olacaktır.
- ③ $\hat{\beta}_1$ 'nın hesaplanabilmesi için x 'de yeterli değişiklik olmalıdır. Eğer örneklemde tüm x 'ler aynı değerleri alıysa x 'in örneklem varyansı sıfır olur ve $\hat{\beta}_1$ tanımsız olur.

$$\sum_{i=1}^n (x_i - \bar{x})^2 > 0$$

Sıfır Koşullu Ortalama Varsayımları (BDR.5) Yorumu

Basit Doğrusal Regresyon Modeli

$$y = \beta_0 + \beta_1 x + u$$

- BDR modelinde, u 'nun x 'lerle ilişkisiz olması varsayımlı, yani BDR.5:

$$E(u|x) = E(u|\mathbf{x}) = 0$$

- Yani x 'in anakütüledeki tüm değerleri için u 'nun beklenen değeri sıfırdır.
- Ücret vs. eğitim modelinde (Slayt 9) BDR.5 varsayımlı aşağıdaki gibi yazılabilir.

$$wage = \beta_0 + \beta_1 educ + u \quad (\text{Model})$$

$$E(u|educ) = 0 \quad (\text{BDR.5})$$

- Bu ücretleri etkileyen diğer faktörlerin (u) ortalama olarak $educ$ ile ilişkisiz olduğu anlamına gelir.
- Örneğin, doğuştan gelen yetenek (ability) u 'nun bir parçası ise, ortalama yetenek düzeyi, eğitimin tüm düzeylerinde aynıdır (sabittir).

$$E(ability|educ = 4) = E(ability|educ = 8) = \dots = 0$$

- Eğer eğitim düzeyi ile doğuştan gelen yeteneğin ilişkili olduğunu düşünüyorsak (örneğin: daha yetenekliler okulda da daha iyiler ve bu nedenle eğitim düzeyleri fazla), bu durumda BDR.5 varsayımlı sağlanmaz.



Sıfır Koşullu Ortalama Varsayıımı (BDR.5) Yorumu

- Tarımsal çıktı vs. gübre miktarı modelinde (Slayt 10), BDR.5 varsayıımı aşağıdaki gibi yazılabilir.

$$output = \beta_0 + \beta_1 fert + u \quad (\text{Model})$$

$$E(u|fert) = 0 \quad (\text{BDR.5})$$

- Yani, tarımsal çıktı miktarını etkileyen diğer faktörler (yağmur miktarı, toprağın kalitesi vs.), ortalama olarak, *fert* değişkeniyle ilişkisizdir.
- Eğer yüksek kaliteli toprak parçalarına yüksek miktarda gübre uygulanırsa (yani toprak kalitesi ve gübre miktarı ilişkili), hata terimi *u*'nun beklenen değeri gübre miktarı ile değişir. Bu durumda BDR.5 varsayıımı sağlanmaz.



Regresyonun Yorumu

Model ve ÖRF

$$y = \beta_0 + \beta_1 x + u \quad (\text{Model})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{ÖRF})$$

$$\Delta\hat{y} = \hat{\beta}_1 \Delta x \quad (\text{Değişim Cinsinden})$$

- Eğim paramtresi tahmincisi $\hat{\beta}_1$, bağımsız değişken x 'in y üzerindeki yalnız/kısmı yani ceteris paribus etkisini verir.

- $\hat{\beta}_1$ 'nın yorumu:

$$\Delta\hat{y} = \hat{\beta}_1 \Delta x$$

- x 'de meydana gelen 1 birimlik değişmenin y 'de meydana getireceği ortalama değişim $\hat{\beta}_1$ kadardır.
 - Parametreleri yorumlarken fonksiyonel forma dikkat edilmelidir.
 - Farklı fonksiyonel formların yorumlamalarılarındaki detaylı bilgi Slayt 93'de bulunabilir.

Örnek: CEO Maaşı vs. Karlılık Modeli

CEO Maaşı vs. Karlılık Modeli

$$y = \beta_0 + \beta_1 x + u \quad \rightarrow \quad \text{salary} = \beta_0 + \beta_1 \text{roe} + u \quad (\text{Model})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad \rightarrow \quad \widehat{\text{salary}} = \beta_0 + \beta_1 \text{roe} \quad (\text{ÖRF})$$

$$\widehat{\text{salary}} = 963.191 + 18.501 \text{ roe} \quad (\text{ÖRF})$$

$$n = 209$$

salary: CEO maaşı (bin dolar); *roe*: şirketin karlılık yüzdesi

- Kesim parametresi $\hat{\beta}_0 = 963.191$ olarak tahmin edilmiştir.
 - $roe = 0$ olduğunda modelce tahmin edilen CEO maaşı $\widehat{\text{salary}}$ 'yi ifade eder. Yani şirketin karlılık yüzdesi roe sıfır olduğunda, CEO maaşı \$963191'dir.
- Eğim parametresi $\hat{\beta}_1 = 18.501$ olarak tahmin edilmiştir.
 - roe 'yı 1 birim arttırdığımızda CEO maaşı salary 18.501 birim, yani \$18501 artar.
 - Başka bir ifadeyle, iki CEO'dan birinin roe düzeyi diğerinden bir birim fazlaysa, bu iki CEO için tahmin edilen maaş farkı ortalama olarak \$18501'dir.
 - Burada somut iki CEO'dan değil ortalama durumdan bahsedilmektedir.

Örnek: CEO Maaşı vs. Karlılık Modeli

- roe 'daki farklı artışların CEO maaşı üzerindeki etkisini tahmin etmek için ÖRF'yi kullanabiliriz. Örneğin, $\Delta roe = 30$ ise

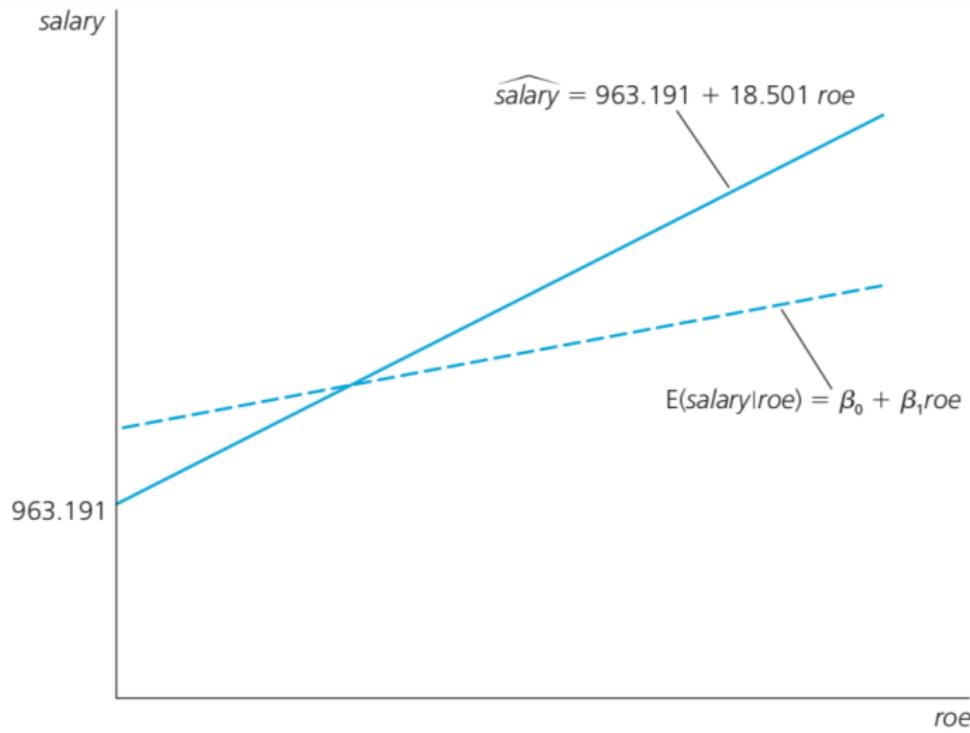
$$\begin{aligned}\widehat{\Delta salary} &= 18.501 \Delta roe && (\text{Değişim Cins.}) \\ &= 18.501 \times 30 \\ &= 555.030\end{aligned}$$

- Farklı roe seviyelerindeki CEO maaşını tahmin etmek için ÖRF'yi kullanabiliriz. Örneğin, $roe = 30$ ise

$$\begin{aligned}\widehat{salary} &= 963.191 + 18.501 roe && (\text{ÖRF}) \\ &= 963.191 + 18.501 \times 30 \\ &= 1518.221\end{aligned}$$

- Ancak bu, şirketi %30 karlılığa sahip olan belirli bir CEO'nun \$1518221 kazandığı anlamına gelmez. Bu sadece ÖRF kullanılarak yapılan bir tahmidir.
- Slayt 41'de verilen CEO maaşı vs. karlılık modeline ait
 - ARF ve ÖRF'nin grafiği Şekil 5'de gösterilmiştir.
 - İlk 15 gözlem için bağımsız roe , bağımsız $değişken roe$ ya da gözlenen değer $salary$, tahmin edilen değer $salary$, ve kalıntı \hat{u} Şekil 6'de gösterilmiştir.

Örnek: CEO Maaşı vs. Karlılık Modeli



Şekil 5: CEO Maaşı vs. Karlılık Modeline Ait ARF ve ÖRF

Kaynak: Wooldridge (2016)

Örnek: CEO Maaşı vs. Karlılık Modeli

TABLE 2.2 Fitted Values and Residuals for the First 15 CEOs

obsno	roe	salary	salaryhat	uhat
1	14.1	1095	1224.058	-129.0581
2	10.9	1001	1164.854	-163.8542
3	23.5	1122	1397.969	-275.9692
4	5.9	578	1072.348	-494.3484
5	13.8	1368	1218.508	149.4923
6	20.0	1145	1333.215	-188.2151
7	16.4	1078	1266.611	-188.6108
8	16.3	1094	1264.761	-170.7606
9	10.5	1237	1157.454	79.54626
10	26.3	833	1449.773	-616.7726
11	25.9	567	1442.372	-875.3721
12	26.8	933	1459.023	-526.0231
13	14.8	1339	1237.009	101.9911
14	22.3	937	1375.768	-438.7678
15	56.3	2011	2004.808	6.191895

Şekil 6: CEO Maaşı vs. Karlılık Modeli Tahminine Ait İlk 15 Gözlem İçin Bazı Değerler

Kaynak: Wooldridge (2016)

Örnek: Ücret vs. Eğitim Modeli

Ücret vs. Eğitim Modeli

$$y = \beta_0 + \beta_1 x + u \quad \rightarrow \quad wage = \beta_0 + \beta_1 educ + u \quad (\text{Model})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad \rightarrow \quad \widehat{wage} = \beta_0 + \beta_1 educ \quad (\text{ÖRF})$$

$$\widehat{wage} = -0.9 + 0.54 educ \quad (\text{ÖRF})$$

$n = 526$

wage: saat başına ücret (dolar); *educ*: eğitim düzeyi (yıl)

- Kesim parametresi $\hat{\beta}_0 = -0.9$ olarak tahmin edilmiştir.
 - $educ = 0$ olduğunda modelce tahmin edilen ücret \widehat{wage} 'i ifade eder. Yani çalışanın eğitim düzeyi *educ* sıfır olduğunda, ücreti $-\$0.9$ 'dur. Ancak ücret negatif olamayacağı için yorumlanması anlamsızdır.
- Eğim parametresi $\hat{\beta}_1 = 0.54$ olarak tahmin edilmiştir.
 - *educ*'u 1 yıl arttırdığımızda ücret *wage* 0.54 birim, yani \$0.54 artar.
 - Başka bir ifadeyle, iki çalışandan birinin *educ* düzeyi diğerinden bir yıl fazlaysa, bu iki çalışan için tahmin edilen ücret farkı ortalama olarak \$0.54'dir.
 - Burada somut iki çalışandan değil ortalama durumdan bahsedilmektedir.

Tahmin Edilen Değer ve Kalıntı

i 'inci Gözlem İçin Tahmin Edilen \hat{y}_i Değeri

$$\underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}} = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{ÖRF})$$

- x_i değerini tahmin edilen regresyonda (ÖRF'de) yerine koyarsak tahmin edilen değer \hat{y}_i 'yi elde ederiz.

Kalıntı (Artık)

$$\underbrace{\hat{u}_i}_{\text{Kalıntı (Artık)}} = \underbrace{y_i}_{\text{Gözlenen Değer}} - \underbrace{\hat{y}_i}_{\text{Tahmin Edilen Değer}}$$

- Gözlenen y_i değeriyle tahmin edilen değer \hat{y}_i arasındaki fark kalıntı \hat{u}_i 'yi verir.
- $\hat{u}_i > 0$ ise $y_i > \hat{y}_i$, eksik tahmin yapılmıştır.
- $\hat{u}_i < 0$ ise $y_i < \hat{y}_i$, fazla tahmin yapılmıştır.



Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- SEKK kalıntılarının toplamı ve dolayısıyla da örneklem ortalaması sıfır eşittir.

$$\sum_{i=1}^n \hat{u}_i = 0 \quad \text{ve} \quad \bar{\hat{u}} = 0$$

- Bu durum SEKK birinci sıra koşullarından ilkinin (aynı zamanda örneklem moment koşullarından ilkinin) bir sonucudur. Bakınız Slayt 32 ve Slayt 34.
- Anakütledeki hata terimi u 'nın örneklemdeki analogu kalıntı \hat{u} olarak yorumlanabilir fakat kesinlikle aynı şeyler değildir.

$$\underbrace{u}_{\text{Anakütle}} \longrightarrow \underbrace{\hat{u}}_{\text{Örneklem}}$$

$$\underbrace{E(u) = 0}_{\text{Anakütle}} \longrightarrow E(\hat{u}) = 0, \quad \underbrace{\sum_{i=1}^n \hat{u}_i = 0}_{\text{Örneklem}} \quad \text{ve} \quad \bar{\hat{u}} = 0$$

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- 2 Bağımsız değişken x ile kalıntı \hat{u} arasındaki örneklem kovaryansı ve korelasyon katsayısı sıfırdır.

$$\text{Cov}(x, \hat{u}) = 0 \quad \text{ve} \quad \text{Corr}(x, \hat{u}) = 0$$

- Bu durum diğer SEKK birinci sıra koşullarının (aynı zamanda diğer örneklem moment koşullarının) bir sonucudur. Bakınız Slayt 32 ve Slayt 34.
- Bağımsız değişken x 'le kalıntı \hat{u} 'nın doğrusal olarak ilişkisizliği çıkarılabilir.

$$\text{Cov}(x, u) = 0 \quad \text{ve} \quad \text{Corr}(x, u) = 0 \quad \rightarrow \quad E(xu) = 0 \quad (\text{Anakütle})$$

$$\text{Cov}(x, \hat{u}) = 0 \quad \text{ve} \quad \text{Corr}(x, \hat{u}) = 0 \quad \rightarrow \quad E(x\hat{u}) = 0 \quad (\text{Örneklem})$$

$$\underbrace{E(xu) = 0}_{\text{Anakütle}} \quad \rightarrow \quad \underbrace{E(x\hat{u}) = 0}_{\text{Örneklem}} \quad \text{ve} \quad \sum_{i=1}^n x_i \hat{u}_i = 0$$

► Ek Bilgi

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- 1. ve 2. cebirsel özelliklerin bir sonucu olarak tahmin edilen değer \hat{y} ile kalıntı \hat{u} arasındaki örneklem kovaryansı ve korelasyon katsayısı sıfırdır.

$$\text{Cov}(\hat{y}, \hat{u}) = 0 \quad \text{ve} \quad \text{Corr}(\hat{y}, \hat{u}) = 0$$

- Bu özellikten tahmin edilen değer \hat{y} ile kalıntı \hat{u} 'nın doğrusal olarak ilişkisizliği çıkarılabilir.

$$\underbrace{\text{Cov}(\hat{y}, \hat{u}) = 0 \quad \text{ve} \quad \text{Corr}(\hat{y}, \hat{u}) = 0}_{\text{Örneklem}} \quad \rightarrow \quad \underbrace{E(\hat{y}\hat{u}) = 0 \quad \text{ve} \quad \sum_{i=1}^n \hat{y}_i \hat{u}_i = 0}_{\text{Örneklem}}$$

► Ek Bilgi



Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri

- ➊ Tahmin edilen değer \hat{y}_i 'lerin ortalaması gözlenen değer y_i 'lerin ortalamasına eşittir.

$$y_i = \hat{y}_i + \hat{u}_i$$

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i + \underbrace{\sum_{i=1}^n \hat{u}_i}_{= 0} \quad (1. \text{ Cebirsel Özellik})$$

$$n\bar{\hat{y}} = n\bar{y}$$

$$\bar{\hat{y}} = \bar{y}$$

- ➋ (\bar{x}, \bar{y}) noktası daima ÖRF'den geçer (ÖRF üzerindedir).

$$(\bar{x}, \bar{y}) \longrightarrow \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

Kareler Toplamları

- Her bir i gözlemi için gözlenen değer, tahmin edilen değer ve kalıntı arasındaki ilişki aşağıdaki gibi gösterilebilir.

$$y_i = \hat{y}_i + \hat{u}_i$$

- Her iki tarafın örneklem ortalamalarından sapmalarının karesini alıp toplarsak

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(\hat{y}_i - \bar{\hat{y}}) + (\hat{u}_i - \bar{\hat{u}})]^2$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(\hat{y}_i - \bar{y}) + \hat{u}_i]^2 \quad (1. \text{ ve } 4. \text{ Cebirsel Öz.})$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2 + 2 \underbrace{\sum_{i=1}^n \hat{u}_i \hat{y}_i}_{= 0} - 2\bar{y} \underbrace{\sum_{i=1}^n \hat{u}_i}_{= 0} \quad (3. \text{ Cebirsel Öz.})$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2$$

Kareler Toplamları

- **Toplam Kareler Toplamı:** SST (Total Sum of Squares) y 'deki toplam değişkenliği verir.

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

$Var(y) = SST/(n - 1)$ olduğuna dikkat edin.

- **Açıklanan Kareler Toplamı:** SSE (Explained Sum of Squares) model tarafından açıklanan kısımdaki, yani tahmin edilen değer \hat{y} 'lardaki, değişkenliği verir.

$$SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- **Kalıntı Kareleri Toplamı:** SSR (Residual Sum of Squares) model tarafından açıklanamayan kısımdaki, yani kalıntı \hat{u} 'lardaki, değişkenliği verir.

$$SSR = \sum_{i=1}^n \hat{u}_i^2$$



Kareler Toplamları

- y' deki toplam değişkenlik aşağıdaki gibi yazılabilir.

$$SST = SSE + SSR$$

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SSE}} + \underbrace{\sum_{i=1}^n \hat{u}_i^2}_{\text{SSR}}$$

Determinasyon Katsayısı

- y 'deki toplam değişkenlik denkleminin her iki tarafını SST'ye bölersek

$$SST = SSE + SSR$$

$$1 = \frac{SSE}{SST} + \frac{SSR}{SST}$$

- Açıklanan kısmın değişkenliğinin toplam değişkenlik içindeki payı regresyonun **determinasyon katsayısı** ya da **belirlilik katsayıısı**dır (coefficient of determination) ve R^2 ile gösterilir.

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

- SSE hiçbir zaman SST'den büyük olamayacağı için $0 \leq R^2 \leq 1$
- R^2 , y 'deki değişkenliğin x tarafından açıklanan kısmının oranını verir. Regresyonun açıklama gücü yükseldikçe R^2 , 1'e yaklaşır.
- R^2 'yi yorumlarken, yüzdeye dönüştürmek için genellikle 100 ile çarparız: $100 \times R^2$, y 'deki değişkenliğin x tarafından açıklanan kısmının yüzdesini verir.
- R^2 modelin açıklama gücünü (ne kadar iyi fit edildiğini) belirttiği için bazen **uyum iyiliği** (goodness-of-fit) olarak da adlandırılır.
- R^2 şu şekilde de hesaplanabilir: $R^2 = \text{Corr}(y, \hat{y})^2$



Determinasyon Katsayısı: Örnek

CEO Maaşı vs. Karlılık Modeli

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (\text{ÖRF})$$

$$\widehat{\text{salary}} = 963.191 + 18.501 \text{ roe} \quad (\text{ÖRF})$$

$$n = 209, \quad R^2 = 0.0132$$

salary: CEO maaşı (bin dolar); *roe*: şirketin karlılık yüzdesi

- Determinasyon katsayısı 0.0132 olarak tahmin edilmiştir.
- CEO maaşı *salary*'deki değişkenliğin yaklaşık %1.32'si *roe* değişkeniyle açıklanabilmektedir. Diğer bir deyişle, *salary*'daki değişkenliğin yaklaşık %98.68'i açıklanamamıştır.
- Dışarıda bırakılan birçok faktör (hata terimi u 'nun içinde) olduğundan CEO maaşı *salary*'nin küçük bir kısmı açıklanabilmiştir.
- CEO maaşı *salary*'yi etkileyen ve bu modelde yer almayan başka birçok değişken olduğu unutulmamalıdır.



SEKK Parametre Tahmincilerinin Beklenen Değeri

- SEKK parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ örneklemden örnekleme değiştiği için bunlara ait dağılımin özelliklerinin incelenmesi gereklidir.
- İncelenenecek dağılım özelliklerini:
 - Beklenen değer
 - Varyans

Teorem: $\hat{\beta}_0$ ve $\hat{\beta}_1$ 'nın Beklenen Değeri

BDR.1 - BDR.5 varsayımları altında

$$E(\hat{\beta}_0) = \beta_0$$

$$E(\hat{\beta}_1) = \beta_1$$

► Ek Bilgi

- Yani, BDR.1 - BDR.5 varsayımları altında SEKK parametre tahmincilerinin örneklem dağılımlarının ortalaması (beklenen değeri) bilinmeyen anakütle parametrelerine eşittir.

SEKK Parametre Tahmincilerinin Varyansı

- SEKK parametre tahmincilerinin varyans formülünün çıkartılmasında otokorelasyonun olmaması (BDR.6) ve sabit varyans (BDR.7) varsayımları önemli bir rol oyanar.
- Bu nedenle, SEKK parametre tahmincilerinin varyansına geçmeden önce bu iki varsayıım hakkındaki temel bilgileri inceleyeceğiz.

Otokorelasyonun Olmaması

BDR.6: Otokorelasyon Olmaması

Hata terimleri arasında otokorelasyon yoktur.

$$\text{Corr}(u_i, u_s | \mathbf{x}) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s | \mathbf{x}) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s) = 0, \quad i \neq s$$

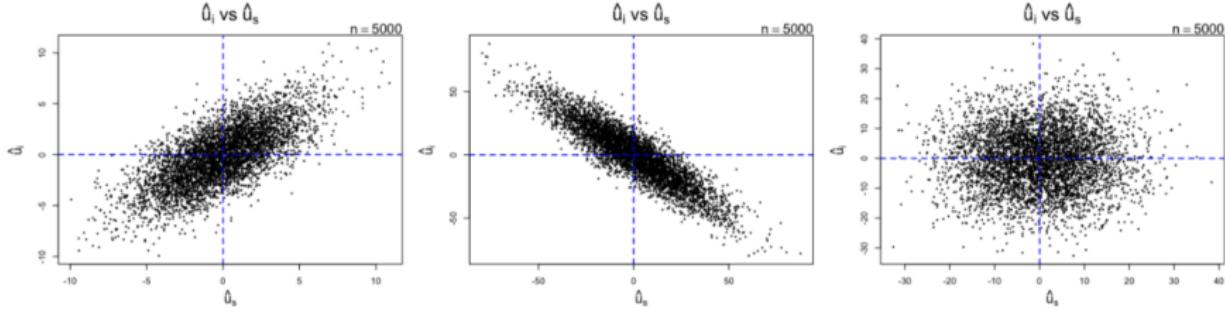
- Bu varsayımda SEKK parametre tahmincilerinin varyansının ve standart hatasının türetilmesinde ve etkinlik özelliklerinin belirlenmesinde kullanılır.
 - SEKK parametre tahmincilerinin sapmasızlığı için BDR.6 varsayıma ihtiyaç yoktur.
- BDR.6 varsayıımı sağlandığında, yani otokorelasyon olmadığından, herhangi iki hata terimi u_i ve u_s doğrusal ilişkisizdir.
- Oysa, BDR.6 varsayıımı sağlanmadığında, herhangi iki hata terimi u_i ve u_s doğrusal ilişkilidir, yani model **otokorelasyon** (autocorrelation) içeriyor demektir.

Otokorelasyonun Olmaması

- Otokorelasyon, çoğunlukla zaman serisi analizine özgür bir sorundur.
- Otokorelasyon olmaması varsayımlı yatay-kesit analizindeki rassallık varsayımlı (BDR.3) nedeniyle genellikle otomatik olarak sağlanır.
 - Rassal örneklemme varsayımlı altında herhangi iki i ve s gözlemlerine ait hata terimleri, u_i ve u_s , birbirinden bağımsızdır, yani otokorelasyon yoktur. Bu durum, bağımsız değişkenlere göre koşullu olarak da geçerlidir.
 - Yatay-kesit analizinde, otokorelasyon varsayımlı sadece çok ekstrem durumlarda gereklidir ve bu nedenle genellikle kullanılmaz. Fakat, burada diğer birçok kaynaktan farklı olarak eklenmiştir.

Uygulamada Otokorelasyonu Belirleme

- Uygulamada, hata terimi u gözlenemediği için u_i ve u_s 'nin doğrusal ilişkili olup olmadığını anlamak mümkün olmaz.
- Bunun yerine kalıntı \hat{u}_i ve \hat{u}_s 'nın grafiğine bakılır.
- Şekil 7'da kalıntı \hat{u}_i ve \hat{u}_s 'nın olası grafikleri verilmiştir. \hat{u}_i ve \hat{u}_s arasındaki doğrusal ilişki:
 - Soldaki grafikte pozitif olduğundan pozitif otokorelasyon vardır.
 - Ortadaki grafikte negatif olduğundan negatif otokorelasyon vardır.
 - Sağdaki grafikte sıfır olduğundan otokorelasyon yoktur.



Şekil 7: Kalıntı \hat{u}_i vs. \hat{u}_s 'nın Olası Grafikleri

Not: Tüm grafiklerde dikey eksende kalıntı \hat{u}_i ve yatay eksende ise kalıntı \hat{u}_s vardır.

Sabit Varyans

BDR.7: Sabit Varyans (Homoscedasticity)

u hata teriminin bağımsız değişken x 'e göre koşullu varyansı sabittir.

$$Var(u|x) = \sigma^2$$

$$Var(u|\mathbf{x}) = \sigma^2$$

$$Var(u) = \sigma^2$$

- Bu varsayımda SEKK parametre tahmincilerinin varyansının ve standart hatasının türetilmesinde ve etkinlik özelliklerinin belirlenmesinde kullanılır.
 - SEKK parametre tahmincilerinin sapmasızlığı için BDR.7 varsayıma ihtiyaç yoktur.
- Örneğin, ücret vs. eğitim modelinde (Slayt 9) bu varsayımda, model dışında bırakılan faktörler u 'daki değişkenliğin modele dahil edilen *educ*'e bağlı olmadığını söyler.
- BDR.5 ve BDR.7 varsayımları kullanılarak Slayt 20'deki gibi bağımlı değişken y 'nin bağımsız değişken x 'lere göre koşullu varyansının da sabit olduğu gösterilebilir.

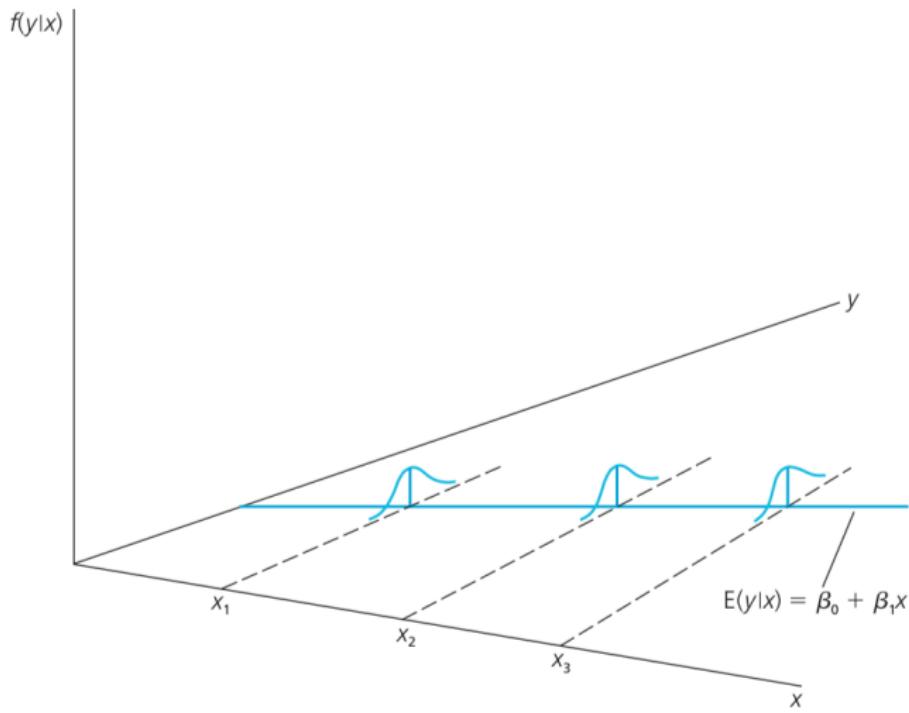
$$Var(y|\mathbf{x}) = \sigma^2$$



Sabit Varyans vs. Değişen Varyans

- **Sabit varyans** (BDR.7) durumunda, $y = \beta_0 + \beta_1x + u$ modeline ait ARF ve $y|\mathbf{x}$ 'in dağılımı Şekil 8'de gösterilmiştir (BDR.5 varsayıımı sağlanıyorken).
- BDR.7'nin sağlanmadığı duruma **değişen varyans** (heteroscedasticity) denir.
- Değişen varyans durumunda, Slayt 9'de verilen ücret vs. eğitim modeline ait ARF ve $y|\mathbf{x}$ 'in dağılımı Şekil 9'deki gibi gösterilebilir (BDR.5 varsayıımı sağlanıyorken).

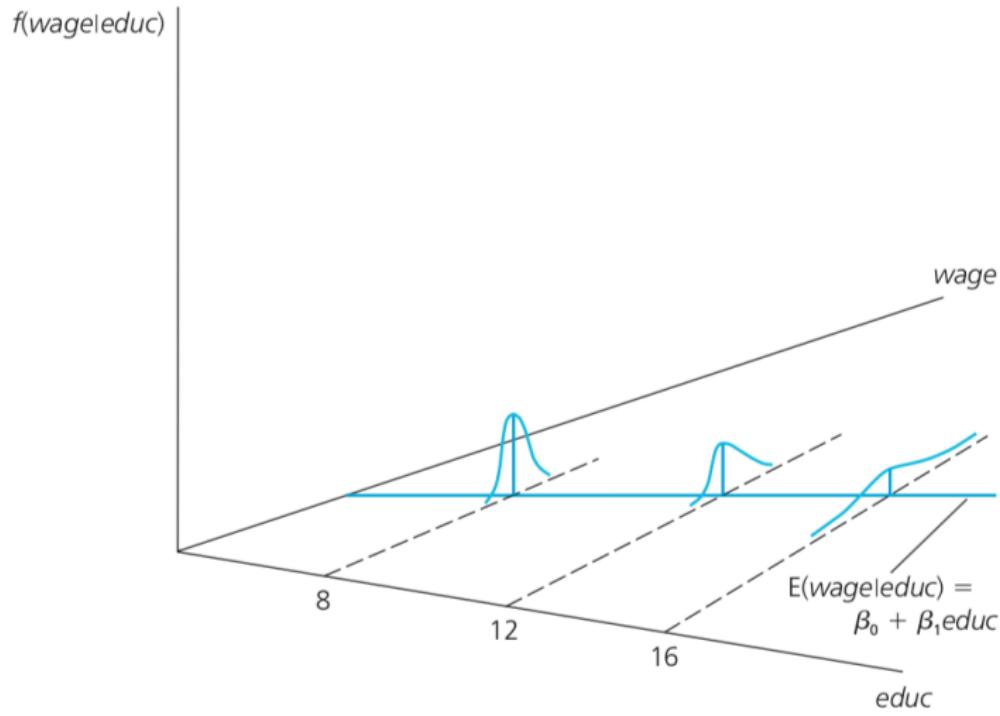
Sabit Varyans



Şekil 8: Sabit Varyans (BDR.7) Durumunda ARF ve $y|\mathbf{x}$ 'in Dağılımı

Kaynak: Wooldridge (2016)

Değişen Varyans



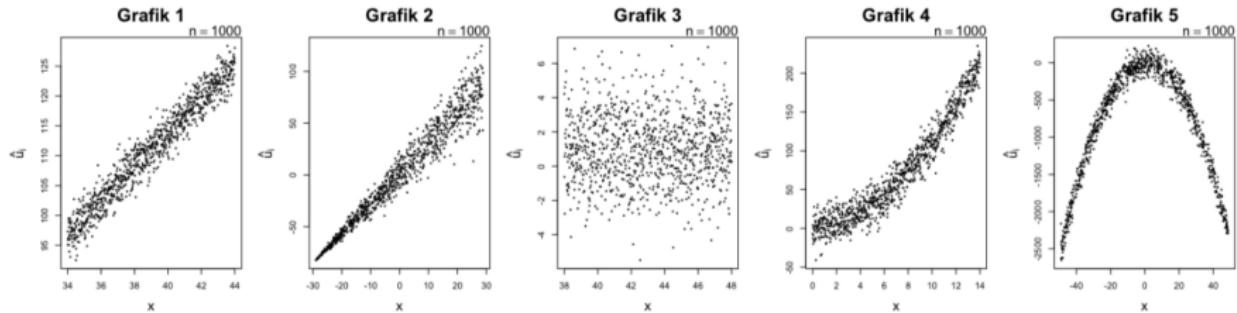
Şekil 9: Değişen Varyans Durumunda ARF ve $y|\mathbf{x}'$ 'in Dağılımı

Kaynak: Wooldridge (2016)

Uygulamada Sabit Varyans vs. Değişen Varyans Belirleme

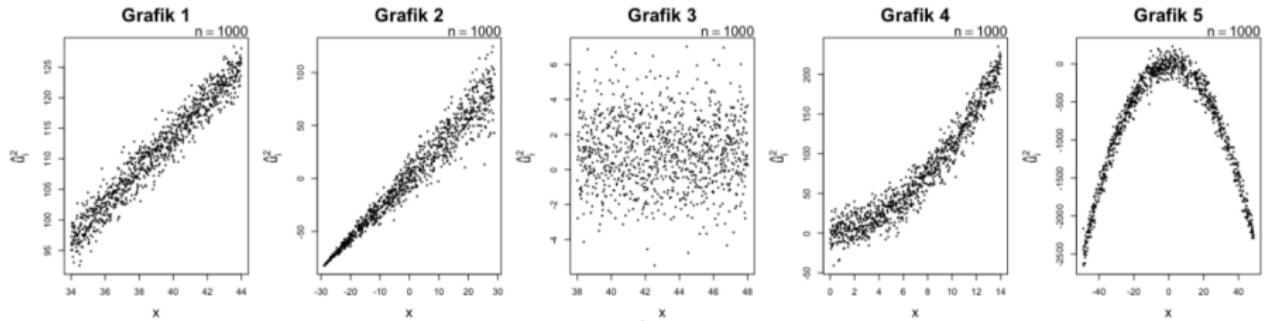
- Uygulamada, hata terimi u gözlenemediği için u 'nun x 'e göre koşullu varyansı $Var(u|\mathbf{x})$ 'in sabit olup olmadığını, yani u 'daki değişkenliğin \mathbf{x} 'e göre nasıl değiştiğini, anlamak mümkün olmaz.
- Bunun yerine iki farklı yöntem kullanılabilir.
 - Kalıntı \hat{u} vs. \mathbf{x} 'in grafiğine bakılır.
 - Kalıntı karesi \hat{u}^2 vs. \mathbf{x} 'in grafiğine bakılır.
- Eğer Şekil 10'deki gibi kalıntı \hat{u} vs. \mathbf{x} 'in grafiğine bakılırsa, kalıntı \hat{u} 'daki değişkenliğin bağımsız değişken \mathbf{x} 'e göre nasıl değiştiği incelenmelidir.
 - Şekil 10'de, sadece Grafik 2'de değişen varyans vardır. Çünkü, \hat{u} 'daki değişkenlik bağımsız değişken \mathbf{x} 'e göre değişir.
 - Şekil 10'deki diğer graifklerde sabit varyans vardır.
- Eğer Şekil 11'deki gibi kalıntı karesi \hat{u}^2 vs. \mathbf{x} 'in grafiğine bakılır, kalıntı karesi \hat{u}^2 'nın bağımsız değişken \mathbf{x} 'e göre nasıl değiştiği incelenmelidir.
 - Şekil 11'de, sadece Grafik 3'de sabit varyans vardır. Çünkü, \hat{u}^2 bağımsız değişken \mathbf{x} 'e göre değişmez (sabit).
 - Şekil 11'deki diğer graifklerde değişen varyans vardır.

Uygulamada Sabit Varyans vs. Değişen Varyans Belirleme



Şekil 10: Kalıntı \hat{u} vs. x 'in Olası Grafikleri

Not: Tüm grafiklerde dikey eksende kalıntı \hat{u}_i ve yatay eksende ise bağımsız değişken x vardır.



Şekil 11: Kalıntı Karesi \hat{u}^2 vs. x 'in Olası Grafikleri

Not: Tüm grafiklerde dikey eksende kalıntı \hat{u}_i^2 ve yatay eksende ise bağımsız değişken x vardır.

SEKK Parametre Tahmincilerinin Varyansı

Teorem: $\hat{\beta}_1$ 'nın Varyansı

Gauss–Markov varsayımları (BDR.1 - BDR.7) altında

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

► Ek Bilgi

- Ekonometrik analizde ana odak $\hat{\beta}_1$ olduğundan, $\hat{\beta}_0$ 'nın varyansı verilmemiştir.
- σ^2 gözlenemeyen hata terimi u 'nun varyansıdır. Bu nedenle σ^2 **hata varyansı**, σ ise **regresyonun standart sapması** olarak adlandırılır.
- SST_x , x 'deki örneklem değişkenliğini ifade eder.
- SEKK parametre tahmincilerine ait varyansın olabildiğinde küçük olması istenir, çünkü küçük varyans tahminin hassaslığını arttırmır. Bakınız Slayt 85.
- $Var(\hat{\beta}_j)$, σ^2 ile aynı yönde ilişkilidir. σ^2 'yi düşürmenin tek yolu güçlü bağımsız değişkenleri modele eklemektir. Daha büyük bir σ^2 , y 'yi etkileyen gözlenemeyen hata terimi u 'ya ait dağılımın daha fazla yayılmış olduğu anlamına gelir.
- $Var(\hat{\beta}_1)$, SST_x ile ters yönde ilişkilidir. SST_x 'yi artırmmanın tek yolu gözlem sayısını artttırmaktır.



SEKK Parametre Tahmincilerinin Varyansı

Teorem: $\hat{\beta}_1$ 'nın Varyansı

Gauss–Markov varsayımları (BDR.1 - BDR.7) altında

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

- Hata terimi u gözlenemediği için hata varyansı σ^2 bilinmez.
- Bu nedenle, SEKK parametre tahmincilerinin varyansı $Var(\hat{\beta}_1)$ 'nın tahmini için öncelikle hata varyansı σ^2 'nin tahmin edilmesi gereklidir.
- Buradaki önemli nokta, $Var(\hat{\beta}_1)$ 'nın sapmasız tahmin edilmesi gereklidir. Bu nedenle, σ^2 'nin de aynı şekilde sapmasız tahmin edilmesi gereklidir.

SEKK Parametre Tahmincilerinin Varyansı

Hata Varyansı σ^2

BDR.5 varsayıımı altında hata varyansı σ^2 aşağıdaki gibi yazılabilir.

$$\begin{aligned} Var(u) &= \sigma^2 = E(u^2) - \underbrace{E(u)^2}_{= 0 \text{ (ÇDR.5)}} && \text{(Varyans Formülü)} \\ &\quad \sigma^2 = E(u^2) \end{aligned}$$

- σ^2 'nin sapmasız tahmincisi hata terimi u 'nun örneklem ortalaması $n^{-1} \sum_{i=1}^n u_i^2$ 'dır.
- Fakat, hata terimi u gözlenemediği için σ^2 'nin tahmininde hata terimi u 'nun yerine onun örneklem analogu olan kalıntı \hat{u} kullanılır. $n^{-1} \sum_{i=1}^n u_i^2 \longrightarrow n^{-1} \sum_{i=1}^n \hat{u}_i^2$
- Fakat $n^{-1} \sum_{i=1}^n \hat{u}_i^2$ sapmalı bir tahmincidir. Bu nedenle, σ^2 'nin sapmasız tahmincisini hesaplamak için bu değerin serbestlik derecesi kullanılarak düzeltilmesi gereklidir.

SEKK Parametre Tahmincilerinin Varyansı

Teorem: Hata Varyansı σ^2 'nin Sapmasız Tahmini

Gauss–Markov varsayımları (BDR.1 - BDR.7) altında hata varyansı σ^2 'nin sapmasız bir tahmincisi:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k - 1} = \frac{SSR}{n - k - 1} = \frac{SSR}{n - 2} \quad (\text{BDR'de } k = 1)$$

- **Serbestik derecesi** (bağımsız bilgi sayısı)

- Bağımsız bilgi sayısı $\rightarrow s.d. = n - (k + 1) = n - k - 1 \rightarrow$ BDR'de $s.d. = n - 2$
- Serbestlik derecesi, SEKK birinci sıra koşullarından ($k + 1$ tane) gelmektedir. Bu koşullar n tane kalıntı \hat{u} 'nın üzerine $k + 1$ tane kısıt koyar.
- n tane kalıntıdan $n - (k + 1)$ tanesi biliniyorsa, geriye kalan $k + 1$ kalıntı otomatik olarak bilinecektir. Bu nedenle kalıntıların serbestlik derecesi $n - k - 1$ 'dir.
- $\hat{\sigma}$, regresyonun standart sapması σ 'nın bir tahmincisidir ve **regresyonun standart hatası** olarak adlandırılır.
- Regresyona yeni bir bağımsız değişken eklendiğinde $\hat{\sigma}$ azalabilir ya da artabilir.
 - Modele yeni bir bağımsız değişken eklendiğinde SSR düşecektir fakat aynı zamanda serbestlik derecesi de 1 düşecektir. SSR payda, serbestlik derecesi ise paydada olduğundan hangi değişimin daha fazla etkiye sahip olacağını kestirememiz.

SEKK Parametre Tahmincilerinin Varyansı

- $\hat{\sigma}^2$ tahmin edildikten sonra $Var(\hat{\beta}_1)$ 'nın formülünde yerine koyulup $Var(\hat{\beta}_1)$ 'nın sapımsız bir tahmincisi hesaplanabilir.

$\hat{\beta}_1$ 'nın Varyans Tahmini

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{SST_x} \quad \longrightarrow \quad \widehat{Var(\hat{\beta}_1)} = \frac{\hat{\sigma}^2}{SST_x}$$

- Genelde, $Var(\hat{\beta}_1)$ ve $\widehat{Var(\hat{\beta}_1)}$ arasındaki ayrim yazimda net olarak gösterilmez.
 - $\hat{\beta}_1$ 'nın varyans tahmini denildiginde $\widehat{Var(\hat{\beta}_1)}$ kastedilmesine rağmen yazidaki gösterimde genelde $Var(\hat{\beta}_1)$ kullanılır.
 - Bu derste aynı yolu izleyip $\hat{\beta}_1$ 'nın varyans tahminini $Var(\hat{\beta}_j)$ ile gösterecegiz.

$$Var(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{SST_x}$$

- $Var(\hat{\beta}_1)$ direkt olarak $\hat{\sigma}^2$ ya bağlı olduğundan aynen $\hat{\beta}_1$ 'lar gibi $Var(\hat{\beta}_1)$ 'nın da örneklem dagılımı vardır ve örneklemden örnekleme degisir.



SEKK Parametre Tahmincilerinin Varyansı

$\hat{\beta}_1$ 'nın Standart Sapması (sd)

$$sd(\hat{\beta}_1) = \sqrt{Var(\hat{\beta}_1)} \quad \rightarrow \quad sd(\hat{\beta}_1) = \frac{\sigma}{\sqrt{SST_x}}$$

$\hat{\beta}_1$ 'nın Standart Hatası (se)

$$se(\hat{\beta}_1) = \sqrt{Var(\hat{\beta}_1)} \quad \rightarrow \quad se(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{SST_x}}$$

- $se(\hat{\beta}_1)$ güven aralıklarının hesaplanması ve hipotez testlerinde kullanılır.
- $se(\hat{\beta}_1)$ direkt olarak $\hat{\sigma}$ 'ya bağlı olduğundan aynen $\hat{\beta}_1$ gibi $se(\hat{\beta}_1)$ 'nın da örneklem dağılımı vardır ve örneklemden örnekleme değişir.
- $se(\hat{\beta}_1)$, BDR.7 (sabit varyans) varsayımlına dayanan $Var(\hat{\beta}_1)$ formülünden türetildiği için BDR.7 varyasının sağlanmaması durumunda, yani değişen varyans varsa, $Var(\hat{\beta}_1)$ ve $se(\hat{\beta}_1)$ tahminleri sapmalı olur.
- Değişen varyans durumunda SEKK parametre tahmincilerinin varyansları ve dolayısıyla standart hataları geçersizdir ve bu nedenle düzeltilmeleri gereklidir.

SEKK Parametre Tahmincilerinin Özellikleri

- Anakütleden çekilen birbirinden farklı ve tekrarlanan **rassal örneklemeleri** (random samples) kullanarak elde edeceğimiz SEKK parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ 'nın **örneklem dağılımlarının** (sampling distributions) özellikleri nelerdir?
- Bu bölümde, SEKK parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ 'nın **küçük örneklem** (small sample) özellikleri detaylı olarak incelenecaktır. Bu özellikler:
 - **Sapmasızlık:** İlgili parametre tahmin edicisinin örneklem dağılımı ortalamasının (beklenen değerin) anakütle bilinmeyen değerine eşit olmasıdır.
 - **Etkinlik:** İlgili parametre tahmin edicisinin örneklem dağılımı varyansının o tahmin ediciler kümesi içinde (genelde sapmasız tahminci kümesi içinde) en küçük olmasıdır.
- SEKK parametre tahmincileri $\hat{\beta}_0$ ve $\hat{\beta}_1$ 'nın
 - **büyük örneklem** (asimptotik) özellikleri daha sonra ayrıca incelenecaktır.
 - küçük örneklem ve büyük örneklem özellikleri birbirine karıştırılmamalıdır.

SEKK Parametre Tahmincilerinin Sapmasızlığı

Teorem: SEKK Parametre Tahmincilerinin Sapmasızlığı

BDR.1 - BDR.5 varsayımları altında SEKK parametre tahmincileri sapmasızdır.

$$E(\hat{\beta}_0) = \beta_0$$

$$E(\hat{\beta}_1) = \beta_1$$

- **Sapmasızlık**, SEKK parametre tahmincilerinin örneklem dağılımlarının ortalamasının (beklenen değerinin) bilinmeyen anakütle parametrelerine eşit olduğunu söyler.
- Sapmasızlık tekrarlanan örneklemelerden elde edilen çok sayıdaki $\hat{\beta}_0$ ve $\hat{\beta}_1$ tahminlerine ait örneklem dağılımlarının bir özelliğidir.
- Dolayısıyla, tek bir örneklem kullanılarak hesaplanan $\hat{\beta}_0$ ve $\hat{\beta}_1$ ile ilgili olarak hiçbir şey söylemez. Çünkü, bilinmeyen anakütle parametreleri β_0 ve β_1 'den çok uzak bir tahmin de elde edebiliriz.
- İlerleyen slaytlarda sapmasızlık için gerekli olan varsayımlar gösterilmiş ve bazılarılarındaki detaylar verilmiştir. Bu varsayımlardan biri veya bir kaç sağlanmazsa sapmasızlık özelliği kaybolur ve sapmalı tahmin ediciler elde edilir.



SEKK Parametre Tahmincilerinin Sapmasızlığı

Model

$$y = \beta_0 + \beta_1 x + u$$

- Yukarıda verilen modeldeki eğim parametresi β_1 'i tahmin etmek için kullanılan iki farklı parametre tahmincisinin örneklem dağılımları Şekil 12'de verilmiştir.
- $\hat{\beta}_1$, eğim parametresi β_1 'in sapmasız bir tahmincisidir, çünkü:

$$E(\hat{\beta}_1) = \beta_1$$

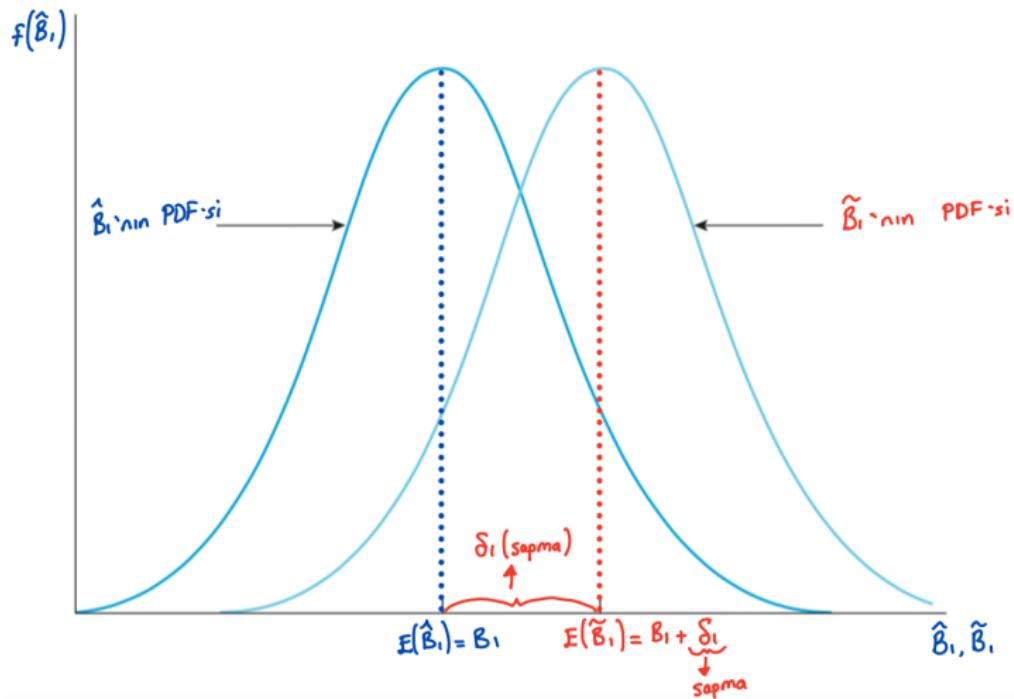
- $\tilde{\beta}_1$, eğim parametresi β_1 'in sapmalı bir tahmincisidir, çünkü:

$$E(\tilde{\beta}_1) \neq \beta_1$$

- $\tilde{\beta}_1$ parametre tahmincisinin sapması δ_1 kadardır.

$$E(\tilde{\beta}_1) = \beta_1 + \delta_1 \quad \longrightarrow \quad \text{sapma} = E(\tilde{\beta}_1) - \beta_1 = \delta_1$$

SEKK Parametre Tahmincilerinin Sapmasızlığı



Şekil 12: Sapmasız $\hat{\beta}_1$ ve Sapmalı $\tilde{\beta}_1$ 'nın Örneklem Dağılımları

Kaynak: Wooldridge (2016)

Sapmasızlık İçin Gerekli Varsayımlar: BDR.1 ve BDR.2

BDR.1: Gözlem Sayısı

Gözlem sayısı n tahmin edilecek anakütle parametre sayısından büyük ya da en azından eşit olmalıdır.

$$n \geq k + 1$$

BDR.2: Parametrelerde Doğrusallık

Model parametrelerde doğrusaldır.

$$y = \beta_0 + \beta_1 x + u \checkmark$$

$$y = \beta_0 + \beta_1 x^2 + u \checkmark$$

$$y = \beta_0 + \beta_1^2 x + u \times$$

$$y = \beta_0 + \sqrt{\beta_1} x + u \times$$



Sapmasızlık İçin Gerekli Varsayımlar: BDR.2

Doğrusal Parametre Tahmincileri

$\hat{\beta}_1$ parametre tahmincisi aşağıdaki gibi yazılabiliriyorsa doğrusaldır.

$$\hat{\beta}_1 = \sum_{i=1}^n w_i y_i$$

- Burada w_i bağımsız değişken x 'in bir fonksiyonudur.
- SEKK parametre tahmincileri aşağıdaki gibi yazılabiligidinden doğrusaldır:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sum_{i=1}^n w_i y_i, \quad \text{burada} \quad w_i = \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- Ekonometrik analizde ana odak $\hat{\beta}_1$ olduğundan, $\hat{\beta}_0$ üzerinde durulmamıştır.

Sapmasızlık İçin Gerekli Varsayımlar: BDR.3 ve BDR.4

BDR.3: Rassallık

Tahminde kullanılan n tane gözlem ilgili anakütleden rassal örneklemeye yoluyla seçilmiştir. Yani gözlemler stokhastiktir (rassal), yani deterministik (kesin) değildir.

$$\{(x_i, y_i) : i = 1, 2, \dots, n\}$$

BDR.4: Bağımsız Değişkenin Sabit Olmaması

Örneklemde (ve bu nedenle anakütlede) bağımsız değişken kendi içinde sabit değildir (yeterli değişimlik vardır).

$$\sum_{i=1}^n (x_i - \bar{x})^2 > 0$$

Sapmasızlık İçin Gerekli Varsayımlar: BDR.5

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$\text{Cov}(x, u) = 0, \quad \text{Corr}(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

- BDR.5 varsayıımı hata terimi u 'nun bağımsız değişken x 'le ilişkisiz olduğunu, yani x 'in **kesin dışsal** (exogenous) olduğunu, söyler.
- Eğer u ve x ile ilişkiliyse, yani BDR.5 sağlanmazsa, SEKK parametre tahmincileri sapmalı olur. Bu durumda tahmin sonuçları güvenilir olmaz.
- BDR.5 varsayıımının sağlanmadığı durumlar nelerdir?
 - Modelin **fonsiyon kalibinin yanlış kurulması** (functional form misspecification)
 - Önemli bir **değişkenin model dışında bırakılması** (omitted variable)
 - Bağımsız değişkenlerde yapılan **ölçme hataları** (measurement error)
- BDR.5 varsayıımı sağlanmıyorsa **içsel değişkenler** (endogenous variables), yani **içsellilik** (endogeneity), söz konusudur.

Sapmasızlık İçin Gerekli Varsayımlar: BDR.5

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$\text{Cov}(x, u) = 0, \quad \text{Corr}(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

- Sıfır koşullu ortalama varsayıımı **ceteris paribus** çıkarımlarının yapılabilmesi için gereklidir.
- BDR.5 varsayıımı aşağıdaki koşulları otomatik olarak sağlar.
 - ① Hata terimi u 'nun anakütle ortalaması sıfırdır.
 - ② Hata terimi u 'nun ortalaması bağımsız değişken x 'den bağımsızdır, yani u ve x ortalama bağımsızdır.

Sapmasızlık İçin Gerekli Varsayımlar: BDR.5

- ➊ Hata terimi u 'nun anakütle ortalaması sıfırdır.

$$E(u) = 0$$

- Modelde kesim parametresi β_0 mevcut olduğu sürece bu koşul kesinlikle sağlanır.
- Bu koşul, u 'nun içerdiği gözlenemeyen faktörlerin dağılımı ile ilgilidir. Kısaca, u 'ların bir kısmı +, bir kısmı ise - işaretlidir ve bunlar birbirini götürdüğünde ortalama sıfır çıkacaktır diye varsayıyoruz.
- β_0 yeniden tanımlanarak bu koşul her zaman kolayca sağlanabilir.

Sapmasızlık İçin Gerekli Varsayımlar: BDR.5

- ② Hata terimi u 'nun ortalaması bağımsız değişken x 'den bağımsızdır, yani u ve x **ortalama bağımsızdır**.

$$E(u|\mathbf{x}) = E(u)$$

- u ve x rassal değişkenler olduğu için x 'in verilen herhangi bir değeri için u 'nun koşullu ortalamasını tanımlayabiliriz.
- Bu koşul gözlenemeyen hata terimi u 'nun ortalamasının x 'in değeriyle belirlenen anakütlenin tüm dilimlerinde aynı olduğunu ve ayrıca u 'nun tüm anakütle üzerindeki ortalamasına eşit olduğunu söyler.
 - Yani, u 'nun ortalaması x 'in alacağı değerlere bağlı değildir.
 - Yani, u ortalamada x 'den bağımsızdır.
- Ortalama bağımsızlık, doğrusal ilişkisizlikten daha güçlü bir kavramdır. Bu nedenle ortalama bağımsızlık aynı zamanda **doğrusal ilişkisizliği** de sağlar.
- Kısacası, bu koşulla beraber gözlenemeyen hata terimi u ve bağımsız değişken x 'in doğrusal olarak ilişkisiz olması da sağlanır.

$$E(u|\mathbf{x}) = E(u) \Rightarrow Cov(x, u) = 0 \text{ ve } Corr(x, u) = 0$$

- Bu koşul, gözlenemeyen hata terimi u ve bağımsız değişken x 'in bağımsız olması hakkında hiçbir varsayımda bulunmaz. Unutmayın ki, bağımsızlık ortalama bağımsızlıktan daha güçlü bir kavramdır.

SEKK Parametre Tahmincilerinin Etkinliği

- Sapmasızlık ile beraber SEKK parametre tahmincilerinin, örneğin $\hat{\beta}_1$ 'nın, örneklem dağılımının β_1 etrafında merkezlendiğini gösterdik.
- Fakat, $\hat{\beta}_1$ 'nın ortalama β_1 'den ne kadar uzakta olacağını da bilmek önemlidir.
- Bir diğer deyişle, tahminin hassallığını artırmak ve daha kesin istatistikci sonuçlara ulaşmak için sapmasız tahminciler arasında ortalamadan en az sapan, yani varyansı en düşük, parametre tahmincisini bulmak isteriz.
- Bunun için de SEKK parametre tahmincilerinin örneklem dağılımındaki yayılımın ölçüsü olan varyans kullanılmalıdır.

SEKK Parametre Tahmincilerinin Etkinliği

Teorem: SEKK Parametere Tahmincilerinin Etkinliği

BDR.6 - BDR.7 varsayımları altında SEKK parametre tahmincileri etkindir.

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

► Ek Bilgi

- SEKK parametresi tahminci $\hat{\beta}_1$ 'nın **etkin** olması **en küçük/minimum varyanslı** olması anlamına gelir.
- Küçük varyans ve dolayısıyla küçük standart hata $se(\hat{\beta}_1)$ istenen bir özellikdir.
 - Küçük varyansa sahip parametresi $\hat{\beta}_1$ 'nın farklı örneklerde elde edilen değerleri gerçek parametre β_1 değerinden (beklenen değeri) çok fazla uzaklaşmaz, yani ortalamadan sapma azdır.
 - Bu nedenle küçük varyansa sahip parametresi $\hat{\beta}_1$ daha **hassas** bir tahmin verir.
 - Küçük standart hata $se(\hat{\beta}_1)$ 'ya sahip ve dolayısıyla daha hassas olan $\hat{\beta}_1$ 'nın güven aralıklarının hesaplanması ve hipotez testlerinin yapılmasında daha **kesin istatistiksel sonuçlara** varabiliriz.



SEKK Parametre Tahmincilerinin Etkinliği

Model

$$y = \beta_0 + \beta_1 x + u$$

- Yukarıda verilen modeldeki eğim parametresi β_1 'i tahmin etmek için kullanılan iki farklı parametre tahmincisinin örneklem dağılımları Şekil 13'de verilmiştir.
- $\hat{\beta}_1$, eğim parametresi β_1 'in sapmasız bir tahmincisidir, çünkü:

$$E(\hat{\beta}_1) = \beta_1$$

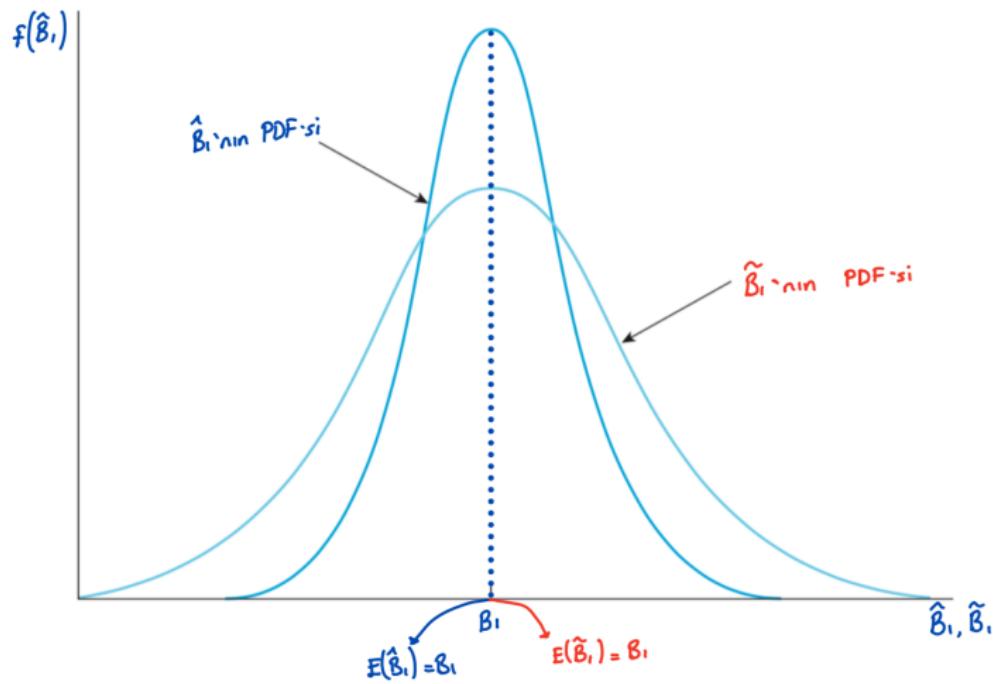
- $\tilde{\beta}_1$, eğim parametresi β_1 'in sapmasız bir tahmincisidir, çünkü:

$$E(\tilde{\beta}_1) = \beta_1$$

- $\hat{\beta}_1$, eğim parametresi β_1 'in sapmasız tahmincileri arasında etkin olan bir parametre tahmincisidir, çünkü:

$$\text{Var}(\hat{\beta}_1) < \text{Var}(\tilde{\beta}_1)$$

SEKK Parametre Tahmincilerinin Etkinliği



Şekil 13: Sapmasız ve Etkin $\hat{\beta}_1$ ve Sapmasız ve Etkin Olmayan $\tilde{\beta}_1$ 'nın Örneklem Dağılımları

Kaynak: Wooldridge (2016)

Etkinlik İçin Gerekli Varsayımlar: BDR.6 ve BDR.7

- Etkinlik için BDR.1 - BDR.5 varsayımlarının yanı sıra BDR.6 - BDR.7 varsayımları da gereklidir.

BDR.6: Otokorelasyon Olmaması

Hata terimleri arasında otokorelasyon yoktur.

$$\text{Corr}(u_i, u_s | x) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s | \mathbf{x}) = 0, \quad i \neq s$$

$$\text{Corr}(u_i, u_s) = 0, \quad i \neq s$$

BDR.7: Sabit Varyans (Homoscedasticity)

u hata teriminin bağımsız değişken x 'e göre koşullu varyansı sabittir.

$$\text{Var}(u|x) = \sigma^2$$

$$\text{Var}(u|\mathbf{x}) = \sigma^2$$

$$\text{Var}(u) = \sigma^2$$



Gauss-Markov Teoremi

Gauss-Markov Teoremi

BDR.1 - BDR.7 varsayımları altında SEKK parametre tahmincileri, tüm doğrusal sapmasız tahminciler arasında etkin/en iyi (minimum varyanslı) olanlardır.

Başka bir ifadeyle, BDR.1 - BDR.7 varsayımları altında SEKK parametre tahmincileri $\hat{\beta}_0, \hat{\beta}_1$ anakütle parametreleri β_0, β_1 'nın **Doğrusal En İyi Sapmasız Tahmin Edicileridir** (DESTE ya da BLUE—**Best Linear Unbiased Estimator**).

- Gauss-Markov Teoremi regresyon modelinin SEKK yöntemiyle tahmini için teorik dayanak sağlar.
- Eğer bu varsayımlar sağlanıyorsa SEKK yöntemi dışında başka bir tahmin yöntemine başvurmamıza gerek yoktur. SEKK yöntemi bize **doğrusal, sapmasız ve varyansı en düşük** (en iyi) tahmincileri vermektedir.
- BDR.1 - BDR.7 varsayımlarından biri bile ihlal edilirse Gaus-Markov Teoremi geçersiz olur.
- BDR.5 sağlanmazsa SEKK parametre tahmincilerinin sapmasızlık özelliği kaybolur ve sapmalı tahmin ediciler elde edilir.
- BDR.6 ve BDR.7 sağlanmazsa etkinlik özelliği kaybolur ve minimum varyans elde edilemez, yani varyans olması gerekenden daha büyük olur.

Gauss–Markov Teoremi



Carl Friedrich Gauss (1777-1855)

Kaynak: Wikipedia



Andrey Markov (1856-1922)

Kaynak: Wikipedia

Orijinden Geçen Regresyon

Orijinden Geçen Regresyon

Bazen Ekonomi Teorisi, kesim parametresi β_0 'ın sıfır olması gerektiğini söyler. Böyle bir durumda β_0 modelden çıkartılarak tahmin yapılır.

$$y = \beta_1 x + u \quad (\text{Model})$$

$$\tilde{y} = \tilde{\beta}_1 x \quad (\text{ÖRF})$$

- Orijinden geçen regresyonda

- Parametre tahminci $\tilde{\beta}_1$ 'nın, kesim parametresi β_0 'ın bulunduğu regresyondaki $\hat{\beta}_1$ dan farklı değer alacağı unutulmamalıdır.
- x 'ler 0 olduğunda tahmin edilen y değeri, yani \hat{y} , 0'dır.
- Cebirsel özellikler geçersizdir.
- R^2 negatif çıkabilir, yani y 'nin örneklem ortalaması, yani \bar{y} , y 'deki değişkenliği açıklamada modeldeki bağımsız değişken x 'lerden daha başarılıdır.
- R^2 negatif ise, $R^2 = 0$ kabul edilir ya da regresyona kesim parametresi eklenerek tahmin yapılır.

Orijinden Geçen Regresyon

Orijinden Geçen Regresyon

Bazen Ekonomi Teorisi, kesim parametresi β_0 'ın sıfır olması gerektiğini söyler. Böyle bir durumda β_0 modelden çıkartılarak tahmin yapılır.

$$y = \beta_1 x + u \quad (\text{Model})$$

$$\tilde{y} = \tilde{\beta}_1 x \quad (\text{ÖRF})$$

- Gerçekte (ARF'de) kesim parametresi β_0 sıfırdan farklı olmasına ($\beta_0 \neq 0$) rağmen orijinden geçen regresyon tahmin edilirse eğim parametresi tahmincisi sapmalı olur. $\rightarrow E(\tilde{\beta}_1) \neq \beta_1$
- Gerçekte (ARF'de) kesim parametresi β_0 sıfır olmasına ($\beta_0 = 0$) rağmen sıfır değilmiş gibi regresyona dahil edilirse eğim parametresi tahmincisinin varyansı yükseltir. $\rightarrow Var(\hat{\beta}_1) \uparrow$
- Gözlem sayısı n arttırılarak parametre tahmincilerinin varyansları düşürülebilirken sapmalı parametre tahminci probleminden kurtulamayız. Bu nedenle uygulamada genelde kesim parametresi β_0 direkt olarak modele eklenir.

Fonksiyonel Form

- Ekonometride sıkılıkla tercih edilen 4 farklı **fonksiyonel form** (functional form) ile regresyon modellerinde y ve x değişkenleri arasındaki ilişkiyi yorumlayalım.
- Farklı fonksiyonel formlar ile ilgili daha fazla bilgi “Ekonometri I - Matematik ve İstatistik Gözden Geçirme” konusunda bulunabilir.

Düzey-Düzey Fonksiyonel Formu

$$y = \beta_0 + \beta_1 x + u \quad \rightarrow \quad \Delta y = \beta_1 \Delta x$$

ceteris paribus koşulu altında, bağımsız değişken x 'deki 1 birimlik artış, bağımlı değişken y 'de ortalamada β_1 birim kadar değişime neden olur.

Düzey-Log Fonksiyonel Formu

$$y = \beta_0 + \beta_1 \ln x + u \quad \rightarrow \quad \Delta y \approx (\beta_1 / 100) \% \Delta x$$

ceteris paribus koşulu altında, bağımsız değişken x 'deki %1'lik artış, bağımlı değişken y 'de ortalamada $\beta_1 / 100$ birim kadar değişime neden olur. $100 \Delta \ln x \approx \% \Delta x$ olduğunu unutmayın.

Fonksiyonel Form

Log-Düzey Fonksiyonel Formu

$$\ln y = \beta_0 + \beta_1 x + u \quad \rightarrow \quad \% \Delta y \approx (100 \beta_1) \Delta x$$

ceteris paribus koşulu altında, bağımsız değişken x 'deki 1 birimlik artış, bağımlı değişken y 'de ortalamada $100 \beta_1$ kadar değişime neden olur. $100 \beta_1$, y 'nin x 'e göre **yarı-esnekliği** olarak adlandırılır. $100 \Delta \ln y \approx \% \Delta y$ olduğunu unutmayın.

Log-Log Fonksiyonel Formu

$$\ln y = \beta_0 + \beta_1 \ln x + u \quad \rightarrow \quad \% \Delta y_t \approx \beta_1 \% \Delta x$$

ceteris paribus koşulu altında, bağımsız değişken x 'deki $\%1$ 'lik artış, bağımlı değişken y 'de ortalamada $\% \beta_1$ kadar değişime neden olur. β_1 , y 'nin x 'e göre **esnekliği** ya da **sabit esnekliği** olarak adlandırılır. $100 \Delta \ln y \approx \% \Delta y$ ve $100 \Delta \ln x \approx \% \Delta x$ olduğunu unutmayın.

- Logaritmik form ekonometrik analizde sıkılıkla kullanılmaktadır.
 - Logaritmik form kullanarak bağımsız değişken x 'in bağımlı değişken y üzerindeki etkisini, ölçü birimlerimden bağımsız olarak, **sabit yüzde** cinsinden elde edebiliriz.

Fonksiyonel Form: Örnek 1

Ücret vs. Eğitim Modeli

$$\widehat{\ln(wage)} = 0.584 + 0.083 \text{ educ}$$

(0.097) (0.008)

$$n = 526, \quad R^2 = 0.186$$

wage: saat başına ücret (dolar); *educ*: eğitim düzeyi (yıl)

- Parametre tahmincilerinin standart hataları $se(\hat{\beta}_0)$ ve $se(\hat{\beta}_1)$ tahminin altında parantez içinde verilmiştir.
- Kesim parametresi $\hat{\beta}_1 = 0.083$ olarak tahmin edilmiştir.
 - Yorumlama:** Ceteris paribus koşulu altında, *educ*'deki 1 birimlik artış, *wage*'de ortalama %100 β_1 , yani %8.3 ($100 \times 0.083 \approx \%8.3$), kadar değişime neden olur.
- Determinasyon katsayısı $R^2 = 0.186$ olarak bulunmuştur.
 - educ*, $\ln(wage)$ 'deki değişkenliğin %18.6'sını açıklayabilmektedir.

Fonksiyonel Form: Örnek 2

Maaş vs. Satış Modeli

$$\widehat{\ln(\text{salary})} = 4.822 + 0.257 \ln(\text{sales})$$

(0.288) (0.035)

$$n = 209, \quad R^2 = 0.211$$

salary: yönetici maaşı (dolar); *sales*: satış mktarı

- Kesim parametresi $\hat{\beta}_1 = 0.257$ olarak tahmin edilmiştir.
 - **Yorumlama:** Ceteris paribus koşulu altında, $\ln(\text{sales})$ 'deki %1'lük artış, $\ln(\text{salary})$ 'de ortalama $\% \beta_1$, yani %0.257, kadar değişime neden olur.
 - Bir başka ifadeyle, yönetici maaşlarının satışlara göre esnekliği 0.257 olarak tahmin edilmiştir.
 - Satışlarda %4'lük bir artış, yönetici maaşlarını yaklaşık %1 ($4 \times \%0.257 \approx \%1$) artırmaktadır.
- Determinasyon katsayısı $R^2 = 0.211$ olarak bulunmuştur.
 - $\ln(\text{sales}), \ln(\text{salary})$ 'deki değişkenliğin %21.1'ini açıklayabilmektedir.

Kaynaklar

Gujarati, D.N. (2009). *Basic Econometrics*. Tata McGraw-Hill Education.

Stock, J.H. ve M.W. Watson (2015). *Introduction to Econometrics*.

Tastan, H. (2020). *Lecture on Econometrics I. Personal Collection of H. Tastan*. Retrieved from Online.

Wooldridge, J.M. (2016). *Introductory Econometrics: A Modern Approach*. Nelson Education.

Ek Bilgiler

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = 0$$

- Daha önce gördüğümüz Yinelenen Beklentiler Kanunu'nu hatırlayalım.

Yinelenen Beklentiler Kanunu

$$E[E(u|\mathbf{x})] = E(u)$$



Ek Bilgiler

- Yinelemeden Beklentiler Kanunu kullanılarak BDR.5 varsayıımı yeniden tanımlanabilir.

$$\underbrace{E[E(u|\mathbf{x})]}_{= 0} = E(u)$$

$$E[0] = E(u)$$

$$0 = E(u)$$

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

Yani, hata terimi u 'nun bağımsız değişken x 'e göre koşullu ve koşulsuz ortalaması sıfırdır.



Ek Bilgiler

- Koşullu beklenen değerin 5. özelliğini kullanarak u ve x arasındaki ilişki hakkında daha fazla yorumda bulunabiliriz.

Koşullu Beklenen Değer: Özellik 5

$$E(u|\mathbf{x}) = E(u) \quad \text{ise} \quad Cov(x, u) = 0 \quad \text{ve} \quad Corr(x, u) = 0$$

Yani, bağımsız değişken x 'in her doğrusal fonksiyonu hata terimi u ile ilişkisizdir.

BDR.5: Sıfır Koşullu Ortalama

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

Sonuç: u ve x ortalama bağımsızdır. Yani u ve x doğrusal olarak ilişkisizdir.

 Sunuma Geri Dön



Ek Bilgiler

BDR.5: Sıfır Koşullu Ortalama Varsayıımı

$$E(u|\mathbf{x}) = E(u) = 0$$

$$Cov(x, u) = 0, \quad Corr(x, u) = 0 \quad \text{ve} \quad E(xu) = 0$$

$$\begin{aligned} Cov(x, u) &= E(xu) - E(x) \underbrace{E(u)}_{= 0} = 0 \\ &= E(xu) = 0 \end{aligned}$$

◀ Sunuma Geri Dön



Ek Bilgiler

BDR.6: Otokorelasyon Olmaması

$$\text{Cov}(u_i, u_s | \mathbf{x}) = 0 \quad \text{ve} \quad \text{Cov}(u_i, u_s) = 0, \quad i \neq s$$

$$E(u_i u_s | \mathbf{x}) = 0 \quad \text{ve} \quad E(u_i u_s) = 0, \quad i \neq s$$

$$\begin{aligned} \text{Cov}(u_i, u_s | \mathbf{x}) &= E(u_i u_s | \mathbf{x}) - \underbrace{E(u_i | \mathbf{x})}_{= 0} \underbrace{E(u_s | \mathbf{x})}_{= 0} = 0 \\ &= E(u_i u_s) = 0 \end{aligned}$$

◀ Sunuma Geri Dön



Ek Bilgiler

BDR.7: Sabit Varyans (Homoscedasticity)

$$E(u^2|\mathbf{x}) = \sigma^2 \quad \text{ve} \quad E(u^2) = \sigma^2$$

$$\begin{aligned} Var(u|\mathbf{x}) &= E(u^2|\mathbf{x}) - \underbrace{E(u|\mathbf{x})^2}_{= 0} = \sigma^2 \\ &= E(u^2|\mathbf{x}) = \sigma^2 \end{aligned}$$

◀ Sunuma Geri Dön



Ek Bilgiler

Anakütle Regresyon Fonksiyonu (ARF)

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

$$y = \beta_0 + \beta_1 x + u$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x + \underbrace{E(u|\mathbf{x})}_{= 0}$$

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x \quad (\text{ARF})$$

$$y = \beta_0 + \beta_1 x + u$$

$$\text{Var}(y|\mathbf{x}) = \text{Var}(u|\mathbf{x})$$

$$\text{Var}(y|\mathbf{x}) = \sigma^2$$

Sunuma Geri Dön



Ek Bilgiler

Parametre Tahmincileri

β_0 kesim parametresinin tahmini $\hat{\beta}_0$:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1$$

- $\hat{\beta}_0$ 'nın formülü

- SEKK birinci sıra koşulları ya da örneklem moment koşullarından ilki (Slayt 34)
- Kalıntı \hat{u} 'nın denklemi
- İndeksli haldeki model denklemi

kullanılarak çıkarılabilir.

$$\begin{aligned} \sum_{i=1}^n \hat{u}_i &= \sum_{i=1}^n (y_i - \hat{y}_i) = 0 \\ &= \sum_{i=1}^n y_i - \sum_{i=1}^n \hat{\beta}_0 - \sum_{i=1}^n \hat{\beta}_1 x_i = 0 \\ &= n\bar{y} - n\hat{\beta}_0 - \hat{\beta}_1 n\bar{x} = 0 \\ &= \bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0 \\ \text{Sonuç: } \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned}$$

◀ Sunuma Geri Dön



Ek Bilgiler

Parametre Tahmincileri

β_1 eğim parametresinin tahmini $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- $\hat{\beta}_1$ 'nın formülü

- SEKK birinci sıra koşulları ya da örneklem moment koşullarından ikincisi (Slayt 34)
- Kalıntı \hat{u} 'nın denklemi
- β_0 kesim parametresinin tahmini $\hat{\beta}_0$
- Ortalamadan sapmaların kareleri toplamı

kullanılarak çıkarılabilir.

$$\begin{aligned} \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ &= \sum_{i=1}^n x_i (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0 \end{aligned}$$



Ek Bilgiler

$$\sum_{i=1}^n x_i(y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0$$

$$\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} + \sum_{i=1}^n \hat{\beta}_1 x_i \bar{x} - \sum_{i=1}^n \hat{\beta}_1 x_i x_i = 0$$

$$\sum_{i=1}^n x_i(y_i - \bar{y}) = \hat{\beta}_1 \sum_{i=1}^n x_i(x_i - \bar{x})$$

Sonuç: $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$

burada

$$\sum_{i=1}^n x_i(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$\sum_{i=1}^n x_i(x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})^2$$

◀ Sunuma Geri Dön



Ek Bilgiler

Parametre Tahmincileri

β_1 eğim parametresinin tahmini $\hat{\beta}_1$ 'nın BDR'deki formülünün bir diğer gösterimi:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

burada

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i$$

◀ Sunuma Geri Dön



Ek Bilgiler

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri - 2

$$\begin{aligned} Cov(x, \hat{u}) &= E(x\hat{u}) - E(x) \underbrace{E(\hat{u})}_{=0} = 0 && \text{(1. Cebirsel Özellik)} \\ &= E(x_j\hat{u}) = 0 \\ \text{ya da} \end{aligned}$$

$$\begin{aligned} Cov(x, \hat{u}) &= \frac{\sum_{i=1}^n (x_i - \bar{x})(\hat{u}_i - \bar{\hat{u}})}{n-1} = 0 \\ Cov(x, \hat{u}) &= \sum_{i=1}^n x_i (\hat{u}_i - \underbrace{\bar{\hat{u}}}_{=0}) = 0 && \text{(1. Cebirsel Özellik)} \\ &= \sum_{i=1}^n x_i \hat{u}_i = 0 \end{aligned}$$

Sunuma Geri Dön



Ek Bilgiler

Tahmin Edilen Değer ve Kalıntıların Cebirsel Özellikleri - 3

$$Cov(\hat{y}, \hat{u}) = Cov(\hat{\beta}_0 + \hat{\beta}_1 x, \hat{u})$$

$$= \hat{\beta}_1 \underbrace{Cov(x, \hat{u})}_{= 0} = 0 \quad (2. \text{ Cebirsel Özellik})$$

$$= E(\hat{y}\hat{u}) = 0 \quad (\text{Kovaryans formülü ve 1. Cebirsel Özellik})$$

$$Cov(\hat{y}, \hat{u}) = \sum_{i=1}^n (\hat{y}_i - \bar{y})(\hat{u}_i - \underbrace{\bar{u}}_{= 0}) = \sum_{i=1}^n (\hat{y}_i - \bar{y})\hat{u}_i = 0 \quad (1. \text{ Cebirsel Özellik})$$

$$= \sum_{i=1}^n \hat{y}_i \hat{u}_i - \bar{y} \underbrace{\sum_{i=1}^n \hat{u}_i}_{= 0} = 0 \quad (1. \text{ Cebirsel Özellik})$$

$$= \sum_{i=1}^n \hat{y}_i \hat{u}_i = 0$$

◀ Sunuma Geri Dön



Ek Bilgiler

SEKK Parametre Tahmincilerinin Beklenen Değeri

$$E(\hat{\beta}_0) = \beta_0$$

$$E(\hat{\beta}_1) = \beta_1$$

BDR Modeli

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\text{Model - İndeksli})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{ÖRF - İndeksli})$$

- $\hat{\beta}_0$ 'nın beklenen değer formülü
 - $\hat{\beta}_0$ 'nın Slayt 36'deki formülünün x 'e (\mathbf{x}) göre koşullu beklenen değerini alıp
 - Model denkleminin toplamları alınarak elde edilen denklem

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad \longrightarrow \quad \sum_{i=1}^n y_i = \sum_{i=1}^n (\beta_0 + \beta_1 x_i + u_i)$$

$$n\bar{y} = n\beta_0 + \beta_1 n\bar{x}$$

$$\bar{y} = \beta_0 + \beta_1 \bar{x}$$

kullanılarak gösterilebilir.



Ek Bilgiler

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (\text{Slayt } 36)$$

$$E(\hat{\beta}_0 | \mathbf{x}) = E(\bar{y} - \hat{\beta}_1 \bar{x} | \mathbf{x})$$

$$\begin{aligned} E(\hat{\beta}_0 | \mathbf{x}) &= \bar{y} - \underbrace{E(\hat{\beta}_1 | \mathbf{x})}_{= \beta_1} \bar{x} \\ &= \beta_1 \end{aligned}$$

$$E(\hat{\beta}_0 | \mathbf{x}) = \bar{y} - \beta_1 \bar{x}$$

$$E(\hat{\beta}_0 | \mathbf{x}) = \beta_0$$

Ek Bilgiler

- $\hat{\beta}_1$ 'nın beklenen değer formülü
 - $\hat{\beta}_1$ 'nın formülü (Slayt 108)
 - BDR model denklemi (Slayt 111)
 - Sıfır koşullu ortalama varsayıımı, BDR.5 (Slayt 14),

kullanılarak gösterilebilir.

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i)}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_1 = \underbrace{\beta_0 \sum_{i=1}^n (x_i - \bar{x})}_{= 0} + \underbrace{\beta_1 \sum_{i=1}^n x_i (x_i - \bar{x})}_{\sum (x_i - \bar{x})^2} + \sum_{i=1}^n (x_i - \bar{x})u_i = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$



Ek Bilgiler

- Alternatif $\hat{\beta}_1$ formülü:

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (\hat{\beta}_1 \text{'nın Alternatif Formülü})$$

- Alternatif $\hat{\beta}_1$ formülünün x 'e (\mathbf{x}) göre koşullu beklenen değerini alalım.

$$E(\hat{\beta}_1 | \mathbf{x}) = E\left(\beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| \mathbf{x}\right) = \beta_1 + \frac{\overbrace{\sum_{i=1}^n (x_i - \bar{x}) E(u_i | \mathbf{x})}^{= 0}}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1$$

$$E(\hat{\beta}_1 | \mathbf{x}) = \beta_1$$



Ek Bilgiler

- $\hat{\beta}_0$ ve $\hat{\beta}_1$ 'nın beklenen değer formülü x 'e (\mathbf{x}) göre koşullu hesaplanmasına rağmen genelde koşulsuz olarak gösterilir:

$$E(\hat{\beta}_0|\mathbf{x}) = \beta_0 \quad \longrightarrow \quad E(\hat{\beta}_0) = \beta_0$$

$$E(\hat{\beta}_1|\mathbf{x}) = \beta_1 \quad \longrightarrow \quad E(\hat{\beta}_1) = \beta_1$$

◀ Sunuma Geri Dön

Ek Bilgiler

Teorem: $\hat{\beta}_1$ 'nın Varyansı

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

BDR Modeli

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\text{Model - İndeksli})$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{ÖRF - İndeksli})$$

- $\hat{\beta}_1$ 'nın varyans formülü

- $\hat{\beta}_1$ 'nın Slayt 114'de gösterilen alternatif formülü
- Otokorelasyon olmaması varsayıımı, BDR.6 (Slayt 15),
- Sabit varyans varsayıımı, BDR.7 (Slayt 16),
- Varyansın bir özelliği $\rightarrow Var(\sum a_i u_i) = \sum a_i^2 Var(u_i)$, burada a_i 'ler sabit sayılardır ve u_i 'ler ikili olarak ilişkisizdir.

kullanılarak çıkarılabilir.



Ek Bilgiler

- Alternatif $\hat{\beta}_1$ formülünün x 'e (\mathbf{x}) göre koşullu varyansını alalım.

$$\begin{aligned}
 Var(\hat{\beta}_1|\mathbf{x}) &= Var\left(\beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \middle| \mathbf{x}\right) = \frac{1}{\left(\sum_{i=1}^n (x_i - \bar{x})^2\right)^2} Var\left(\sum_{i=1}^n (x_i - \bar{x}) u_i \middle| \mathbf{x}\right) \\
 &= \frac{1}{\left(\sum_{i=1}^n (x_i - \bar{x})^2\right)^2} \left(\sum_{i=1}^n (x_i - \bar{x})^2 \underbrace{Var(u_i \mid \mathbf{x})}_{= \sigma^2 \text{ (BDR.7)}} \right) \\
 &= \frac{1}{\left(\sum_{i=1}^n (x_i - \bar{x})^2\right)^2} \sigma^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}
 \end{aligned}$$

Ek Bilgiler

- $\hat{\beta}_1$ 'nın varyans formülü

$$Var(\hat{\beta}_1 | \mathbf{x}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}$$

- $\hat{\beta}_1$ 'nın varyans formülü x 'e (\mathbf{x}) göre koşullu hesaplanmasına rağmen genelde koşulsuz olarak gösterilir:

$$Var(\hat{\beta}_1 | \mathbf{x}) = \frac{\sigma^2}{SST_x} \quad \longrightarrow \quad Var(\hat{\beta}_1) = \frac{\sigma^2}{SST_x}$$

 Sunuma Geri Dön



Ek Bilgiler

Teorem: SEKK Parametere Tahmincilerinin Etkinliği

BDR.6 - BDR.7 varsayımları altında SEKK parametre tahmincileri etkindir.

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

- $\hat{\beta}_1$ 'nın etkinliğini kanıtlayabilmek için β_1 'in herhangi bir doğrusal sapmasız tahmincisi olan $\tilde{\beta}_1$ 'nın $\hat{\beta}_1$ 'e göre daha büyük varyanslı olduğunun gösterilmesi gereklidir. $\rightarrow Var(\tilde{\beta}_1) \geq Var(\hat{\beta}_1)$
- Bu nedenle $\hat{\beta}_1$ ve $\tilde{\beta}_1$ 'nın varyanslarının hesaplanarak karşılaştırılması gereklidir.
- $\hat{\beta}_1$ 'nın x 'e (\mathbf{x}) göre koşullu varyansı (bakınız Slayt 118)

$$Var(\hat{\beta}_1|\mathbf{x}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}$$



Ek Bilgiler

- $\tilde{\beta}_1$ 'nın x 'e (\mathbf{x}) göre koşullu varyansı

- $\hat{\beta}_1$ 'nın Slayt 114'de gösterilen alternatif formülü önce $\tilde{\beta}_1$ için yazılıp x 'e (\mathbf{x}) göre koşullu varyansını alındıktan sonra
- Varyansın bir özelliği $\rightarrow \text{Var}(\sum a_i u_i) = \sum a_i^2 \text{Var}(u_i)$, burada a_i 'ler sabit sayılardır ve u_i 'ler ikili olarak ilişkisizdir.

kullanılarak hesaplanabilir.

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \rightarrow \quad \tilde{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

($\hat{\beta}_1$ ve $\tilde{\beta}_1$ 'nın Alternatif Formülü)

$$\tilde{\beta}_1 = \beta_1 + \sum_{i=1}^n w_i u_i, \quad \text{burada} \quad w_i = \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{ve} \quad \sum_{i=1}^n w_i (x_i - \bar{x}) = 1$$



Ek Bilgiler

$$\begin{aligned}
 Var(\tilde{\beta}_1 | \mathbf{x}) &= Var\left(\beta_1 + \sum_{i=1}^n w_i u_i | \mathbf{x}\right) = Var\left(\sum_{i=1}^n w_i u_i | \mathbf{x}\right) \\
 &= \sum_{i=1}^n w_i^2 \underbrace{Var(u_i | \mathbf{x})}_{= \sigma^2 \text{ (BDR.7)}}
 \end{aligned}$$

$$Var(\tilde{\beta}_1 | \mathbf{x}) = \sigma^2 \sum_{i=1}^n w_i^2 \quad (\tilde{\beta}_1 \text{'nın Varyansı})$$

Ek Bilgiler

- Şimdi, BDR.1 - BDR.7 varsayımları altında $Var(\tilde{\beta}_1|\mathbf{x})$ ve $Var(\hat{\beta}_1|\mathbf{x})$ arasındaki farkı inceleyelim.

$$\begin{aligned}
 Var(\tilde{\beta}_1|\mathbf{x}) - Var(\hat{\beta}_1|\mathbf{x}) &= \sigma^2 \sum_{i=1}^n w_i^2 - \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sigma^2 \left(\sum_{i=1}^n w_{i1}^2 - \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \\
 &= \sigma^2 \left(\sum_{i=1}^n w_i^2 - \frac{\left(\sum_{i=1}^n w_i(x_i - \bar{x}) \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \quad (\sum w_i(x_i - \bar{x}) = 1) \\
 &= \sigma^2 \sum_{i=1}^n \left(w_i - \hat{\gamma}_1(x_i - \bar{x}) \right)^2, \quad \text{burada } \hat{\gamma}_1 = \frac{\sum_{i=1}^n w_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}
 \end{aligned}$$

Ek Bilgiler

$$Var(\tilde{\beta}_1|\mathbf{x}) - Var(\hat{\beta}_1|\mathbf{x}) = \sigma^2 \sum_{i=1}^n (w_i - \hat{y}_1(x_i - \bar{x}))^2, \quad \text{burada} \quad \hat{y}_1 = \frac{\sum_{i=1}^n w_i (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- σ^2 her zaman pozitif olan bir değerdir.
- $\sum_{i=1}^n (w_i - \hat{y}_1(x_i - \bar{x}))^2$ değeri, w_i 'in $(x_i - \bar{x})$ üzerine uygulanan regresyondan elde edilen kalıntı kareleri toplamıdır ve her zaman pozitif olan bir değerdir.
 - \hat{y}_1 ise aynı regresyondan elde edilen eğim parametresi tahmincisidir.
- Bu nedenle $Var(\tilde{\beta}_1) \geq Var(\hat{\beta}_1)$ 'dır.
- $\hat{\beta}_1$ doğrusal sapmasız tahminciler içinde en küçük varyansa sahiptir, yani etkindir.

Teorem: SEKK Parametere Tahmincilerinin Etkinliği

BDR.6 - BDR.7 varsayımları altında SEKK parametre tahmincileri etkindir.

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}, \quad SST_x = \sum_{i=1}^n (x_i - \bar{x})^2$$

Sunuma Geri Dön

