

Otokorelasyon

Hafta #1

11

- * Ekonometride otokorelasyon denildiğinde hata terimlerinin diğer hata terimleri ile ilişkisi akla gelir.
- * Otokorelasyona serisel korelasyon da denilmektedir.
- * Literatürde bazen farklılıklar olsa da genelde otokorelasyon ve serisel korelasyon aynı şeyleri ifade eder.
 - fakat bazı yazarlar aynı serinin farklı devreleri arasındaki ilişkisi ifade etmek için otokorelasyon teriminini kullanır. ÖR: $\varepsilon_1, \varepsilon_2, \varepsilon_3, \dots, \varepsilon_{10}$ ve $\varepsilon_2, \varepsilon_3, \varepsilon_4, \dots, \varepsilon_{11}$
 - iki farklı seri arasındaki ilişkisi ifade etmek için ise serisel korelasyon teriminini kullanırlar. ÖR: $\varepsilon_1, \varepsilon_2, \varepsilon_3, \dots, \varepsilon_{10}$ ve $u_1, u_2, u_3, \dots, u_{10}$
 - fakat biz bunları aynı kavramlarımız gibi kullanacağız.

* Hata terimleri arasında otokorelasyon olmaması, regresyonun temel varsayımlarından biridir.

• Coklu Doğrusal Regresyonda

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

$$y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i \rightarrow \varepsilon_i \sim N(0, \sigma^2_\varepsilon)$$

→ ^① $\text{Corr}(\varepsilon_i, \varepsilon_j | X) = 0 \quad \forall i, j = 1, \dots, n$

CDR 6 → ^② $\text{Cov}(\varepsilon_i, \varepsilon_j | X) = 0 \quad i \neq j$

Not: ^① $\text{Cov}(\varepsilon_i, \varepsilon_j) = E[(\varepsilon_i - E(\varepsilon_i))(\varepsilon_j - E(\varepsilon_j))] = 0$) CDR 5
 $= E[\varepsilon_i \varepsilon_j] = 0 \quad i \neq j \text{ iain}$ E(\varepsilon_i | X) = 0 E(\varepsilon_j | X) = 0

sonuç hata terimleri arasında linear bir bağıntı yok.

$$\textcircled{2} \quad \text{Corr}(\varepsilon_i, \varepsilon_j) = \frac{\text{Cov}(\varepsilon_i, \varepsilon_j)}{\sqrt{\text{Var}(\varepsilon_i)} \sqrt{\text{Var}(\varepsilon_j)}} \stackrel{\{=0\}}{=} 0 \quad .12$$

$$\rho = \frac{\mathbb{E}(\varepsilon_i \varepsilon_j)}{\sigma^2} \quad \begin{aligned} \text{Var}(\varepsilon_i | X) &= \sigma^2 \\ \text{Var}(\varepsilon_j | X) &= \sigma^2 \end{aligned}$$

$$\rho = 0 \quad i \neq j \text{ iken}$$

↪ yani hata terimleri arasında otokorelasyon yok.
herhangi bir i, j ikilisi için

- * Otokorelasyon, model doğru tanımlanmasından ortadan kaldırılabilir ama sistematik olmayan yani rassal kısmın sözanesi gerekir.
- * Artıklarda rassal olmayan bir görünüm varsa otokorelasyon (OK) olabilir.
- * OK zaman serilerinde daha sık görülür.

Otokorelasyonun Montajı

* Örneğin 3 aylık zaman serisi datasiyle ilgili olduğumuzu düşünelim ve akitleri sermaye ve emek üzerine regres edelim. Eğer işçiler bu 3 aylık ilk dönemde greve giderlerse, bu grevin ikinci 3 aylık dönemi etkileneyeceğini varsayımanız otokorelasyon olmaması durumudur. Yani emekteki bir değişiklik bu dönemdeki akiti etkileyecet fakat bir dönem sonrası akiti etkilemeyecektir.

Zaman
Serisi

13

$$\left. \begin{array}{l} Gikt_{1,1} = B_0 + B_1 Sermaye_1 + B_2 Emek_1 + \varepsilon_1 \\ Gikt_{1,2} = B_0 + B_1 Sermaye_2 + B_2 Emek_2 + \varepsilon_2 \end{array} \right\} \begin{array}{l} \checkmark \\ \times \end{array}$$

$E(\varepsilon_1 \varepsilon_2) = 0$

OK YOK

$$\left. \begin{array}{l} Gikt_{1,1} = B_0 + B_1 Sermaye_1 + B_2 Emek_1 + \varepsilon_1 \\ Gikt_{1,2} = B_0 + B_1 Sermaye_2 + B_2 Emek_2 + \varepsilon_2 \end{array} \right\} \begin{array}{l} \checkmark \\ \checkmark \end{array}$$

$E(\varepsilon_1 \varepsilon_2) \neq 0$

OK VAR

Yatay Kesit
Verisi

$$\left. \begin{array}{l} Tüketim_{1,1} = B_0 + B_1 Gelir_1 + \varepsilon_1 \rightarrow \text{aile 1} \\ Tüketim_{1,2} = B_0 + B_1 Gelir_2 + \varepsilon_1 \rightarrow \text{aile 2} \end{array} \right\} \begin{array}{l} \checkmark \\ \times \end{array}$$

$E(\varepsilon_1 \varepsilon_2) = 0 \Rightarrow \text{OK YOK}$

$$\left. \begin{array}{l} Tüketim_{1,1} = B_0 + B_1 Gelir_1 + \varepsilon_1 \rightarrow \text{aile 1} \\ Tüketim_{1,2} = B_0 + B_1 Gelir_2 + \varepsilon_2 \rightarrow \text{aile 2} \end{array} \right\} \begin{array}{l} \checkmark \\ \checkmark \end{array}$$

$E(\varepsilon_1 \varepsilon_2) \neq 0$

OK VAR

* Otokorelasyon denilince regresyon modellerinin hata terimleri için OK hatırlanır fakat her değişken için korelasyon hesaplanabilir.

* Değişkenler arasında bir ilişki olup olmadığını kovaryans ve onun bir türü olan korelasyon katsayıısı ifade eder

$$\text{Cov}(x, y) = E[x - E(x)][y - E(y)]$$

↳ bazen $\text{Cov}(x, y)$ olarak da ifade edilir.

hesaplama

$$\text{Cov}(x, y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n}$$

anakütle
icin

örneklem ?

$$\text{Cov}(x, x) = E[x - E(x)][x - E(x)]$$

$$\text{hesaplama} = E[x - E(x)]^2$$

$$= \frac{\sum (x_i - \bar{x})^2}{n} = s_x^2$$

* Eğer kovaryans sıfırdan farklı ise değişkenler arasında lineer ilişki vardır.

* Kovaryans "- " ve "+" olması ilişkinin yönünü belirtir ama standart bir ölçüt olmadığından ilişkinin gücü hakkında bilgi vermez $-\infty < \text{Cov} < +\infty$

* Bu nedenle korelasyon katsayısi hesaplanır.

* Korelasyon katsayısi ± 1 arasında değer alır standart bir ölçüdür $-1 \leq \text{Corr} \leq +1$

r = Korelasyon katsayısi

ρ = otokorelasyon katsayısi

$$r = \frac{\text{Cov}(x, y)}{s_x s_y}$$

anakütle

örneklem ?

$$r = \frac{E[x - E(x)][y - E(y)]}{\sqrt{E[(x - E(x))^2]} \sqrt{E[(y - E(y))^2]}}$$

$$\Rightarrow r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y}) / n}{\sqrt{\frac{\sum (x_i - \bar{x})^2}{n}} \sqrt{\frac{\sum (y_i - \bar{y})^2}{n}}}$$

* Otokorelasyon katsayıısı ise herhangi bir değişkenin kendinden önceki ya da sonraki gözlemler değerleri ile ilişkisi olup olmadığını ve varsa gücünü gösterir.

ÖR: X değişkeni için X_i ve X_{i-s} arasındaki otokorelasyon katsayıısına bakalım.

Not: $S = \text{devre kaybı}$.

$$X = \{1, 3, 4, 8, 20, 30\}$$

$s=2$ olsun

#	X_i	X_{i-2}
1	1	-
2	3	-
3	4	1
4	8	3
5	20	4
6	30	8

2 devre kaybı
pünkü $s=2$

kullanılacak data

$n-s$ gözlemler kaldı

$s=1$ olsun

#	X_i	X_{i-1}
1	1	-
2	3	1
3	4	3
4	8	4
5	20	8
6	30	20

$$\text{Cov}(x_i, x_{i-s}) = E[x_i - E(x_i)][x_{i-s} - E(x_{i-s})]$$

$$= \frac{\sum_{i=s+1}^n (x_i - \bar{x}_i)(x_{i-s} - \bar{x}_{i-s})}{n}$$

$$q_s = \frac{\text{Cov}(x_i, x_{i-s})}{\sqrt{\sigma_{x_i}^2} \cdot \sqrt{\sigma_{x_{i-s}}^2}}$$

Aşağıdakileri kullanıarak
 q_s yazılabilir

$$\text{Cov}(x_i, x_{i-s}) = \frac{\sum_{i=s+1}^n (x_i - \bar{x}_i)(x_{i-s} - \bar{x}_{i-s})}{n-1}$$

Örneklem

$$\sigma_{x_i}^2 = \frac{\sum_{i=s+1}^n (x_i - \bar{x}_i)^2}{n-1}$$

$$\sigma_{x_{i-s}}^2 = \frac{\sum_{i=s+1}^n (x_{i-s} - \bar{x}_{i-s})^2}{n-1}$$

* $\hat{\rho}_S \Rightarrow$ otokorelasyon fonksiyoru
 ↳ belli devre kayipleri iain
 $s = 1, 2, 3, \dots, M \Rightarrow \hat{\rho}_1, \hat{\rho}_2, \hat{\rho}_3, \dots, \hat{\rho}_M$

(6)

} tekrar dönerceğiz.

Hata Terimleri iain Otokorelasyon Katsayıısı

Basit Regresyonda

$$y_t = \beta_0 + \beta_1 X_t + u_t \quad \forall t = 1, \dots, n$$

OK yok a) $\text{Cov}(u_t, u_{t-s}) = 0; s > 0$ $n = \text{gözlem sayısı}$

OK VAR b) $\text{Cov}(u_t, u_{t-s}) \neq 0; s > 0$ $t = \text{zaman ifade eden indeks}$

* zaman serilerinde zaman t indeksi ile ifade edilir.

* S ile gecikmeden (devre kaybi) bahsedilir.

u_t	u_{t-s}
u_1	-
u_2	-
u_3	-
\vdots	-
u_s	-
u_{s+1}	u_1
\vdots	\vdots
u_t	u_{t-s}
\vdots	
u_n	u_{n-s}

* S teorik olarak

$1 \leq s \leq n-1$ olabilir.

ama uygulanada çok büyük degildir. Eğer çok büyük olursa sorbestlik derecesi düşer.

$n-s$
Kalan
gözlem
sayısı

bağımsız
bilgi
sayısı

→ * iki önemli varsayımlı hatırlayın

$$\text{ADR 5} \Rightarrow E(u_t | x) = 0$$

$$\text{ADR 7} \Rightarrow \text{Var}(u_t | x) = \sigma^2 \quad \Rightarrow \quad t - \text{ye göre}\}$$

değişmiyor

* Korelasyon katsayıısının formülünü kullanarak ve basit regresyondaki eğim parametresinin formülünü kullanarak $\hat{\rho}_S$ ve $\hat{\rho}_{S-1}$ değerlerini hesaplayalım

① Korelasyon katsoyisının formülü ile
CDRS kullanıldı

$$g_s = \frac{\text{Cov}(u_t, u_{t-s})}{\sqrt{\sigma_{u_t}^2} \cdot \sqrt{\sigma_{u_{t-s}}^2}} = \frac{E[u_t - \bar{E}(u_t)][u_{t-s} - \bar{E}(u_{t-s})]}{\sigma_{u_t}^2}$$

CDR7
kullanıldı

$$g_s = \frac{E[u_t \cdot u_{t-s}]}{E[u_t - \bar{E}(u_t)]^2} = \frac{E[u_t \cdot u_{t-s}]}{E[u_t^2]}$$

$$\hat{g}_s^1 = \frac{\sum_{t=s+1}^n (u_t \cdot u_{t-s})}{\sum_{t=s+1}^n u_t^2}$$

② Basit regresyon eğim parametresi ile.

$$y_t = B_0 + B_1 x_t + u_t \quad \forall t = 1, 2, 3, \dots, n$$

$$\hat{B}_1 = \frac{\sum_{t=1}^n (x_t - \bar{x})(y_t - \bar{y})}{\sum_{t=1}^n (x_t - \bar{x})^2}$$

u_t -leri regresyon ile ifade edelim

$$u_t = g_s u_{t-s} + e_t \rightarrow \text{yeri regresyondaki hata terimi}$$

AR(s)
otoregresif
model
s. dereceden

$$\hat{g}_s = \frac{\sum_{t=s+1}^n (u_{t-s} - \bar{u}_{t-s})(u_t - \bar{u}_t)}{\sum_{t=s+1}^n (u_{t-s} - \bar{u}_{t-s})^2}$$

$$e_t \sim N(0, \sigma_e^2)$$

$$\text{Cov}(e_t, e_s) = 0$$

$$\text{Cov}(e_t, u_{t-s}) = 0$$

$$= \frac{\sum_{t=s+1}^n u_t \cdot u_{t-s}}{\sum_{t=s+1}^n (u_{t-s})^2} \cong \frac{\sum_{t=s+1}^n u_t u_{t-s}}{\sum_{t=s+1}^n u_t^2}$$

Sonuç: Korelasyon katsayısi $\hat{\beta}$ ≈ Regresyon modeli
SEKK tahminci

Otokorelasyon Fonksiyonu

$$U_t = \varphi_1 U_{t-1} + \varepsilon_t$$

$$U_t = \varphi_2 U_{t-2} + \varepsilon_{2t}$$

$$U_t = \varphi_3 U_{t-3} + \varepsilon_{3t}$$

$$\vdots \quad \vdots \quad \vdots$$

$$U_t = \varphi_M U_{t-M} + \varepsilon_{Mt}$$

$\hat{\varphi}_i$ -ler otokorelasyon fonksiyonunu oluşturur.

$i = 1, 2, \dots, M$

$\hat{\varphi}_1, \hat{\varphi}_2, \dots, \hat{\varphi}_M$

→ otokorelasyon katsayıları

Otoregresif Süreg

* AR(1) \Rightarrow birinci derereden otoregresif süreg $\Rightarrow (s=1)$

AR(2) \Rightarrow ikinci " " " $\Rightarrow (s=2)$

AR(q) \Rightarrow q. " " " $\Rightarrow (s=q)$

* Eğer otokorelasyon tımcut ise herhangi bir hata terimi s devre önceki / sonraki hata teriminden etkilenmez denetir. Bu ilişkili otokorelasyon katsayıları kader olacaktır.

* Ana model daha önce verilmiştir.

* Hata terimi için AR modeli...

$$\varepsilon_t \sim N(0, \sigma^2)$$

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$$

$$\text{Cov}(\varepsilon_t, U_{t-i}) = 0$$

Kovaryans
formülünden
ve CDR5'den

$$\text{Cov}(\varepsilon_t, U_{t-i}) = E[\varepsilon_t - E(\varepsilon_t)][U_{t-i} - E(U_{t-i})]$$

$$= E[\varepsilon_t \cdot U_{t-i}] = 0$$

Peki AR(1) modelde doğru mu?

$$-1 \leq \varphi \leq 1$$

AR(1)
hata terimi
için

teorik olarak

* Hata terimi için AR modelinin her iki tarafının da kovaryansını alalım.

$$U_t = \varphi U_{t-1} + \varepsilon_t$$

$$\text{Var}(U_t) = \text{Var}(\varphi U_{t-1} + \varepsilon_t) \quad \text{Cov}(U_{t-1}, \varepsilon_t) = 0$$

$$\text{Var}(U_t) = \text{Var}(\varphi U_{t-1}) + \text{Var}(\varepsilon_t) + 2\varphi \text{Cov}(U_{t-1}, \varepsilon_t)$$

$$\text{Var}(U_t) = \varphi^2 \text{Var}(U_{t-1}) + \text{Var}(\varepsilon_t)$$

$$\begin{aligned} \sigma_{U_t}^2 &= \varphi^2 \sigma_{U_{t-1}}^2 + \sigma_{\varepsilon_t}^2 \\ \sigma_{U_t}^2 &= \varphi^2 \sigma_{U_t}^2 + \sigma_{\varepsilon_t}^2 \end{aligned} \quad \Rightarrow \quad \text{Var}(U_t) = \sigma_{U_t}^2 = \sigma_{U_{t-1}}^2 \text{ her } + \text{iain}$$

$$\sigma_{U_t}^2 = \frac{\sigma_{\varepsilon_t}^2}{(1-\varphi^2)} \Rightarrow \sigma_{U_t}^2 \text{-nın tanımlanabilmesi için} \\ 1-\varphi^2 > 0 \Rightarrow 1 > \varphi^2 \Rightarrow -1 < \varphi < 1$$

* Sonuç olarak AR(1) model için derge koşulu $-1 < \varphi < 1$ olarak verilir. Eğer $\varphi = -1$ ya da $\varphi = 1$ olursa ise patlayan bir sistem oluşur.

* Şimdi de U_t ve U_{t-s} arasındaki kovaryansı bulalım.

$$U_t = \varphi U_{t-1} + \varepsilon_t$$

$$U_{t-1} = \varphi U_{t-2} + \varepsilon_{t-1}$$

$$U_{t-2} = \varphi U_{t-3} + \varepsilon_{t-2}$$

⋮

⋮

⋮

$$\textcircled{1} \Rightarrow U_t = \varphi [\varphi U_{t-2} + \varepsilon_{t-1}] + \varepsilon_t$$

$$U_t = \varphi^2 U_{t-2} + \varphi \varepsilon_{t-1} + \varepsilon_t$$

$$\textcircled{2} \quad U_t = \varphi^2 [\varphi U_{t-3} + \varepsilon_{t-2}] + \varphi \varepsilon_{t-1} + \varepsilon_t$$

$$U_t = \varphi^3 U_{t-3} + \varphi^2 \varepsilon_{t-2} + \varphi \varepsilon_{t-1} + \varepsilon_t$$

genel form

$$\downarrow U_t = \varphi^s U_{t-s} + \varphi^{s-1} \varepsilon_{t-s+1} + \varphi^{s-2} \varepsilon_{t-s+2} + \dots + \varphi \varepsilon_{t-1} + \varepsilon_t$$

* Her iki tarafı da U_{t-s} ile aşıri beklenen değerini alalım.

$$U_t = \rho^s U_{t-s} + \rho^{s-1} \varepsilon_{t-s+1} + \dots + \varepsilon_t + \varepsilon_{t+1} + \dots + \varepsilon_{t+s}$$

$$E[U_t U_{t-s}] = E[\rho^s U_{t-s} U_{t-s} + \rho^{s-1} \varepsilon_{t-s+1} U_{t-s} + \dots + \rho \varepsilon_{t-1} U_{t-s} + \varepsilon_t U_{t-s}]$$

$$E[U_t U_{t-s}] = \rho^s E[U_{t-s}^2] + \rho^{s-1} E[\varepsilon_{t-s+1} U_{t-s}] + \dots + \rho E[\varepsilon_{t-1} U_{t-s}] + E[\varepsilon_t U_{t-s}]$$

$$= \text{Cov}(U_t, U_{t-s}) = \sigma_{ut}^2 = 0 \quad \text{GDR5} \quad = 0 \quad \text{GDR5} \quad = 0 \quad \text{GDR5}$$

$$\text{Cov}(U_t, U_{t-s}) = \rho^s \sigma_{ut}^2$$

$$\text{Cov}(U_t, U_{t-s}) = E[U_t - \underbrace{E(U_t)}_{=0}][U_{t-s} - \underbrace{E(U_{t-s})}_{=0}]$$

$$= E[U_t U_{t-s}]$$

$$\text{Var}(U_{t-s}) = E[U_{t-s} - \underbrace{E(U_{t-s})}_{=0}]^2$$

$$= E[U_{t-s}^2]$$

$$= \sigma_{ut-s}^2$$

$$= \sigma_{ut}^2$$

$$\text{Cov}(U_t, U_{t-s}) = \rho^s \sigma_{ut}^2$$

$$\text{Corr}(U_t, U_{t-s}) = \frac{\text{Cov}(U_t, U_{t-s})}{\sigma_{ut}^2} = \rho^s$$

yani s devre kaybı kadar ıssel olmır.

Sonuç $\Rightarrow \rho_s = \rho^s \Rightarrow$ iste bu otokorelasyon fonksiyonudur. Farklı s devre kayiplarına göre değişir.

* Otokorelasyon katsayıları $U_t, U_{t-1}; U_t, U_{t-2}; U_t, U_{t-3}, \dots$ için hesaplanırsa gecikmelerle göre hesaplanan katsayıların oluşturduğu fonksiyona otokorelasyon fonksiyonu denir.


* Bu fonksiyonun grafiği çizilebilir. Bu grafiğe koreogram denir. Koreogram gecikme uzunluğuna göre otokorelasyon katsayılarını gösteren bir grafiktir.

OR:


$$g = 0,6 \text{ varsayılm}$$

$$g = -0,6 \text{ varsayılm}$$


11



* Azalarak giden
lineer ilişkisi var
yon hep pozitif




* Azalarak giden lineer
ilişkisi var fakat yönü
negatif ve pozitif olarak
değişiyor




Pozitif OK

$$0 < g < 1$$



Negatif OK

$$-1 < g < 0$$



OK VOK

$$g = 0$$